

Diseño del modelo multidimensional utilizando las fases del modelo de Kimball - APAAD -

Marcelo Ferreiro Sánchez
Pablo Chantada Saborido
Gillermo García Engelmo
Pepe Romero Conde

26 de octubre de 2025

Índice

1. Introducción	3
2. Restricións	3
2.1. Proceso de negocio, parte <i>top-down</i>	3
2.1.1. Consultas	3
2.2. Fontes de datos, parte <i>bottom-up</i>	4
2.3. Suposicións adicionais	4
3. Detalles da implementación	5
3.1. Nomenclatura e atributos do DFM	5
3.1.1. Táboa de Feitos: FEITOS_REVIEW	6
3.1.2. Dimensión VALORADOR	6
3.1.3. Dimensión HOSPEDAXE	6
3.1.4. Dimensión HOSPEDADOR	6
3.1.5. Dimensión LOCALIZACIÓN	7
3.1.6. Dimensión TEMPO	7
3.1.7. Dimensión EVENTOS	7
3.1.8. Dimensión CHUVIA	7
3.2. Elección de feitos e dimensións	8
3.3. Granularidade	9
3.4. Xustificación de decisións relevantes do modelo	9
3.4.1. Esquema de copo de neve	9
3.4.2. Atributos multivaluados para comodidades e accesibilidade	9
3.4.3. Desnormalización de HOST_VERIFICATIONS	10
3.4.4. Dimensións que cambian no tempo (SCD)	11
3.4.5. Dimensións dexeneradas	12
3.4.6. Xerarquías dimensionais	12
3.5. Métricas	12
3.5.1. Métrica principal: SCORE	12

3.5.2. Carácter aditivo: NON ADITIVA	12
--	----

1. Introducción

No presente informe descríbese o deseño da nosa Base de Datos Analítica.

Nós somos parte do equipo técnico de Airbnb e para analizar o negocio e avaliar onde pode mellorarse ou que aspectos están a fallar encomendóusenos o deseño dunha Base de Datos Analítica. Se ben os directivos facilitáronnos unhas preguntas ás que queren respostas (*consultas* na nosa Base de Datos) tamén temos que satisfacer as restricións dos datos en si mesmos. Non podemos simplemente deseñar o Almacén de datos que queramos, ten que ser posible chegar a el a partir dos `.csv` que temos á nosa disposición. Polo tanto a nosa aproximación metodolóxica é híbrida, pois dispoñemos de restricións de **o proceso de negocio** a modelar (de alto nivel, materializadas nas *consultas*) e de **as fontes de datos** (baixo nivel, materializadas nos `.csv`).

2. Restricións

2.1. Proceso de negocio, parte *top-down*

O interese desde o punto de vista do proceso de negocio é responder ás preguntas evidentes facilmente formulables e ás preguntas que xurdan en función destas. Por iso, para o que poida ocorrer elixiremos sempre a granularidade máis pequena (ver sección 3.2).

2.1.1. Consultas

- Teñen mellores valoracións os terratenentes con múltiples vivendas? (HOSPEDADOR, score)
- Canta é a influencia dos axentes externos no número de reservas? (TEMPO, EVENTOS, CHUVIA)
- Inflúe a idade do arrendatario no seu calendario de viaxes? (VALORADOR, TEMPO)
- Que caracteriza ós arrendatarios con máis valoracións feitas? (VALORADOR)
- Que caracteriza ós arrendadores con mellores *scores*? (HOSPEDADOR, verificacións)
- Como é a relación entre o precio e o score? Os barrios máis caros teñen mellores scores? (HOSPEDAXE, LOCALIZACIÓN)
- Depende o número de verificacións do tempo de resposta? (HOSPEDADOR)
- Que comodidades correlacionan con mellores scores? (HOSPEDAXE, comodidades)
- Varía a importancia das comodidades por localización ou temporada? (HOSPEDAXE, LOCALIZACIÓN, TEMPO)

2.2. Fontes de datos, parte *bottom-up*

Veusenos dado, como punto de partida material para o desenvolvemento do Almacén de Datos, unha colección de `.csvs`, nos que, para cada cidade dispoñemos do seguinte (ver Figura 1):

- **hospedaxes**: cada fila é un obxecto de alugueiro. Tense información de valor ¹ sobre: os donos (quen son e información sobre eles); cantos baños, habitacións e dormitorios hai; cantas persoas poden alugar; o barrio; a dispoñibilidade e información xeral de reserva (cantas noites como mínimo); puntuación das valoracións; e as **comodidades** (formato JSON array).
- **hospedaxes_resumo**: é un subconxunto das columnas de **hospedaxes**. Por tanto máis manexable pero sen información adicional.
- **calendario**: ten un rexistro da dispoñibilidade dos hospedaxes ao longo do tempo. Seranos de utilidade para caracterizar a influencia de factores externos.
- **valoracións**: dinos *quen* fixo *que* reseña e *cando*. No proceso ETL estas reseñas deberán sufrir un proceso de conversión a través dunha ferramenta de Procesamento da Linguaxe Natural (NLP) para obter un *score* numérico, máis útil á hora de ser agregado que a reseña en si mesma.
- **valoracións_resumo**: son pares (`id_hospedaxe`, `data`).
- **veciñdario**: Esta táboa dependendo da cidade da que a descarguemos, pode conter unha pequena información do barrio ou estar baleira directamente. No que segue, simularemos a súa completitude con información aleatoria, por cuestións do alcance da práctica.

Nota: As **comodidades** e **host_verifications** son campos multivaluados en formato array que requiren procesamento no ETL. As reviews individuais con `data` e `reviewer` provén de `reviews.csv`.

2.3. Suposiciones adicionales

Para a futura construción da Base de Datos Analítica serán precisas as seguintes fontes de información actualmente non dispoñibles (para o cumprimento da práctica é probable que inventemos os datos):

- Información adicional sobre os arrendatarios (actualmente só dispoñemos o nome). Idealmente deberíamos contar con: data de nacemento, xénero, lugar de nacemento...
- Rexistros meteorolóxicos (chuvia, neve, altas temperaturas). Estes datos integraranse naturalmente no modelo dimensional como unha dimensión máis.
- Información sobre eventos de interese tales como concertos de música ou partidos deportivos.

¹acompañada de información que non aporta á análise do negocio.




Figura 1: Diagrama de los datos del OLTP

3. Detalles da implementación

A continuación descríbense as decisións técnicas que tiveron lugar na construción do Modelo de Feitos Dimensionais. Para unha representación visual ver a Figura 2.

3.1. Nomenclatura e atributos do DFM

Seguindo as recomendacións de deseño, os atributos representados no diagrama DFM (Figura 2) utilizan nomes descritivos e autoexplicativos, evitando abreviaturas que dificulten a comprensión. A continuación detállanse únicamente os atributos incluídos no modelo conceptual dimensional:

3.1.1. Táboa de Feitos: FEITOS_REVIEW

- `review_id` (PK): Identificador único da valoración
- `score`: Puntuación da valoración (0.00-5.00)
- Claves foráneas ás dimensións: `valorador_id`, `hospedaxe_id`, `data_id`, `eventos_id`, `chuvia_id`

3.1.2. Dimensión VALORADOR

- `valorador_id` (PK): Identificador único do valorador
- `nome_valorador`: Nome completo do usuario
- `idade`: Idade do valorador (calculada de `data_nacemento`)
- `xenero`: Xénero (M/F/Outro/Non especifica)
- `grupo_etario`: Categoría de idade (18-25, 26-35, 36-50, 51+) - jerarquía

3.1.3. Dimensión HOSPEDAXE

- `hospedaxe_id` (PK): Identificador único do aloxamento
- `nome_hospedaxe`: Nome descritivo da propiedade
- `tipo_propiedade`: Tipo de aloxamento (apartamento, casa, habitación privada, etc.)
- `precio_noite`: Prezo por noite en moeda local
- `comodidades`: Atributo multivaluado con elementos gratuitos do hospedaxe (WiFi, cociña, piscina, etc.)
- `accesibilidade`: Atributo multivaluado con características de accesibilidade (rampla, ascensor, etc.)
- `capacidade_maxima`: Número máximo de hóspedes
- `hospedador_id` (FK): Referencia ao propietario (esquema copo de neve)
- `localizacion_id` (FK): Referencia á localización (esquema copo de neve)

3.1.4. Dimensión HOSPEDADOR

- `hospedador_id` (PK): Identificador único do propietario
- `nome_hospedador`: Nome do propietario
- `tempo_resposta`: Tempo medio de resposta
- `numero_propiedades`: Cantidade de aloxamentos que xestiona
- `score_medio`: Valoración media de todas as súas propiedades

- `email_verificado`: Verificación de email (S/N)
- `telefono_verificado`: Verificación de teléfono (S/N)
- `es_superuser`: Status de Superhost (S/N)

3.1.5. Dimensión LOCALIZACIÓN

- `localizacion_id` (PK): Identificador único da localización
- `barrio`: Nome do barrio
- `cidade`: Nome da cidade
- `pais`: Nome do país
- Jerarquía xeográfica: barrio → cidade → país

3.1.6. Dimensión TEMPO

- `data_id` (PK): Identificador único da data (formato YYYYMMDD)
- `dia`: Día do mes
- `mes`: Mes
- `ano`: Ano
- `estacion`: Estación do ano (Primavera, Verán, Outono, Inverno)
- `tempada_alta`: Indicador de tempada alta turística (S/N)
- Xerarquías: día → mes → ano; día → estación → ano

3.1.7. Dimensión EVENTOS

- `eventos_id` (PK): Identificador único do rexistro de eventos
- `numero_eventos`: Cantidade de eventos na cidade ese día
- `tipo_evento_principal`: Tipo do evento máis relevante (Deportivo, Musical, Cultural, etc.)
- `impacto_estimado`: Impacto esperado no turismo (Baixo/Medio/Alto)

3.1.8. Dimensión CHUVIA

- `chuvia_id` (PK): Identificador único do rexistro meteorolóxico
- `precipitacion_mm`: Precipitación en milímetros
- `temperatura_media`: Temperatura media en graos Celsius
- `condicao_xeral`: Descrición xeral (Soleado, Nubrado, Choiva, Tormenta, etc.)




Figura 2: Diagrama do Modelo de Feitos Dimensional (*DFM*). Nota: Os atributos comodidades e accesibilidade em HOSPEDAXE son multivaluados.

3.2. Elección de feitos e dimensións

No noso modelo as reseñas son os **feitos**, pois son moitos e crecen a moita velocidade, e son un punto de partida para moitas análises. É posible que cada departamento teña as súas necesidades especiais, e eventualmente poderase crear *data marts* para cada un deles, pero nós pensamos que as reseñas son de alto interese para calquera análise. Estas contan cunha única **métrica**, o *score*, que indica o grao de satisfacción do usuario coa experiencia do hospedaxe. Así, as circunstancias que circundan á reseña son as **dimensións**, responden ás seguintes preguntas:

- *Quen?* O valorador, cos seus atributos: idade, sexo.
- *Cando?* Indicando ata o día, con información de estacións (para estudar a influencia da tempada alta).
- *A que?* O hospedaxe. Este á súa vez debe responder a: *De quen?* (o propietario, cos seus atributos) e *Onde?* (localización). Ademais, o hospedaxe inclúe *Que comodidades?* como atributos multivaluados.
- *Baixo que circunstancias?* Información meteorolóxica e de eventos xerais.

Pódese apreciar que dentro de *A que?* vai *De quen?* e *Onde?*. Isto indica que o noso Modelo segue o esquema de copo de neve [1], xustificado por evitar redundancia (un hospedador ten múltiples hospedaxes) e implementar xerarquías xeográficas eficientemente. O trade-off é máis JOINS nas consultas, aceptable para un DW analítico.

3.3. Granularidade

.All grain definitions should start at the lowest, most atomic grain and should describe the physical process that collects the data.”

Ralph Kimball [2]

No noso deseño levamos a granularidade ao máis fino que podemos: as datas van ata o día, os lugares ata os barrios, e cada fila da táboa de feitos representa unha **reseña individual**. Esta granularidade atómica permite máxima flexibilidade nas consultas analíticas.

3.4. Xustificación de decisións relevantes do modelo

Nesta sección detállanse as decisións de deseño máis importantes do modelo dimensional, en particular aquelas relacionadas coas particularidades das dimensións e as medidas.

3.4.1. Esquema de copo de neve

O modelo segue un esquema de copo de neve, normalizado parcialmente. Pódese apreciar que a dimensión HOSPEDAXE conecta con HOSPEDADOR e LOCALIZACIÓN, creando dous niveis de normalización.

Xustificación:

- **Evitar redundancia:** Un hospedador xestiona múltiples hospedaxes. Almacenar os seus atributos (nome, verificacións, tempo_resposta) en cada hospedaxe produciría duplicación masiva.
- **Xerarquías xeográficas:** A localización ten unha xerarquía natural (barrio → cidade → país) que benefíciase da normalización.
- **Trade-off aceptable:** Aínda que require máis JOINS nas consultas, en DW analíticos con volumes moderados este custo é asumible. A alternativa (esquema estrela desnormalizado) produciría actualizacións complexas e inconsistencias.

3.4.2. Atributos multivaluados para comodidades e accesibilidade

As comodidades e características de accesibilidade represéntanse como atributos multivaluados dentro da dimensión HOSPEDAXE, non como dimensións independentes.

Xustificación:

- **Natureza descritiva:** As comodidades e a accesibilidade son propiedades intrínsecas do hospedaxe que o describen, non entidades independentes. Non teñen atributos propios máis aló do seu nome.

- **Simplicidade do modelo:** Mantelas como atributos multivaluados evita crear dimensións adicionais e táboas ponte que complicarían o modelo sen aportar valor analítico significativo.
- **Orixe dos datos:** Nos ficheiros fonte (`listings.csv`) xa veñen como arrays JSON, polo que manter esta estrutura simplifica o proceso ETL.
- **Consultas típicas:** As análises sobre comodidades son principalmente de tipo:
 - “Hospedaxes con Wifi” (filtro simple)
 - “Score medio de hospedaxes con piscina” (filtro + agregación)
 - “Comodidades máis comúns nos hospedaxes de 5 estrelas” (parsing do atributo)
- **Implementación técnica:** No modelo lóxico, estas representaríanse como:
 - Opción 1: Campos TEXT coa lista de comodidades (para consultas simples)
 - Opción 2: Táboa auxiliar normalizada `HOSPEDAXE_AMENITIES` (se a análise requirira conteos exactos ou combinacións)

Consideracións de implementación:

No DFM conceptual, os atributos multivaluados indícanse simplemente como comodidades e accesibilidade. No modelo lóxico/físico decidírase se:

- Almacenalos como TEXT delimitado (para consultas WHERE con LIKE)
- Crear unha táboa ponte auxiliar para consultas máis complexas
- Usar tipos de datos específicos do SGBD (arrays, JSON) se están dispoñibles

Esta decisión reflicte o principio de *“o modelo conceptual debe capturar os requisitos de negocio, mentres que os detalles de implementación adaptanse ás capacidades tecnolóxicas”*.

3.4.3. Desnormalización de HOST_VERIFICATIONS

Ao contrario que comodidades, as verificacións do hospedador almacénanse como atributos booleanos directamente na táboa `HOSPEDADOR`.

Xustificación:

- **Baixa cardinalidade:** Só 4-5 tipos de verificación (email, phone, work_email, government_id, identity)
- **Valores estables:** O conxunto de verificacións non cambia frecuentemente
- **Simplificación:** Consultas como “hospedadores con email E teléfono verificados” son triviais sen JOINS
- **Performance:** Evita unha táboa ponte adicional con moi poucas filas

Esta decisión ilustra o principio de *“normalizar ou desnormalizar en función da cardinalidade e patrón de uso”*.

3.4.4. Dimensións que cambian no tempo (SCD)

SCD Tipo 1 (Sobrescribir) - HOSPEDADOR e HOSPEDAXE: Atributos como `score_medio`, `tempo_resposta_medio`, `precio_noite` son variables no tempo pero aplícase SCD Tipo 1.

Xustificación:

- **Foco en estado actual:** As análises empresariais préguntanse “cal é o score actual deste hospedador?”, non “cal era o seu score hai 6 meses?”
- **Reviews como snapshots:** Cada review xa é un rexistro histórico puntual. O score da review non cambia retroactivamente cando o `score_medio` do hospedador mellora.
- **Complexidade vs. valor:** Implementar SCD Tipo 2 (versionado histórico) requiriría:
 - Columnas `data_inicio_vixencia`, `data_fin_vixencia`, `version_actual`
 - Lóxica ETL complexa para detectar cambios e crear novas filas
 - Consultas máis complexas (filtrar por `version_actual = 'S'`)
 - Volume aumentado (múltiples versións de cada hospedador/hospedaxe)
- **Queries típicas non requiren histórico:** As consultas de negocio son tipo:
 - “Hospedadores superhost con `tempo_resposta` ¡1 hora” (estado actual)
 - “Evolución temporal do número de reviews” (xa capturada na táboa de feitos por data)

Escenario donde SCD Tipo 2 sería útil: Se o negocio precisara analizar “como evolucionou o precio deste hospedaxe ao longo do tempo e como afectou ás súas reviews”, entón sería necesario. Pero este non é un requisito das consultas actuais.

SCD Tipo 0 (Sen cambios) - LOCALIZACIÓN, TEMPO, EVENTOS, CHUVIA: Estas dimensións son estables ou históricas por natureza:

- **TEMPO:** Dimensión estática por definición (o 1 de xaneiro de 2023 sempre será o mesmo día)
- **LOCALIZACIÓN:** Barrios e cidades non cambian de nome/país (casos excepcionais ignóranse)
- **EVENTOS e CHUVIA:** Son rexistros históricos puntuais (o tempo do 15/03/2023 xa non cambia)

SCD Tipo 1 implícito - VALORADOR: A idade calcúlase dinamicamente como `EXTRACT(YEAR FROM CURRENT_DATE) - EXTRACT(YEAR FROM data_nacemento)`. Non se almacena, polo que sempre reflicte o valor actual. O `grupo_etario` derivase da idade, tamén calculado en tempo de consulta.

3.4.5. Dimensións dexeneradas

Non se identificaron dimensións dexeneradas no modelo actual. Todos os atributos dimensionais residen en táboas de dimensión propias con atributos descritivos.

Xustificación: Os candidatos típicos a dimensións dexeneradas (como números de factura, códigos de transacción) non aplican no noso contexto. O `review_id` é a clave primaria da táboa de feitos, pero non se usa para análises descritivas (non tes consultas tipo “agrupa por `review_id`”).

3.4.6. Xerarquías dimensionais

As seguintes xerarquías permiten drill-down e roll-up nas análises:

- **TEMPO:**
 - día → mes → ano
 - día → estación → ano
- **LOCALIZACIÓN:** barrio → cidade → país
- **VALORADOR:** idade → grupo_etario (18-25, 26-35, 36-50, 51+)

3.5. Métricas

3.5.1. Métrica principal: SCORE

A nosa táboa de feitos contén unha única métrica: o **SCORE** da valoración.

Características técnicas:

- **Tipo de datos:** DECIMAL(3,2)
- **Rango:** 0.00 - 5.00
- **Orixe:** Obtido mediante procesamento NLP do texto da reseña (`reviews.csv`)

Xustificación da métrica única: Na granularidade de **unha review individual** (unha fila = un feito), o score é o único valor **medible observable no momento do evento**. Seguindo o principio de Kimball de granularidade atómica, unha reseña nun instante só xera unha medida: a valoración do usuario.

Outras métricas candidatas como:

- `numero_reviews_hospedaxe`: é un atributo agregado do hospedaxe (dimensión), non un feito atómico
- `precio`: é unha característica do hospedaxe (dimensión), constante para todas as reviews dese hospedaxe
- `count(*)`: é unha agregación sobre os feitos, non un valor observable

3.5.2. Carácter aditivo: NON ADITIVA

O SCORE é unha métrica **NON ADITIVA**.

Xustificación matemática: Sumar puntuacións non ten sentido semántico:

$$\frac{3}{5} + \frac{4}{5} = \frac{7}{5} \text{ (sen significado)}$$

As valoracións miden satisfacción nunha escala fixa. Non son magnitudes acumulables como vendas ou cantidades.

Operacións válidas: Agregacións non aditivas:

- **AVG(score):** agregación principal por hospedaxe, barrio, hospedador, estación
- **MIN/MAX(score):** rangos de satisfacción
- **MEDIAN(score):** tendencia central robusta a outliers
- **STDDEV(score):** variabilidade das valoracións

Referencias

- [1] Ralph Kimball. *The Data Warehouse Toolkit: Practical Techniques for Building Dimensional Data Warehouses*. Wiley, New York, 1st edition, 1996.
- [2] Ralph Kimball. Keep to the grain in dimensional modeling, July 2007. Accessed: 2025-10-24.