

# Diseño del modelo multidimensional utilizando las fases del modelo de Kimball - AAPAD -

Marcelo Ferreiro Sánchez  
Pablo Chantada Saborido  
Gillermo García Engelmo  
Pepe Romero Conde

25 de octubre de 2025

## Índice

|                                                |          |
|------------------------------------------------|----------|
| <b>1. Introducción</b>                         | <b>2</b> |
| <b>2. Restricións</b>                          | <b>2</b> |
| 2.1. Proceso de negocio, parte <i>top-down</i> | 2        |
| 2.1.1. Consultas                               | 2        |
| 2.2. Fontes de datos, parte <i>bottom-up</i>   | 3        |
| 2.3. Suposicións adicionais                    | 3        |
| <b>3. Detalles da implementación</b>           | <b>4</b> |
| 3.1. Qué é cada cousa?                         | 4        |
| 3.2. Granularidade                             | 6        |
| 3.3. Dimensións particulares                   | 6        |
| 3.3.1. Dimensións dexeneradas                  | 6        |
| 3.3.2. Atributos multivaluados                 | 6        |
| 3.3.3. Dimensións basura                       | 6        |
| 3.3.4. Dimensións que cambian no tempo (SCD)   | 6        |
| 3.3.5. Xerarquías dimensionais                 | 7        |
| 3.4. Métricas                                  | 7        |

# 1. Introducción

No presente informe descríbese o diseño da nosa Base de Datos Analítica.

Nós somos parte do equipo técnico de Airbnb e para analizar o negocio e evaluar onde pode mellorarse ou que aspectos estan a fallar encomendóusenos o diseño dunha Base de Datos Analítica. Se ben os directivos facilitaronnos unhas preguntas ás que queren respostas (*consultas* na nosa Base de Datos) tamén temos que satisfacer a restriccións dos datos en si mesmos. Non podemos simplemente diseñar o Almacén de datos que queramos, ten que ser posible chegar a él a partires dos `.csv` que temos a nosa disposición. Polo tanto a nosa aproximación metodolóxica é híbrida, pois dispoñemos de restriccións de **o proceso de negocio** a modelar (de alto nivel, materializadas nas *consultas*) e de **as fontes de datos** (baixo nivel, materializadas nos `.csv`).

## 2. Restriccións

### 2.1. Proceso de negocio, parte *top-down*

O interés desde o punto de vista de o proceso de negocio e responder a: as preguntas evidentes facilmente formulables e ás preguntas que xurdan en función destas. Por eso, polo que poda ocorrer elixiremos sempre a granularidade máis pequena (ver sección 3.2).

#### 2.1.1. Consultas

- Teñen mellores valoracións os terratenentes con múltiples vivendas? (HOSPEDADOR, score)
- Canta é a influencia dos axentes externos no número de reservas? (TEMPO, EVENTOS, CHUVIA)
- Inflúe a idade do arrendatario no seu calendario de viaxes? (VALORADOR, TEMPO)
- Que caracteriza ós arrendatarios con máis valoracións feitas? (VALORADOR)
- Que caracteriza ós arrendadores con mellores *scores*? (HOSPEDADOR, verificacións)
- Como é a relación entre o precio e o score? Os barrios máis caros teñen mellores scores? (HOSPEDAXE, LOCALIZACIÓN)
- Depende o número de verificacións do tempo de resposta? (HOSPEDADOR)
- Que amenities correlacionan con mellores scores? (AMENITY, HOSPEDAXE)
- Varía a importancia das amenities por localización ou temporada? (AMENITY, LOCALIZACIÓN, TEMPO)

## 2.2. Fontes de datos, parte *bottom-up*

Veúsenos dado, como punto de partida material para o desenvolvemento do Almacén de Datos, unha colección de `.csvs`, nos que, para cada cidade dispoñemos do seguinte (ver Figura 1):

- **hospedaxes**: cada fila é un obxecto de aluguer. Tense información de valor <sup>1</sup> sobre: os donos (quenes son e información sobre eles); cantos baños, habitacións e dormitorios hai; cantas persoas poden alugar; o barrio; a dispoñibilidade e información xeral de reserva (cantas noites como mínimo); puntuación das valoracións; e as **amenities** (formato JSON array).
- **hospedaxes\_resumo**: é un subconxunto das columnas de **hospedaxes**. Por tanto máis manexable pero sin información adicional.
- **calendario**: ten un rexistro da dispoñibilidade de os hospedaxes ó longo do tempo. Seranos de utilidade para caracterizar a influencia de factores externos.
- **valoracions**: dinos *quen* fixo *que* reseña e *cando*. No proceso ETL estas reseñas deberan sufrir un proceso de conversión a través dunha ferramenta de Procesamento da Linguaxe Natural (NLP) para obter un *score* numérico, máis útil á hora de ser agregado que a reseña en si mesma.
- **valoracions\_resumo**: son pares (`id_hospedaxe`, `data`).
- **vecindario**: Esta táboa dependendo da cidade da que a descarguemos, pode conter unha pequena información do barrio ou estar baleira directamente. No que sigue, simularemos a súa completitude con información aleatoria, por cuestións do alcance da práctica.

**Nota:** As **amenities** e **host\_verifications** son campos multivaluados en formato array que requiren procesamento no ETL. As reviews individuais con `data` e `reviewer` provén de `reviews.csv`.

## 2.3. Suposiciones adicionales

Para a futura construción da Base de Datos Analítica serán precisas as seguintes fontes de información actualmente non dispoñibles (para o complemento da práctica é probable que inventemos os datos):

- Información adicional sobre os arrendatarios (actualmente só dispoñemos o nome). Idealmente deberíamos contar con: fecha de nacemento, xénero, lugar de nacemento...
- Rexistros meteorolóxicos (chuvia, neve, altas temperaturas). Estos datos integraranse naturalmente no modelo dimensial como unha dimensión máis.
- Información sobre eventos de interese tales como concertos de música ou partidos deportivos.

---

<sup>1</sup>acompañada de información que non aporta ó análise do negocio.




Figura 1: Diagrama de los datos del OLTP

### 3. Detalles da implementación

A continuación descríbese as decisións técnicas que tiveron lugar na construción do Modelo de Feitos Dimensionais. Para unha representación visual ver a Figura 2.

#### 3.1. Qué é cada cousa?

No noso modelo as reseñas son os **feitos**, pois son moitos e crecen a moita velocidade, e son un punto de partida para moitos análisis. É posible que cada departamento teña as súas necesidades especiais, e eventualmente poderase crear *data marts* para cada un deles, pero nós pensamos que as reseñas son de alto interés para calqueira análise. Estas contan cunha única **métrica**, o *score*, que indica o grao




Figura 2: Diagrama do Modelo de Feitos Dimensional (*DFM*). Nota: A dimensión AMENITY conecta con HOSPEDAXE mediante relación N:M a través dunha táboa ponte. Atributos: amenity\_id, nome, categoría.

de satisfacción do usuario ca experiencia do hospedaxe. Así, as circunstancias que circumbalan á reseña son ás **dimensións**, responden as seguintes preguntas:

- *Quen?* O valorador, cos seus atributos: idade, sexo.
- *Cando?* Indicando ate o día, con información de estacións (para estudar a influencia da tempada alta).
- *A que?* O hospedaxe. Este á súa vez debe responder a: *De quen?* (o propietario, cos seus atributos) e *Onde?* (localización).
- *Que amenities?* Comodidades do hospedaxe (Wifi, cocina, piscina...) mediante táboa ponte N:M.
- *Baixo que circunstancias?* Información meteorolóxica e de eventos xerais.

Pódese apreciar que dentro de *A que?* vai *De quen?* e *Onde?*. Isto indica que o noso Modelo sigue os esquema de copo de neve [1], xustificado por evitar redundancia (un hospedador ten múltiples hospedaxes) e implementar xerarquías xeográficas eficientemente. O trade-off é máis JOINS nas consultas, aceptable para un DW analítico.

## 3.2. Granularidade

.All grain definitions should start at the lowest, most atomic grain and should describe the physical process that collects the data.”

---

Ralph Kimball [2]

No noso diseño levamos a granularidade ó máis fino que podemos: as datas van ate o día, os lugares ate os barrios, e cada fila da táboa de feitos representa unha **reseña individual**. Esta granularidade atómica permite máxima flexibilidade nas consultas analíticas.

## 3.3. Dimensións particulares

### 3.3.1. Dimensións dexeneradas

Non temos dimensións dexeneradas. Todas as dimensións (TEMPO, VALORADOR, HOSPEDAXE, HOSPEDADOR, LOCALIZACIÓN, AMENITY, EVENTOS, CHUVIA) contan con táboas propias e atributos descritivos.

### 3.3.2. Atributos multivaluados

**AMENITIES:** Nos datos fonte aparecen como array JSON: ["Wifi", "Kitchen", "TV"]. Implementamos unha táboa ponte (bridge table):

HOSPEDAXE — — — < HOSPEDAXE\_AMENITY > — — — AMENITY

Táboa AMENITY: `amenity_id` (PK), `nome`, `categoría`.

Táboa HOSPEDAXE\_AMENITY: `hospedaxe_id` (FK), `amenity_id` (FK).

Xustificación: alta cardinalidade (50-200+ valores únicos), crecemento dinámico, permite consultas flexibles. No ETL parseamos o JSON, normalizamos nomes e poboamos as táboas. Ao agregar, úsase `COUNT(DISTINCT)` para evitar duplicación.

**HOST\_VERIFICATIONS:** Array como ['email', 'phone', 'work\_email']. Desnormalizamos en atributos booleanos na táboa HOSPEDADOR: `email_verificado`, `telefono_verificado`, `work_email_verificado` (CHAR(1): 'S'/'N'). Xustificación: baixa cardinalidade (4-5 valores), simplifica consultas, valores estables.

### 3.3.3. Dimensións basura

Non identificamos dimensións basura no modelo.

### 3.3.4. Dimensións que cambian no tempo (SCD)

**HOSPEDADOR e HOSPEDAXE:** SCD Tipo 1 (sobrescribir). Atributos como `score_medio`, `tempo_resposta`, `price` cambian, pero para análise de reviews interézanos o estado actual. Cada review é un snapshot puntual, manter histórico completo (Tipo 2) complicaría o modelo sen valor analítico significativo.

**LOCALIZACIÓN, TEMPO, EVENTOS, CHUVIA, AMENITY:** SCD Tipo 0 (sen cambios). Son datos estables ou históricos.

**VALORADOR:** SCD Tipo 1. A idade calcúlase da data de nacemento.

### 3.3.5. Xerarquías dimensionais

- TEMPO: día → mes → ano; día → estación → ano
- LOCALIZACIÓN: barrio → cidade → país
- VALORADOR: idade → grupo\_etario (18-25, 26-35, 36-50, 51+)
- AMENITY: nome → categoría

## 3.4. Métricas

A nosa métrica principal é o **SCORE** (DECIMAL(3,2), rango 0.00-5.00).

**Carácter: NON ADITIVA.** Non se pode sumar:  $\frac{3}{5} + \frac{4}{5} = \frac{7}{5}$  non ten sentido semántico. As valoracións miden satisfacción nunha escala fixa, non son magnitudes acumulables.

### Operacións válidas:

- **AVG(score):** agregación principal por hospedaxe, barrio, hospedador, estación, amenity
- **COUNT(\*):** volume de reviews (ADITIVA)
- **COUNT(DISTINCT valorador\_id):** usuarios únicos (ADITIVA)
- **MIN/MAX/MEDIAN/STDDEV(score):** rangos e distribucións (NON ADITIVAS)

Métricas derivadas: contaxes (aditivas), agregacións de score (non aditivas), proporcións (non aditivas).

## Referencias

- [1] Ralph Kimball. *The Data Warehouse Toolkit: Practical Techniques for Building Dimensional Data Warehouses*. Wiley, New York, 1st edition, 1996.
- [2] Ralph Kimball. Keep to the grain in dimensional modeling, July 2007. Accessed: 2025-10-24.