

# Diseño del modelo multidimensional utilizando las fases del modelo de Kimball - AAPAD -

Marcelo Ferreiro Sánchez  
Pablo Chantada Saborido  
Gillermo García Engelmo  
Pepe Romero Conde

24 de octubre de 2025

## Índice

|                                                          |          |
|----------------------------------------------------------|----------|
| <b>1. Introducción</b>                                   | <b>2</b> |
| <b>2. Restricións</b>                                    | <b>2</b> |
| 2.1. Proceso de negocio, parte <i>top-down</i> . . . . . | 2        |
| 2.1.1. Consultas . . . . .                               | 2        |
| 2.2. Fontes de datos, parte <i>bottom-up</i> . . . . .   | 2        |
| 2.3. Suposiciones adicionales . . . . .                  | 3        |
| <b>3. Detalles da implementación</b>                     | <b>3</b> |
| 3.1. Qué es que cousa? . . . . .                         | 4        |
| 3.2. Granularidade . . . . .                             | 5        |
| 3.3. Dimensions particulares . . . . .                   | 5        |
| 3.4. Métricas . . . . .                                  | 5        |

# 1. Introducción

No presente informe descríbese o deseño da nosa Base de Datos Analítica.

Nós somos parte do equipo técnico de Airbnb e para analizar o negocio e avaliar onde pode mellorarse ou que aspectos están a fallar encomendáronnos o deseño dunha Base de Datos Analítica. Se ben os directivos facilitáronnos unhas preguntas ás que queren respostas (*consultas* na nosa Base de Datos) tamén temos que satisfacer a restricións dos datos en si mesmos. Non podemos simplemente deseñar o Almacén de datos que queramos, ten que ser posible chegar a él a partir dos `.csv` que temos a nosa disposición. Polo tanto a nosa aproximación metodolóxica é híbrida, pois dispoñemos de restricións de **o proceso de negocio** a modelar (de alto nivel, materializadas nas *consultas*) e de **as fontes de datos** (baixo nivel, materializadas nos `.csv`).

## 2. Restriccións

### 2.1. Proceso de negocio, parte *top-down*

O interese desde o punto de vista de o proceso de negocio e responder a: as preguntas evidentes facilmente formulables e ás preguntas que xurdan en función destas. Por eso, polo que poda ocorrer elixiremos sempre a granularidade máis pequena (*desenvolver este punto en outro lado máis profundamente*).

#### 2.1.1. Consultas

- Teñen mellores valoracións os terratenentes con múltiples vivendas?
- Cantas é a influencia dos axentes externos (chuvia, eventos deportivos ou concertos) no número de reservas?
- Inflúe a idade do arrendatario no seu calendario de viaxes?
- Que caracteriza ós arrendatarios con máis valoracións feitas?
- Que caracteriza ós arrendadores con mellores *scores*?
- Como é a relación entre o prezo dun hospedaxe e o seu score medio? Os barrios máis caros son os que teñen mellores scores?
- Depende o número de medios de accesibilidade do hospedador co seu tempo de resposta?

### 2.2. Fontes de datos, parte *bottom-up*

Veúsenos dado, como punto de partida material para o desenvolvemento do Almacén de Datos, unha colección de `.csvs`, nos que, para cada cidade dispoñemos do seguinte (ver Figura 1):

- **hospedaxes**: cada fila é un obxecto de aluguer. Tense información de valor <sup>1</sup> sobre: os donos (quenes son e información sobre eles); cantos baños, habitacións e dormitorios hai; cantas persoas poden alugar; o barrio; a dispoñibilidade e información xeral de reserva (cantas noites como mínimo); puntuación das valoracións *asegurar a completitude e correctitude de esto que se dice aquí*
- **hospedaxes\_resumo**: é un subconxunto das columnas de **hospedaxes**. Por tanto máis manexable pero sin información adicional.
- **calendario**: ten un rexistro da dispoñibilidade de os hospedaxes ó longo do tempo. Seranos de utilidade para caracterizar a influéncia de factores externos.
- **valoracions**: dinos *quen* fixo *que* reseña e *cando*. No proceso ETL estas reseñas deberan sufrir un proceso de conversión a través dunha ferramenta de Procesamento da Linguaxe Natural (NLP) para obter un *score* numérico, máis útil á hora de ser agregado que a reseña en si mesma.
- **valoracions\_resumo**: son pares (`id_hospedaxe`, `data`).
- **vecindario**: Esta táboa dependendo da cidade da que a descarguemos, pode conter unha pequena información do barrio ou estar baleira directamente. No que sigue, simularemos a súa completitude con información aleatoria, por cuestións do alcance da práctica.

## 2.3. Suposicións adicionais

Para a futura construción da Base de Datos Analítica serán precisas as seguintes fontes de información actualmente non dispoñibles (para o complemento da práctica é probable que inventemos os datos):

- Información adicional sobre os arrendatarios (actualmente só dispoñemos o nome). Idealmente deberíamos contar con: fecha de nacemento, xénero, lugar de nacemento...
- Rexistros meteorolóxicos (chuvia, neve, altas temperaturas). Estes datos integraranse naturalmente no modelo dimensial como unha dimensión máis.
- Información sobre eventos de interese tales como concertos de música ou partidos deportivos.

## 3. Detalles da implementación

A continuación descríbese as decisións técnicas que tiveron lugar na construción do Modelo de Feitos Dimensionais. Para unha representación visual ver a Figura 2.

---

<sup>1</sup>acompañada de información que non aporta ó análise do negocio.




Figura 1: Diagrama de los datos del OLTP

### 3.1. Qué es que cousa?

No noso modelo as reseñas son os **feitos**, pois son moitos e crecen a moita velocidade, e son un punto de partida para moitos análisis. É posible que cada departamento teña as súas necesidades especiais, e eventualmente poderase crear *data marts* para cada un deles, pero nós pensamos que as reseñas son de alto interés para calqueira análise. Estas contan cunha única **métrica**, o *score*, que indica o grao de satisfacción do usuario ca experiencia do hospedaxe. Así, as circunstancias que circumbalan á reseña son ás **dimensións**, responden as seguintes preguntas:

- *Quen?* O valorador, cos seus atributos: idade, sexo...
- *Cando?* Indicando ate o día, con información de estacións (para estudar a




Figura 2: Diagrama do Modelo de Feitos Dimensional (DFM)

influencia da tempada alta)

- *A que?* O hospedaxe. Este á súa vez debe responder a: *De quen?* (o propietario, cos seus atributos) *Onde?* O lugar onde esta o hospedaxe.
- *Baixo que circunstancias?* Información meteorolóxica e de eventos xerais.

Pódese apreciar que dentro de *A que?* vai *De quen?* e *Onde?*. Isto indica que o noso Modelo sigue os esquema de copo de neve [1] .

### 3.2. Granularidade

“All grain definitions should start at the lowest, most atomic grain and should describe the physical process that collects the data.”

Ralph Kimball [2]

No noso diseño levamos a granularidade ó máis fino que podemos, isto significa que as datas van ate o día, os lugares ate os barrios.

### 3.3. Dimensions particulares

### 3.4. Métricas

A nosa única métrica é o *score* da reseña. Non é aditiva porque  $\frac{3}{5} + \frac{4}{5} = \frac{7}{5}$  pero non ten sentido nin é posible scores de máis de 1. En cambio pode agregarse con AVG.

## Referencias

- [1] Ralph Kimball. *The Data Warehouse Toolkit: Practical Techniques for Building Dimensional Data Warehouses*. Wiley, New York, 1st edition, 1996.
- [2] Ralph Kimball. Keep to the grain in dimensional modeling, July 2007. Accessed: 2025-10-24.