

Entrega Final

- APAAD -

Marcelo Ferreiro Sánchez
Pablo Chantada Saborido
Gillermo García Engelmo
Pepe Romero Conde

11 de noviembre de 2025

Índice

1. Introducción	2
2. Diseño del modelo lógico e implementación del DW en Oracle	2
2.1. Rediseño do modelo da práctica anterior	2
2.2. Toma de decisións	2
2.3. Creación das Táboas	4
3. Diseño e implementación del ETL	7
4. Explotación del DW	8
Consulta 1	8
Consulta 2	8
Consulta 3	8

1. Introducción

blablabla

2. Diseño del modelo lógico e implementación del DW en Oracle

- Proponer el diagrama del modelo lógico para el diseño realizado (normalmente será un modelo sencillo, en estrella o en copo de nieve), incluyendo una breve explicación de las decisiones tomadas y crear las tablas resultantes en Oracle.
- Crear las tablas necesarias en Oracle.

2.1. Rediseño do modelo da práctica anterior

Despois da corrección da entrega anterior modificamos o DFM do seguinte xeito:


- Baixamos as dimensións de **Hospedador** e **Lugar** ó nivel de **Hospedaxe** para evitar o modelo *Copo de neve*, o cal atopamos vantaxoso por gañar simpleza do modelo e velocidade das consultas (ver [1]).
- Actualizamos o DFM cos atributos da dimensión **Eventos** especificados no informe.
- Cambiamos as SCD a tipo 2 para conservar os datos do pasado e poder analízalos (dimensións **Hospedador** e **Valorador**).
- Cambios sobre o resto de atributos para busca coherencia co informe anterior.

Estos cambios pódense ver reflectidos na Figura 1. Na seguinte subsección veremos como implementar estes cambios.


2.2. Toma de decisións

Con todo resulta un modelo en estrela. Onde:

- A dimensión **Tempo** está denormalizada, para que en vez de estar representada de forma xerárquica, sea tipo Estrela. Ademais, como proposto nas teóricas usamos o atributo **data** como chave primaria (identifica o que ten que identificar).
- Á dimensión **Lugar** tivemos que crearlle unha chave primaria *surrogada* pois pode haber, por exemplo, máis dun barrio *chínés*. Con todo, si forzamos a non duplicidade das ternas (**barrio**, **cidade**, **pais**) con **UNIQUE KEY**.
- A dimensión **Hospedaxe** ten dos atributos multievaluados (**Comodidades** e **Accesibilidade**, que describen prestacións do aloxamento e formas de chegar a él, respectivamente) e modelárasen con Táboas Ponte.
- A dimensión **Eventos** inclúe un índice (**INDEX**) para que as consultas do tipo:



(a) DFM Orixinal



(b) DFM Modificado

Figura 1: Diagrama do Modelo de Feitos Dimensional (*DFM*) antes e despois da corrección

```
SELECT evento_id
FROM dim_eventos
WHERE evento_data = '2024-11-10'
AND cidade_nome = 'Madrid';
```

sexan veloces, e xustamente son ese tipo de consultas ás que nos interesan (os eventos ocorren nun momento nunha cidade) (ver [2]).

- Os atributos **comodidade** e **accesibilidade** ó seren multievaluados teñen que ser modelados cunha táboa ponte. Por tanto merecen a súa dimensión propia (ademáis da ponte).
- A dimensión **Chuvia** é dexenerada pois a única métrica que aporta son os mm de precipitación. Polo tanto ben a podemos incluír na táboa de feitos.

2.3. Creación das Táboas

A continuación mostrase as instrucións SQL para crealas táboas. Agrupadas segundo o tipo.

Táboas de dimensión

```
CREATE TABLE dim_tempo (
data DATE NOT NULL PRIMARY KEY,
dia INT NOT NULL,
mes INT NOT NULL,
ano INT NOT NULL,
estacion VARCHAR(10) NOT NULL,
tempada_alta BOOLEAN NOT NULL);

CREATE TABLE dim_lugar (
lugar_id INT PRIMARY KEY AUTO_INCREMENT,
barrio VARCHAR(100) NOT NULL,
cidade VARCHAR(100) NOT NULL,
pais VARCHAR(100) NOT NULL,
UNIQUE KEY uk_lugar (barrio, cidade, pais));

CREATE TABLE dim_hospedaxe (
hospedaxe_id INT PRIMARY KEY, -- Xa a tiñamos na OLTP
precio_noite DECIMAL(10,2) NOT NULL,
tipo VARCHAR(50) NOT NULL);

CREATE TABLE dim_comodidades (
comodidade_id INT PRIMARY KEY AUTO_INCREMENT,
comodidade_nome VARCHAR(100) NOT NULL UNIQUE);

CREATE TABLE dim_accesibilidade (
accesibilidade_id INT PRIMARY KEY AUTO_INCREMENT,
accesibilidade_nome VARCHAR(100) NOT NULL UNIQUE);
```

```
CREATE TABLE dim_eventos (
evento_id INT PRIMARY KEY AUTO_INCREMENT,
evento_nome VARCHAR(200) NOT NULL,
evento_tipo VARCHAR(50) NOT NULL,
impacto VARCHAR(20) NOT NULL,
cidade_nome VARCHAR(100) NOT NULL,
evento_data DATE NOT NULL,
INDEX idx_evento_data_cidade (evento_data, cidade_nome));
```

Táboas de dimensión que cambian lentamente, implementadas con SCD tipo 2

```
CREATE TABLE dim_valorador (
valorador_chave INT PRIMARY KEY AUTO_INCREMENT, -- Chave
surrogada, unha para cada versión
valorador_id INT NOT NULL, -- ID do OLTP, non muda no tempo e
identifica o individuo
idade INT NOT NULL,
sexo VARCHAR(10), -- Opcional
data_nacemento DATE NOT NULL,
actual BOOLEAN NOT NULL DEFAULT TRUE,
INDEX idx_valorador_id (valorador_id),
INDEX idx_actual (actual)
);
```

```
CREATE TABLE dim_hospedador (
hospedador_chave INT PRIMARY KEY AUTO_INCREMENT, -- Chave
surrogada, unha para cada versión
hospedador_id INT NOT NULL, -- ID do OLTP
tempo_resposta VARCHAR(50) NOT NULL,
score_medio DECIMAL(3,2),
numero_hospedaxes INT NOT NULL,
é_superhost BOOL NOT NULL,
actual BOOLEAN NOT NULL DEFAULT TRUE,
INDEX idx_hospedador_id (hospedador_id),
INDEX idx_actual (actual)
);
```

Táboas ponte

```
CREATE TABLE ponte_hospedaxe_comodidade (
hospedaxe_id INT NOT NULL,
comodidade_id INT NOT NULL,
PRIMARY KEY (hospedaxe_id, comodidade_id),
```

```

FOREIGN KEY (hospedaxe_id) REFERENCES dim_hospedaxe(hospedaxe_id),
FOREIGN KEY (comodidade_id) REFERENCES dim_comodidade(comodidade_id)
);

CREATE TABLE ponte_hospedaxe_accesibilidade (
hospedaxe_id INT NOT NULL,
accesibilidade_id INT NOT NULL,
PRIMARY KEY (hospedaxe_id, accesibilidade_id),
FOREIGN KEY (hospedaxe_id) REFERENCES dim_hospedaxe(hospedaxe_id),
FOREIGN KEY (accesibilidade_id) REFERENCES
dim_accesibilidade(accesibilidade_id)
);

CREATE TABLE ponte_valoracion_eventos (
valoracion_id INT NOT NULL,
evento_id INT NOT NULL,
PRIMARY KEY (valoracion_id, evento_id),
FOREIGN KEY (valoracion_id) REFERENCES feito_valoracion(valoracion_id),
FOREIGN KEY (evento_id) REFERENCES dim_eventos(evento_id)
);

```

E finalmente...

Táboa de feitos

```

CREATE TABLE feito_valoracion (
valoracion_id INT PRIMARY KEY, -- Do OLTP
hospedaxe_id INT NOT NULL,
lugar_id INT NOT NULL,
data INT NOT NULL,
valorador_chave INT NOT NULL, -- Chave surrogada (SCD Tipo 2)
hospedador_chave INT NOT NULL, -- Chave surrogada (SCD Tipo 2)
score DECIMAL(3,2) NOT NULL,
chuvia_mm DECIMAL(5,2), -- Dimensión dexenerada

-- Chaves Foraneas
FOREIGN KEY (hospedaxe_id) REFERENCES dim_hospedaxe(hospedaxe_id),
FOREIGN KEY (lugar_id) REFERENCES dim_lugar(lugar_id),
FOREIGN KEY (data) REFERENCES dim_tempo(data),
FOREIGN KEY (valorador_chave) REFERENCES
dim_valorador(valorador_chave),
FOREIGN KEY (hospedador_chave) REFERENCES
dim_hospedador(hospedador_chave),
);

```

3. Diseño e implementación del ETL

- Diseñar e implementar el proceso ETL (Extract, Transform, Load) completo en Apache Hop, que permita extraer, depurar/limpiar, transformar y cargar los datos reales de Airbnb en el Data Warehouse creado en la tarea 2. El proceso deberá automatizar la carga desde los ficheros fuente hasta las tablas destino en Oracle, garantizando la calidad, consistencia y trazabilidad de los datos.
- Deberán especificarse los datasets de origen utilizados y documentar las principales transformaciones realizadas (limpieza, conversión de tipos, homogeneización de categorías, generación de claves sustitutas, etc.). Además, es necesario describir cómo se tratan valores nulos o inconsistentes, claves foráneas faltantes, formatos de fecha y moneda, posibles duplicados...
- El fichero principal de ejecución debe llamarse: `etl_airbnb_main.hpl` y debe ser ejecutable en Hop sin necesidad de editar las rutas internas. El entregable final debe incluir una carpeta datasets (o enlace a los ficheros fuente utilizados).
- El proyecto de Hop debe incluir al menos: Un job principal (.hpl) que coordine la ejecución completa del proceso ETL con varias transformaciones específicas para cada tabla. El pipeline debe ser ejecutable de forma completa desde un único job principal.
- Todas las rutas de ficheros y conexiones deben configurarse de manera relativa (no absolutas) para facilitar su ejecución en otro entorno. La conexión a Oracle debe configurarse mediante variables de entorno de Hop (`$ORACLE_HOST`, `$ORACLE_USER`, etc.), documentadas en el informe.
- Todas las transformaciones deben estar claramente nombradas y documentadas dentro del proyecto Hop. También deben utilizarse Hop variables para parametrizar rutas, nombres de archivos y credenciales, facilitando la reutilización.
- No es requisito mínimo, pero se valorará positivamente la inclusión de al menos una de las siguientes funcionalidades avanzadas: Gestión de dimensiones lentamente cambiantes (SCD tipo 1 o 2), control de carga incremental (detección de nuevos registros o cambios) o mecanismo de logging o control de errores mediante variables o salidas de Hop.
- *Conjunto de datos utilizados:*
- *Tratamiento de nulos/inconsistentes:*
- *Claves foráneas*
- ...

4. Explotación del DW

- Se deben plantear y resolver tres consultas analíticas relevantes sobre el DW implementado. Para cada consulta, debe incluirse una breve descripción de la consulta (qué hace, y por qué es relevante o para qué podría aplicarse), y la sentencia SQL que resuelve dicha consulta sobre el esquema seleccionado. Las consultas deben de ser realistas y diferentes (utilizando diferentes tipos de consultas analíticas).
- Se debe crear un informe en Power BI que muestre visualizaciones interactivas de los datos, incluyendo alguna métrica DAX.

Consulta 1: Influe o número de hospedaxes dun hospedador sobre o seu score medio? Canto?

Consulta 1

blablabla

Consulta 2: Cales son os barrios con peores valoracións? Ordenados descendentemente pola valoración media da cidade.

Consulta 2

blablabla

Consulta 3: Entre as comodidades e accesibilidades que pode ter un hospedaxe, cal beneficia máis á valoración ca súa presenza e cal perxudica máis ca súa ausencia?

Consulta 3

blablabla

Referencias

- [1] R. Kimball, “Snowflaked dimensions,” 2007, disponible en: <https://www.kimballgroup.com/data-warehouse-business-intelligence-resources/kimball-techniques/dimensional-modeling-techniques/snowflake-dimension/>.
Accedido: 2025-11-10.
- [2] IBM, “Indexes for data warehouse applications,” 2025, disponible en: <https://www.ibm.com/docs/en/informix-servers/14.10.0?topic=indexes-data-warehouse-applications>.
Accedido: 2025-11-10.