

Práctica 2 – Almacenamiento NoSQL y Preprocesado Avanzado sobre MongoDB (2 puntos)

Enunciado

Cada grupo deberá trabajar con el mismo conjunto de datos utilizado en la Práctica 1 para realizar las siguientes tareas:

Fuente de datos base: <https://insideairbnb.com/get-the-data/>

Tarea 1 (0,8 puntos): Preprocesado en Python.

1. Análisis exploratorio inicial. Mostrar forma y tamaño del dataset, identificar tipos de datos, identificar valores nulos y detectar posibles outliers.
2. Tratamiento de valores faltantes. Aplicar al menos dos estrategias diferentes, justificadas según el tipo de variable: eliminar registros con demasiados nulos, rellenar variables numéricas (media, mediana, etc.), rellenar categóricos (utilizando la moda o una categoría especial), sustituir mediante reglas específicas del dominio.
3. Transformaciones adicionales. Según proceda en el dominio, deben aplicarse al menos dos transformaciones tales como:
 - a. Normalización o estandarización de variables numéricas.
 - b. Codificación simple de valores categóricos.
 - c. Limpieza de texto simple (trim, lowercase, ...).
 - d. Agrupaciones o reducción de categorías (por ejemplo, High, Medium, Low).
4. Balanceo de datos. Si el dominio lo requiere deben aplicarse técnicas de undersampling, oversampling, filtrado de ruido, etc. (Opcional, solo si es pertinente en caso de hacer tarea 4)

Tarea 2 (0,4 puntos): Modelado y Carga en MongoDB

1. Deberá crearse una base de datos específica para el dominio en una instalación propia de MongoDB, en la que se importarán los datos usando una de las tres formas:
 - a. *Pymongo* para importación directa desde Python.
 - b. Exportación en formato JSON y carga mediante MongoDB Compass.
 - c. Exportación en formato JSON e importación mediante *mongoimport* desde terminal.
2. Explicar detalladamente la estructura de los documentos (anidar objetos, arrays, decisiones de normalización o desnormalización). Justificar el modelo elegido y posibles alternativas.

Tarea 3 (0,8 puntos): Consultas en MongoDB

Cada grupo deberá implementar 4 consultas que respondan a preguntas analíticas relevantes dentro de su dominio. Se valorará positivamente el uso del pipeline de agregación.

Algunos ejemplos de categorías válidas serían: cálculo de estadísticas numéricas, agrupaciones por barrio/tipo de habitación/host/país, ranking (top de precios/valoraciones), detección de anomalías o valores extremos, evolución temporal.

Cada consulta debe incluir:

- Enunciado claro de la pregunta analítica que quiere responder.
- Consulta completa o pipeline en sintaxis MongoDB.
- Resultados resumidos o capturas de la salida, acompañados de una breve explicación de la salida.

Tarea 4 (+0,4 puntos): Modelo de aprendizaje (opcional)

De forma opcional y rápida, entrenar un modelo de aprendizaje automático utilizando los datos almacenados en MongoDB (por ejemplo, regresión, clasificación, ...). Debe explicarse brevemente el objetivo del modelo, las variables utilizadas y los resultados principales.

Comentarios:

- El enunciado es intencionadamente abierto, a fin de permitir múltiples interpretaciones. Se valorará fundamentalmente la consistencia entre el dominio, las suposiciones realizadas, el preprocesado realizado, el modelo de datos diseñado y las consultas analíticas propuestas.

Grupos

La práctica se realizará en grupos, utilizando la misma distribución de grupos que en la Práctica 1.

Fechas de entrega y defensa

La entrega se realizará a través del campus virtual.

Entrega: 12 de diciembre de 2025, 23:59h

Defensa: durante último día de clase de prácticas de la asignatura, es decir, 16/18 de diciembre de 2025. La defensa será presencial, y permitirá comprobar que los estudiantes han adquirido correctamente los fundamentos del diseño de bases de datos NoSQL y uso de MongoDB.

Entregables

- Código Python en un único notebook o script que incluya análisis exploratorio, preprocesamiento y exportación de los datos para su carga en MongoDB.
 - (Opcional) Consultas a MongoDB con pymongo
 - (Opcional) Modelo generado en la tarea 4.
- Datasets cargados en MongoDB en formato JSON.
- Documento de memoria (máx. 10 páginas) que incluya el dominio seleccionado (recordatorio breve), preprocesado realizado y justificación, modelo elegido para la base de datos en MongoDB, justificación de anidamiento o no, explicación de cada consulta (pregunta analítica, consulta/pipeline completo y resultado interpretado) y conclusiones analíticas obtenidas.
- Explicación del modelo generado en la tarea 4 (opcionalmente).