

ENTREGA 3: ADE & MONGODB

Marcelo Ferreiro Sánchez, Pablo Chantada Saborido
Gillermo García Engelman & Pepe Romero Conde

6 de diciembre de 2025

Índice

1. Introducción	2
2. Modelo de Datos	2
3. Preprocesado de datos	3
3.1. Análisis exploratorio del dataset	4
3.2. Tratamiento de nulos	4
3.2.1. Nulos numéricos	4
3.2.2. Otros nulos	5
3.3. Otras operaciones de procesado	5
4. Definición e implementación da Base de Datos	5
5. Explotación da Base de Datos	6
Consulta 1	6
Consulta 2	7
Consulta 3	7
Consulta 4	8
Consulta 5	8
Consulta 6	9
Consulta 7	9
6. Relleno de nulos usando Aprendizaxe Automático	11

1. Introducción

Como nas prácticas anteriores, traballamos sobre o conxunto de datos de AirBnB. Neste caso truncamos o punto de vista ou a aplicación. Se ben anteriormente o foco era na explotación analítica do feito **valoración** agora centrámonos nos **hospedaxes**. O diseño da Base de datos terá lugar na sección 4, e será realizado sobre os datos expostos en 2.

2. Modelo de Datos

Nesta ocasión non nos limitamos a usar os `.csvs` de unha cidade, con motivo de facer máis diversas as estadísticas e os resultados en xeral. Dende un principio observamos que o porcentaxe de nulos para a mesma columna non era ó meso ó longo das cidades, por eso con varias cidades esperamos unha representación máis fiel da realidade (e.g a cidade de Girona ten 100% de nulos para a columna `neighbourhood_group_cleansed` mentras que Lisboa ten un 0%). As primeiras manipulacións que tivemos que facerlle ós datos foi a de eliminar as columnas que non nos interesasen, engadir a columna de “cidade” e apilar todo nun `csv`. Fixemos ese traballo ca librería Pandas [1] de Python [2], xa que os campos de texto libre, como `description`, contiñan caracteres de salto de carro `^M` que dificultaban a tarefa a *oneliners* en AWK [3] (ver o programa adxunto `src/merge_csvs.py` e a Figura 1).

As columnas elixidas pódense ver na Figura 2. A elección foi un compromiso entre expresividade e tamaño, pensamos que cas columnas elixidas podemos facer bos análisis e consultas sen ten que cargar con todo o peso dos `.csvs` orixinais. Ademáis, o teren tipos de datos distintos e mesmo unha estrutura xerárquica implícita, supoñen unha interesante materia prima. A estrutura implícita a modelamos como: unha única colección de hospedaxes na que cada documento ten embebidos outros dous (o hospedador e máis o *Score*) e un arranxo, as prestacións.




Figura 1: A primeira transformación e xuntar os datos de distintas cidades e quitar as columnas que non nos interesen. Aproveitamos a ocasión para facer unha imputación sinxela, *vaninilla* dos datos



Figura 2: Diagrama do Modelo de Datos

3. Preprocesado de datos

- Análisis exploratorio inicial. Mostrar forma y tamaño del dataset, identificar tipos de datos, identificar valores nulos y detectar posibles outliers.
- Tratamiento de valores faltantes. Aplicar al menos dos estrategias diferentes, justificadas según el tipo de variable: eliminar registros con demasiados nulos, rellenar variables numéricas (media, mediana, etc.), rellenar categóricos (utilizando la moda o una categoría especial), sustituir mediante reglas específicas del dominio.
- Transformaciones adicionales. Según proceda en el dominio, deben aplicarse al menos dos transformaciones tales como:

Normalización o estandarización de variables numéricas.

Codificación simple de valores categóricos.

Limpieza de texto simple (trim, lowercase, ...).

Agrupaciones o reducción de categorías (por ejemplo, High, Medium, Low).

- Balanceo de datos. Si el dominio lo requiere deben aplicarse técnicas de undersampling, oversampling, filtrado de ruido, etc. (Opcional, solo si es pertinente en caso de hacer tarea 4)

3.1. Análisis exploratorio del dataset

3.2. Tratamiento de nulos

Como logo temos que volcar os datos a MongoDB (licencia en [4]), o noso programa xa limpia os datos cunha imputación sinxela pero apropiada para o tipo de datos (o exisido pola práctica), non obstante podemos desactivala e observar os nulos do arquivo mergeado, o porcentaxe está dispoñibel na Figura 2. Ademáis do porcentaxe é interesante o tipo de dato e o rol que desempeña esa columna.

3.2.1. Nulos núéricos

Dende logo o tipo de dato condiciona as opcións de imputación. Ademáis pódese dicir que estos nulos divídense en tres grupos: os relacionados co inmobiliario (baños, habitacións e camas), os valores de *Score* e o número de hospedaxes. Unha primeira idea de encher os nulos dun grupo con valores do mesmo (e.g. imputar o *score* de comunicación co resto de *scores*) desmantelouse á vista da Figura 3



Figura 3: Correlación entre os nulos. Pódese apreciar claramente que os *scores* son nulos á vez, igual que cos membros do inmobiliario.

```
(.venv) 🌱🌱🌱🌱 entrega_03 (main) » python scripts/knn_vs_median.py
bathrooms: Median MSE=1.3115, KNN MSE=0.6238
beds: Median MSE=5.4196, KNN MSE=2.3719
host_total_listings_count: Median MSE=283499.0809, KNN MSE=191732.6506
bedrooms: Median MSE=1.9067, KNN MSE=0.9160
```

Figura 4: Comparación dos métodos de imputación KNN ($k=3$) e mediana sobre a métrica $\mathcal{L}_2$. Os resultados repórtanse con KFold de $k=2$.

3.2.2. Outros nulos

3.3. Outras operaciones de procesado

4. Definición e implementación da Base de Datos

- Deberá crearse una base de datos específica para el dominio en una instalación propia de MongoDB, en la que se importarán los datos usando una das tres formas:

Pymongo para importación directa desde Python.

Exportación en formato JSON y carga mediante MongoDB Compass.

Exportación en formato JSON e importación mediante mongoimport desde terminal.

- Explicar detalladamente la estructura de los documentos (anidar objetos, arrays, decisiones de normalización o desnormalización). Xustificar el modelo elegido y posibles alternativas.

Unha vez que temos o `csv` con as columnas que queremos (e solo esas) e os valores limpos, é un bo momento de cargar os datos en MongoDB (licencia en [4])

5. Explotación da Base de Datos

Cada grupo deberá implementar 4 consultas que respondan a preguntas analíticas relevantes dentro de su dominio. Se valorará positivamente el uso del pipeline de agregación. Algunos ejemplos de categorías válidas serían: cálculo de estadísticas numéricas, agrupaciones por barrio/tipo de habitación/host/país, ranking (top de precios/valoraciones), detección de anomalías o valores extremos, evolución temporal. Cada consulta debe incluir:

- Enunciado claro da pregunta analítica que quiere responder.
- Consulta completa o pipeline en sintaxis MongoDB.
- Resultados resumidos o capturas da saída, acompañados de una breve explicación da saída.

Agora que hemos definido e implementado a nosa Base de Datos,

Consulta 1: Obter un índice de centralidade (dentro da cidade) para cada hospedaxe

Xustificación: como verase na sección 6, imos usar este valor para facer prediccións sobre o precio de cada hospedaxe. Ademáis parecíanos un bo uso das funcións nativas de MongoDB.

Para levar acabo esta consulta precisamos calcular os centroides de cada cidade e logo, para cada hospedaxe calcularemos a distancia ó centroide. O seguinte código crea ditos centroides, agragando os hospedaxes por cidade e facendo a media das súas coordenadas.

```
1 const centroides = db.listings.aggregate([
2   {
3     $group: {
4       _id: "$city",
5       avg_lat: { $avg: "$latitude" },
6       avg_lon: { $avg: "$longitude" }
7     }
8   }
9 ]).toArray();
```

Agora que temos eso só nos queda facer un `updateMany` no que por cada centroide, collemos os hospedaxes desa cidade e calculamos a distancia euclídea do centroide ó hospedaxe. Malia seren moitas liñas, as liñas 8-13 correspóndense co cálculo.

```

1 centroids.forEach(c => {
2   db.listings.updateMany(
3     { city: c._id },      // filtro
4     [
5       {
6         $set: {
7           centrality: {
8             $sqrt: {
9               $add: [
10                { $pow: [{ $subtract: ["$latitude", c.avg_lat] }, 2]
11                },
12                { $pow: [{ $subtract: ["$longitude", c.avg_lon] }, 2]
13                }
14              ]
15            }
16          }
17        }
18      ]
19    );
20  });

```

Resultados: Tal cual o fixemos cambia a base de datos, non devolve. Para ver o efecto podemos facer unha mini-consulta de comprobación como `db.listings.findOne()` e ver que xa figura o novo atributo.

Consulta 2: Cales son os barrios con hospedadores máis novos? Para cada cidade

Xustificación:

Resultados:

```

1 SELECT

```

Consulta 3: Influe foto de perfil no prezo medio?

Xustificación: de ser certo, AirBnB debería exisir ós seus hospedadores que se poñan foto, ou mesmo saldría deles. Tamén é interesante dende o punto de vista sociolóxico.

Esta consulta é sinxela, só hai que agrupar por valor de `host.has_profile_pic`, agregando o prezo

```

1 db.listings.aggregate([
2   {
3     $group: {
4       _id: "$host.has_profile_pic",
5       avg_price: { $avg: "$price" },
6       min_price: { $min: "$price" },
7       max_price: { $max: "$price" },
8       std_dev_price: { $stdDevSamp: "$price" },
9       count: { $sum: 1 }
10    }
11  },

```

```

12 {
13   $project: {
14     has_profile_pic: "$_id",
15     avg_price: { $round: ["$avg_price", 2] },
16     min_price: 1,
17     max_price: 1,
18     std_dev_price: 1,
19     count: 1,
20     _id: 0
21   }
22 },
23 { $sort: { has_profile_pic: 1 } }
24 ])

```

Resultados: como pode verse os resultados obtidos (ver abaixo) son algo significativos, posto que aínda que as medias son distintas as desviacións estandar solápanse. En calquera caso, análise de distribucións é algo que debería facerse en R [5], Julia [6] ou Python pero non en MongoDB.

```

1 {
2   min_price: 8,
3   max_price: 18000,
4   std_dev_price: 407.5147249606762,
5   count: 4682,
6   has_profile_pic: false,
7   avg_price: 161.12
8 },
9 {
10  min_price: 8,
11  max_price: 92150,
12  std_dev_price: 1500.7666758984817,
13  count: 154072,
14  has_profile_pic: true,
15  avg_price: 366.86
16 }

```

Consulta 4: Cales son os barrios con hospedaxes máis grandes (máis habitacións)?

Xustificación:

Resultados:

```

1 SELECT

```

Consulta 5: Que *score* é o que máis fluctua?

Xustificación:

Resultados:

```

1 SELECT

```


Consulta 6: Cales son os hospedaxes con hospedadores fóra desa cidade?

Xustificación:

Resultados:

```
1 SELECT
```

Consulta 7: Cales son os hospedaxes que estan a facer un bo último mes?

Xustificación: esta consula é de carácter moi xeral e o interese pode vir de moitos lados, os hospedadores poden querer estudar que fan eses hospedaxes tan bos; tamén AirBnB pódese ver beneficiado se é capaz de caracterizar tendencias, ou premiar ós mellores hospedaxes.

```
1 db.listings.aggregate([
2   {
3     $match: {
4       number_of_reviews_130d: { $gt: 0 },
5       reviews_per_month: { $gt: 0 }
6     }
7   },
8   {
9     $project: {
10       _id: 1,
11       description: 1,
12       city: 1,
13       neighbourhood_group_cleansed: 1,
14       price: 1,
15       "score.rating": 1,
16       number_of_reviews_130d: 1,
17       reviews_per_month: 1,
18       performance_score: {
19         $add: [
20           { $multiply: ["$number_of_reviews_130d", 2] },
21           { $multiply: ["$reviews_per_month", 1.5] },
22           { $multiply: ["$score.rating", 10] }
23         ]
24       },
25       recent_popularity: {
26         $multiply: ["$number_of_reviews_130d", 10]
27       }
28     },
29   },
30   {
31     $match: {
32       performance_score: { $gt: 40 }
33     }
34   },
35   {
36     $sort: {
37       performance_score: -1,
38       recent_popularity: -1
39     }
40   }
41 ])
```

```

39     }
40 },
41 {
42     $project: {
43         _id: 1,
44         description: 1,
45         city: 1,
46         neighbourhood: "$neighbourhood_group_cleansed",
47         price: 1,
48         rating: "$score.rating",
49         reviews_last_30d: "$number_of_reviews_l30d",
50         reviews_per_month: 1,
51         performance_score: { $round: ["$performance_score", 2] },
52         status: {
53             $switch: {
54                 branches: [
55                     { case: { $gte: ["$performance_score", 70] }, then: "
56                         Excellent" },
57                     { case: { $gte: ["$performance_score", 50] }, then: "Good"
58                         },
59                     { case: { $gte: ["$performance_score", 40] }, then: "
60                         Average" }
61                 ],
62                 default: "Below Average"
63             }
64         }
65     },
66     { $limit: 15 }
67 ]})

```

Resultados:

```

1  {
2    _id: ObjectId('693348dc7269f26612df5898'),
3    description: 'Ideal room to share stories and experiences with
4        capacity for up to 8 people. It has 4 bunk beds. Includes a
5        private bathroom, two sinks, air conditioning, free wifi, bed
6        linen and an individual space to store your luggage. All beds
7        have USB connection to charge your devices. Unite has rooms
8        with bathroom adapted for the disabled according to
9        availability.<br/>The establishment is cashless.<br/>Unite is
10       cashless',
11    price: 33,
12    reviews_per_month: 94.77,
13    city: 'barcelona',
14    neighbourhood: 'San Marti',
15    performance_score: 428.45,
16    status: 'Excellent'
17 },
18 {
19     _id: ObjectId('693348dc7269f26612e06f70'),
20     description: 'This bright and cosy double room comes with a double
21         bed, air-conditioning, wall-mounted TV and free Wi-Fi. All

```

```

rooms_in_easyHotel_Madrid_Alcala_offer_comfort_and_cleanliness_at_a_budget_price_to_allow_you_to_spend_time_exploring_our_great_city_outside_of_your_hotel_room.Room_size_12_sqm.',
14 price: 128,
15 reviews_per_month: 82.94,
16 city: 'madrid',
17 neighbourhood: 'San_Blas-Canillejas',
18 rating: 4.82,
19 reviews_last_30d: 116,
20 performance_score: 404.61,
21 status: 'Excellent'
22 },
23 {
24   _id: ObjectId('693348dc7269f26612df3f4f'),
25   description: 'Flawless_time_with_the_whole_family_in_this_stylish_accommodation!<br/><br/>The_apartments_have_three_bedrooms,a_bathroom,and_a_toilet.The_master_bedroom_has_a_double_bed,the_second_bedroom_has_two_single_beds_and_the_third_bedroom_has_a_single_bed.<br/><br/>Enjoy_the_freedom_and_privacy_of_having_your_own_apartment_in_the_city_center.',
26   price: 324,
27   reviews_per_month: 61.23,
28   city: 'barcelona',
29   neighbourhood: 'Eixample',
30   rating: 4.72,
31   reviews_last_30d: 100,
32   performance_score: 339.05,
33   status: 'Excellent'
34 },
35
36 ...

```

6. Recheo de nulos usando Aprendizaxe Automático

De forma opcional y rápida, entrenar un modelo de aprendizaje automático utilizando los datos almacenados en MongoDB (por ejemplo, regresión, clasificación, ...). Debe explicarse brevemente el objetivo del modelo, las variables utilizadas y los resultados principales.

Como a columna price nos .csvs orixinais tiña un 10% de nulos, decidimos entrenar un modelo de Aprendizaxe Automático para *regresar* los valores de precio. Ademáis, esta tarea parecíanos interesante de por sí.

Referencias

- [1] “pandas bsd 3-clause license,” <https://github.com/pandas-dev/pandas?tab=BSD-3-Clause-1-ov-file>, accessed: 2025-12-05.
- [2] Python Software Foundation, “Cpython license (psf license version 2),” <https://github.com/python/cpython?tab=License-1-ov-file>, accessed: 2025-12-05.
- [3] “Gnu general public license, version 3,” <https://www.gnu.org/licenses/gpl-3.0.html>, accessed: 2025-12-05.
- [4] “Mongodb server side public license (sspl),” <https://github.com/mongodb/mongo?tab=License-1-ov-file>, accessed: 2025-12-05.
- [5] “R license,” <https://www.r-project.org/COPYING>, accessed: 2025-12-05.
- [6] “Julia mit license,” <https://github.com/JuliaLang/julia?tab=MIT-1-ov-file>, accessed: 2025-12-05.