

ENTREGA 3: MONGODB

Marcelo Ferreiro Sánchez, Pablo Chantada Saborido
Guillermo García Engelman & Pepe Romero Conde

12 de diciembre de 2025

Índice

1. Introducción	2
2. Modelo de Datos	2
3. Preprocesado de datos	4
3.1. Análise exploratoria do conxunto de datos	4
3.2. Tratamento de nulos	7
3.2.1. Nulos numéricos	7
3.2.2. Outros nulos	8
3.3. Outras operacións de procesado	8
4. Definición e implementación da Base de Datos	9
5. Explotación da Base de Datos	11
5.1. Consultas non analíticas	11
5.1.1. Consulta: Cal é o hospedaxe que ten 40 habitacións?	11
5.1.2. Consulta: Existen hospedaxes con máis de 5 camas?	13
5.2. Consultas analíticas	13
5.2.1. Consulta: Obter un índice de centralidade (dentro da cidade) para cada hospedaxe	13
5.2.2. Consulta: Inflúe a foto de perfil no prezo medio?	14
5.2.3. Consulta: Cales son os barrios con hospedadores máis novos (para cada cidade)?	15
5.2.4. Consulta: Cales son os barrios con hospedaxes máis grandes (máis habi- tacións)?	18
5.2.5. Consulta: Cales son os hospedaxes con hospedadores fóra desa cidade? .	20
5.2.6. Consulta: Cales son os hospedaxes que están a facer un bo último mes? .	21
6. Recheo de nulos usando Aprendizaxe Automática	23
7. Conclusións	24

1. Introducción

Na práctica actual, mantemos o conxunto de datos de AirBnB, pero cambiamos o foco da explotación analítica. Se ben nas sesións anteriores nos centramos en feitos sinxelos como a táboa de **valoracións**, nesta práctica a nosa atención céntrase nos **hospedaxes**. Este cambio débese á nosa elección de empregar **MongoDB**, unha base de datos NoSQL orientada a documentos, o que nos permite un deseño de datos máis flexible e complexo. O obxectivo é aproveitar as súas características para demostrar a capacidade dos **documentos anidados** e **arrays** embebidos, como os detalles do **host** dentro do documento do **hospedaxe**. Deste xeito, eliminamos a necesidade de realizar custosas **unións (joins)** en tempo de consulta, mellorando o desempeño da recuperación e permitindo unha modelaxe máis natural dos datos (sempre e cando as nosas consultas non teñan como obxectivo devolver hospedadores, pois nese caso serían algo máis caras).

O deseño da base de datos terá lugar na sección 4, e será realizado sobre os datos expostos na sección 2.

2. Modelo de Datos

Nesta ocasión non nos limitamos a usar os **.csv** dunha cidade, co motivo de facer máis diversas as estatísticas e os resultados en xeral. Dende un principio observamos que a porcentaxe de nulos para a mesma columna non era o mesmo ao longo das cidades, por iso con varias cidades esperamos unha representación máis fiel da realidade (e.g. a cidade de Girona ten 100 % de nulos para a columna **neighbourhood_group_cleansed** mentres que Lisboa ten un 0 %). As primeiras manipulacións que tivemos que facerlles aos datos foi a de eliminar as columnas que non nos interesasen, engadir a columna de “cidade” e apilar todo nun **csv**. Fixemos ese traballo coa librería Pandas [1] de Python [2], xa que os campos de texto libre, como **description**, contiñan caracteres de salto de carro `~M` que dificultaban a tarefa a *oneliners* en AWK [3] (ver o programa adxunto **src/merge_csvs.py** e a Figura 1).

As columnas elixidas pódense ver na Figura 2. A elección foi un compromiso entre expresividade e tamaño; pensamos que coas columnas elixidas podemos facer boas análises e consultas sen ter que cargar con todo o peso dos **.csv** orixinais. Ademais, ao teren tipos de datos distintos e mesmo unha estrutura xerárquica implícita, supoñen unha interesante materia prima. A estrutura implícita modelámola como: unha única colección de hospedaxes na que cada documento ten embebidos outros dous (o hospedador e mais o *Score*) e un array, as prestacións.




Figura 1: A primeira transformación é xuntar os datos de distintas cidades e quitar as columnas que non nos interesen. Aproveitamos a ocasión para facer unha imputación sinxela, *vanilla*, dos datos.



Figura 2: Diagrama do Modelo de Datos

3. Preprocesado de datos

3.1. Análise exploratoria do conxunto de datos

Comenzamos a análise co obxecto de estudo da Consulta 1 e da sección 6, o prezo das vivendas. Vemos que en xeral a distribución $p(\$ = X)$ ten as colas moi longas (aínda que por exemplo $p(\$ = X | \text{cidade} = \text{Madrid})$ non tanto). Vemos que as dúas cidades con maiores abanicos son as insulares, que efectivamente hai unha correlación entre o que custa un hospedaxe e a xente que colle nel (ver Consulta 4) e que o logaritmo é unha mellor forma de representar o prezo.




Figura 3: Análise de prezos por cidade.

No gráfico de abaixo podemos ver o dispersos que están os hospedaxes nas cidades, o cal repercutirá no índice de centralidade (ver Consulta 1). Parécenos curioso que Mallorca estea tan pragada de turismo que se poida recoñecer a forma insular dende este gráfico.




Figura 4: Distribución xeográfica das 9 cidades.

Por último queriamos mostrar as distribucións máis dispersas, tanto que parece que están cheas de atípicos. Pero nós pensamos que non é o caso, que simplemente a realidade é dispersa, e AirBnB permite facer anuncios de propiedades de todo tipo, atendendo ás gráficas da figura 5, apreciamos como hai algunhas propiedades con máis de 40 habitacións e 20 baños. Forma de investigar máis a fondo se verdaderamente estamos ante a presenza dun *outlier* ou anuncio espurio pode ser facer unha consulta (mais detalle posteriormente na sección de explotación [5.1.1])




Figura 5: Visualización de atípicos.

3.2. Tratamento de nulos

Como logo temos que envorcar os datos a MongoDB (licenza en [4]), o noso programa xa limpa os datos cunha imputación sinxela pero apropiada para o tipo de datos (o esixido pola práctica); non obstante podemos desactivala e observar os nulos do arquivo unificado. A porcentaxe está dispoñible na Figura 2. Ademais da porcentaxe é interesante o tipo de dato e o rol que desempeña esa columna.

3.2.1. Nulos numéricos

Dende logo o tipo de dato condiciona as opcións de imputación. Ademais pódese dicir que estes nulos divídense en tres grupos: os relacionados co inmobiliario (baños, habitacións e camas), os valores das reseñas e tres atributos do hospedador. Unha primeira idea de encher os nulos dun grupo con valores do mesmo (e.g. imputar o *score* de comunicación co resto de *scores*) desmantelouse á vista da Figura 6; é dicir, non se poden encher os nulos dun grupo con valores dese grupo porque cando un é nulo os outros tamén o son (alta correlación). Ademais, por curiosidade, fixemos un experimento (ver `src/knn_vs_median.py` ou Táboa 1) para ver a diferenza de erro se usamos imputación simple (mediana) ou máis sofisticada (adestramento dun KNN non paramétrico) e observamos que o erro, malia ser a metade co método sofisticado, segue estando na mesma orde de magnitude e ademais encarece moito computacionalmente o proceso. Por todo o dito, e polo alcance da práctica, limitámonos a unha imputación sinxela por mediana.




Figura 6: Correlación entre os nulos. Pódese apreciar claramente que os *scores* son nulos á vez, igual que cos membros do inmobiliario.

Táboa 1: Comparación de MSE: Imputación por Mediana vs KNN

Variable	MSE Mediana	MSE KNN
bathrooms	0.5484	0.3359
beds	3.1542	2.2738
host_total_listings_count	30972.2424	27884.0846
bedrooms	1.0932	0.8283

3.2.2. Outros nulos

Como pode verse na función `fillna` do arquivo `src/merge_csvs.py`, tanto os Booleanos como os Strings impútanse mediante a moda. Se ben poderíanse levar a cabo operacións máis sofisticadas, polo alcance da práctica limitámonos a esta opción.

3.3. Outras operacións de procesado

Se ben o discutido ata o de agora foi máis ben dos valores en si, cabe destacar que para envorcar os datos a MongoDB foi necesaria unha disposición especial dos datos, en particular para o formato dos dous documentos embebidos e do array de prestacións. Estas operacións, en cambio, situámolos na fase de carga (*Load*) e por tanto lévanse a cabo no arquivo adxunto `csv2mongo.py`.

4. Definición e implementación da Base de Datos




Figura 7: Unha vez que temos todos os datos nun `.csv` sobre o cal podemos facer Análise Exploratoria, estamos listos para pasar os datos a MongoDB, segundo a definición do esquema dada na sección 2.

O modelo de datos da Figura 2 é o “esquema” que usaremos en MongoDB. Dado o noso plantexamento de centrarnos nos hospedaxes (os protagonistas dos `csv` máis grandes e argumentablemente da aplicación enteira de AirBnB) non houbo moitas decisións de deseño difíciles. O array de prestacións tiña que ser un array en MongoDB e os *scores* son un documento embebido principalmente por azucre sintáctico [5]; en cambio os hospedadores ben podían ter sido unha colección por si mesma. Tal cousa tería sentido se fixésemos consultas hospedador-céntricas, é dicir, se pensásemos nos hospedadores como entidades por si mesmas; non foi o noso caso pois pensamos que o hospedador vén subrogado ao hospedaxe e as consultas que iamos facer non precisaban a complexidade de varias coleccións.

Dito o anterior, a base de datos móntase co *script* adxunto `csv2mongo.py`. Este establece conexión cun cliente de Mongo local e carga os datos no formato especificado, de xeito que podemos facer:

```
1 (.venv) entrega_03 (main) > python src/mongo/csv2mongo.py
2 Inserted 158754 listings          airbnb.listings
3 (.venv) entrega_03 (main) > mongosh
4 Current Mongosh Log ID: 69347505a2994911f4cd9cc3
5 Connecting to:                  mongodb://127.0.0.1:27017/?directConnection=
   true&serverSelectionTimeoutMS=2000&appName=mongosh+2.5.10
6 Using MongoDB:                  8.2.2
7 Using Mongosh:                  2.5.10
8
9 For mongosh info see: https://www.mongodb.com/docs/mongosh-shell/
10
11 -----
12 The server generated these startup warnings when booting
13 2025-12-06T16:07:08.499+01:00: Access control          enabled for
   the database. Read      write access to data      configuration
   unrestricted
14 -----
15
16 test> use airbnb
17 switched to db airbnb
18 airbnb> db.listings.findOne()
19 {
```

```

_id: ObjectId('693474fcce4ae65c237470e5'),
neighbourhood_group_cleansed: 'Eixample',
latitude: 41.40556,
longitude: 2.17262,
property_type: 'Entire rental unit',
accommodates: 8,
bathrooms: 2,
bedrooms: 3,
beds: 6,
price: 210,
number_of_reviews: 51,
number_of_reviews_l30d: 0,
availability_eoy: 74,
instant_bookable: true,
reviews_per_month: 0.34,
city: 'barcelona',
host: {
  since: '2010-01-19',
  location: 'Barcelona, Spain',
  response_time: 'within an hour',
  response_rate: '96%',
  acceptance_rate: '91%',
  is_superhost: false,
  total_listings_count: 46,
  has_profile_pic: true,
  identity_verified: true
},
score: {
  rating: 4.34,
  accuracy: 4.4,
  cleanliness: 4.56,
  checkin: 4.64,
  communication: 4.62,
  location: 4.82,
  value: 4.32
},
amenities: [
  '"Pets allowed',
  '30 inch TV',
  'Coffee maker',
  'Elevator',
  'Host greets you',
  'Pack \u2019n play/Travel crib',
  'Heating',
  'Hangers',
  'AC - split type ductless system',
  'Iron',
  'Crib',
  'Dishes and silverware',
  'Private patio or balcony',
  'Kitchen',
  'Essentials',
  'Free washer \u2013 In unit',

```

```

73     'Wifi',
74     'Hot water',
75     'City skyline view',
76     'Shampoo',
77     'Hair dryer',
78     'Refrigerator"]',
79 ],
80 row_id: 0
81 }

```

Pódese ver que a operación é exitosa e a consulta da liña 18 é só un exemplo para demostrar o funcionamento. Ademais pódese ver que ao final do documento hai un atributo de fila, este vai ser útil na sección 6 pois imos ter que exportar o resultado da primeira consulta de MongoDB a csv de volta, e ter o identificador de fila vai nos valer para emparellar facilmente. Sen identificador de fila teríamos que exportar a base de datos enteira, pero con el, podemos devolver as columnas que creemos en MongoDB ordenadas por `row_id` e teremos a certeza de que vai cadrar ben.

5. Explotación da Base de Datos

Agora que definimos e implementamos a nosa base de datos, procedemos á súa explotación.

5.1. Consultas non analíticas

Comezamos con dúas consultas sinxelas de exploración e verificación de datos, que non requiren agregacións complexas nin cálculos estatísticos.

5.1.1. Consulta: Cal é o hospedaxe que ten 40 habitacións?

Xustificación: É un anómalo realmente?

```

1  airbnb> db.listings.find({bedrooms : {$gt : 40}}, {bedrooms : 1}).
    sort({ bedrooms: -1 })

```

```

1  [
2    { _id: ObjectId('693479deab134920609e549c'), bedrooms: 43 },
3    { _id: ObjectId('693846ba023c5ca99b6f26e6'), bedrooms: 43 },
4    { _id: ObjectId('693848aca2b4d841d69f4700'), bedrooms: 43 }
5  ]

```

```

1  airbnb> db.listings.find({_id : 693479deab134920609e549c})

```

Resultados: Vemos que é un hotel, polo que non poderíamos dicir que é un dato erróneo, e esperaríamos máis hoteis polo que quedarnos con él parece lóxico.

```

1  [
2    {
3      _id: ObjectId('693479deab134920609e549c'),
4      description: 'Cascais at your door',
5      neighbourhood_group_cleansed: 'Cascais',
6      latitude: 38.69952,
7      longitude: -9.42015,
8      property_type: 'Room in hotel',
9      accommodates: 3,

```

```

10     bathrooms: 1,
11     bedrooms: 43,
12     beds: 2,
13     price: 128,
14     number_of_reviews: 9,
15     number_of_reviews_l30d: 0,
16     availability_eoy: 80,
17     instant_bookable: true,
18     reviews_per_month: 0.14,
19     city: 'lisboa',
20     host: {
21         since: '2020-07-16',
22         location: 'Madrid, Spain',
23         response_time: 'within an hour',
24         response_rate: '100%',
25         acceptance_rate: '100%',
26         is_superhost: true,
27         total_listings_count: 7,
28         has_profile_pic: true,
29         identity_verified: true
30     },
31     score: {
32         rating: 4.67,
33         accuracy: 5,
34         cleanliness: 4.89,
35         checkin: 4.78,
36         communication: 4.78,
37         location: 5,
38         value: 4.44
39     },
40     amenities: [
41         '["Heating',
42         'Smoke alarm',
43         'Essentials',
44         'Private entrance',
45         'Carbon monoxide alarm',
46         'Breakfast',
47         'Self check-in',
48         'Air conditioning',
49         'HDTV',
50         'Shampoo',
51         'Exterior security cameras on property',
52         'Fire extinguisher',
53         'Iron',
54         'Building staff',
55         'Hangers',
56         'Hair dryer',
57         'Wifi"]'
58     ],
59     row_id: 52196,
60     centrality: 0.22156954910595233
61 }
62 ]

```

5.1.2. Consulta: Existen hospedaxes con máis de 5 camas?

Xustificación: A plataforma de AirBnB podería sinalar que un hospedaxe ten tantas camas como habitacións, o cal estaría ben, por exemplo, para viaxes de parella ou grupos. Pero primeiro, hai tales hospedaxes?

```
1 airbnb> db.listings.find(  
2 |   { beds: { $gt: 5 }, $expr: { $eq: ["$beds", "$bedrooms"] } },  
3 |   { price: 1, beds: 1 }  
4 | ).sort({ beds: -1 })
```

Resultados: Vemos que si, Hoteis.

```
1 [  
2   { _id: ObjectId('693479deab134920609efe31'), beds: 25, price: 72 },  
3   { _id: ObjectId('693848aca2b4d841d6a020f4'), beds: 25, price: 72 },  
4   { _id: ObjectId('693846ba023c5ca99b7000da'), beds: 25, price: 72 },  
5   { _id: ObjectId('693848ada2b4d841d6a0f3f7'), beds: 20, price: 29 },  
6   { _id: ObjectId('693848ada2b4d841d6a0f3f4'), beds: 20, price: 41 },  
7   { _id: ObjectId('693479deab134920609fdf9c'), beds: 20, price: 41 },  
8   { _id: ObjectId('693479deab134920609fdf9b'), beds: 20, price: 36 },  
9   { _id: ObjectId('693479deab134920609fdf98'), beds: 20, price: 36 },  
10  { _id: ObjectId('693479deab134920609fdf97'), beds: 20, price: 31 },  
11  { _id: ObjectId('693846ba023c5ca99b70d3d9'), beds: 20, price: 36 },  
12  { _id: ObjectId('693479deab134920609fdf96'), beds: 20, price: 28 },  
13  { _id: ObjectId('693479deab134920609fdf95'), beds: 20, price: 36 },  
14  { _id: ObjectId('693479deab134920609fdf94'), beds: 20, price: 37 },  
15  { _id: ObjectId('693846ba023c5ca99b70d3e6'), beds: 20, price: 41 },  
16  { _id: ObjectId('693846ba023c5ca99b70d3e5'), beds: 20, price: 36 },  
17  { _id: ObjectId('693848ada2b4d841d6a0f400'), beds: 20, price: 41 },  
18  { _id: ObjectId('693848ada2b4d841d6a0f3ff'), beds: 20, price: 36 },  
19  { _id: ObjectId('693846ba023c5ca99b70d3e2'), beds: 20, price: 36 },  
20  { _id: ObjectId('693846ba023c5ca99b70d3e1'), beds: 20, price: 31 },  
21  { _id: ObjectId('693479deab134920609fdf93'), beds: 20, price: 29 }  
22 ]
```

5.2. Consultas analíticas

As seguintes consultas empregan agregacións complexas, cálculos estatísticos e análise de patróns para extraer insights dos datos.

5.2.1. Consulta: Obter un índice de centralidade (dentro da cidade) para cada hospedaxe

Xustificación: como se verá na sección 6, imos usar este valor para facer prediccións sobre o prezo de cada hospedaxe. Ademais parecíanos un bo uso das funcións nativas de MongoDB.

Para levar a cabo esta consulta precisamos calcular os centroides de cada cidade e logo, para cada hospedaxe, calcularemos a distancia ao centroide. O seguinte código crea ditos centroides, agregando os hospedaxes por cidade e facendo a media das súas coordenadas.

```
1 const centroides = db.listings.aggregate([  
2   {  
3     $group: {  
4       _id: "$city",
```

```

5     avg_lat: { $avg: "$latitude" },
6     avg_lon: { $avg: "$longitude" }
7   }
8 }
9 ]).toArray();

```

Agora que temos iso só nos queda facer un `updateMany` no que por cada centroide, collemos os hospedaxes desa cidade e calculamos a distancia euclidiana do centroide ao hospedaxe. Malia seren moitas liñas, as liñas 8-13 correspóndense co cálculo.

```

1 centroids.forEach(c => {
2   db.listings.updateMany(
3     { city: c._id },      // filtro
4     [
5       {
6         $set: {
7           centrality: {
8             $sqrt: {
9               $add: [
10                { $pow: [{ $subtract: ["$latitude", c.avg_lat] }, 2]
11                },
12                { $pow: [{ $subtract: ["$longitude", c.avg_lon] }, 2]
13                }
14              ]
15            }
16          }
17        }
18      ]
19    );
20 });

```

Resultados: Tal cal o fixemos cambia a base de datos, non devolve nada. Para ver o efecto podemos facer unha miniconsulta de comprobación como `db.listings.findOne()` e ver que xa figura o novo atributo.

5.2.2. Consulta: Inflúe a foto de perfil no prezo medio?

Xustificación: de ser certo, Airbnb debería esixir aos seus hospedadores que poñan foto, ou mesmo saíría deles. Tamén é interesante dende o punto de vista sociolóxico.

Esta consulta é sinxela, só hai que agrupar por valor de `host.has_profile_pic`, agregando o prezo.

```

1 db.listings.aggregate([
2   {
3     $group: {
4       _id: "$host.has_profile_pic",
5       avg_price: { $avg: "$price" },
6       min_price: { $min: "$price" },
7       max_price: { $max: "$price" },
8       std_dev_price: { $stdDevSamp: "$price" },
9       count: { $sum: 1 }
10    }
11  },
12  {

```

```

13     $project: {
14         has_profile_pic: "$_id",
15         avg_price: { $round: ["$avg_price", 2] },
16         min_price: 1,
17         max_price: 1,
18         std_dev_price: 1,
19         count: 1,
20         _id: 0
21     }
22 },
23 { $sort: { has_profile_pic: 1 } }
24 ])

```

Resultados: como pode verse, os resultados obtidos (ver abaixo) son algo significativos, posto que aínda que as medias son distintas, as desviacións estándar solápanse. En calquera caso, a análise de distribucións é algo que debería facerse en R [6], Julia [7] ou Python pero non en MongoDB.

```

1 {
2     min_price: 8,
3     max_price: 18000,
4     std_dev_price: 407.5147249606762,
5         : 4682,
6     has_profile_pic: false,
7     avg_price: 161.12
8 },
9 {
10     min_price: 8,
11     max_price: 92150,
12     std_dev_price: 1500.7666758984817,
13         : 154072,
14     has_profile_pic: true,
15     avg_price: 366.86
16 }

```

5.2.3. Consulta: Cales son os barrios con hospedadores máis novos (para cada cidade)?

Xustificación: esta consulta é básica para a análise de tendencias e evolución do mercado inmobiliario.

```

1 db.listings.aggregate([
2     {
3         $project: {
4             city: 1,
5             neighbourhood_group_cleansed: 1,
6             host_since: "$host.since",
7             year: { $year: { $toDate: "$host.since" } }
8         }
9     },
10     {
11         $group: {
12             _id: {
13                 city: "$city",

```

```

14     neighbourhood: "$neighbourhood_group_cleansed"
15   },
16   avg_host_year: { $avg: "$year" },
17   count: { $sum: 1 }
18 }
19 },
20 {
21   $sort: { "_id.city": 1, "avg_host_year": -1 }
22 },
23 {
24   $group: {
25     _id: "$_id.city",
26     neighbourhoods: {
27       $push: {
28         neighbourhood: "$_id.neighbourhood",
29         avg_host_year: "$avg_host_year",
30         count: "$count"
31       }
32     }
33   }
34 },
35 {
36   $project: {
37     city: "$_id",
38     neighbourhoods: {
39       $slice: [
40         {
41           $sortBy: {
42             input: "$neighbourhoods",
43             sortBy: { avg_host_year: -1 }
44           }
45         },
46         5
47       ]
48     }
49   }
50 }
51 ]))

```

Resultados: se ben non procede mostrar os resultados completos, abaixo pódese ver as cidades con barrios máis novos. O certo é que a forma de mostrar esta consulta non só compara os barrios dentro dunha cidade senón tamén as cidades entre si.

```

1   ...
2
3   {
4     _id: 'euskadi',
5     city: 'euskadi',
6     neighbourhoods: [
7       {
8         neighbourhood: 'Vizcaya',
9         avg_host_year: 2019.032435404068,
10        : 3638
11      },

```



```

12     {
13         neighbourhood: 'Alava',
14         avg_host_year: 2017.819964349376,
15             : 561
16     },
17     {
18         neighbourhood: 'Guipuzcoa',
19         avg_host_year: 2017.6565040650407,
20             : 2952
21     }
22 ]
23 },
24 {
25     _id: 'madrid',
26     city: 'madrid',
27     neighbourhoods: [
28         {
29             neighbourhood: 'Vicalvaro',
30             avg_host_year: 2020.0117647058823,
31                 : 85
32         },
33         {
34             neighbourhood: 'Tetuan',
35             avg_host_year: 2019.724836212031,
36                 : 1679
37         },
38         {
39             neighbourhood: 'Villaverde',
40             avg_host_year: 2019.5731707317073,
41                 : 246
42         },
43         {
44             neighbourhood: 'Villa de Vallecas',
45             avg_host_year: 2019.4336283185842,
46                 : 113
47         },
48         {
49             neighbourhood: 'Barajas',
50             avg_host_year: 2019.3680981595091,
51                 : 163
52         }
53     ]
54 },
55 {
56     _id: 'valencia',
57     city: 'valencia',
58     neighbourhoods: [
59         {
60             neighbourhood: 'BENICALAP',
61             avg_host_year: 2020.3698630136987,
62                 : 146
63         },
64         {

```

```

65     neighbourhood: 'JESUS',
66     avg_host_year: 2020.0177304964539,
67         : 282
68 },
69 {
70     neighbourhood: 'RASCANYA',
71     avg_host_year: 2019.9685534591194,
72         : 159
73 },
74 {
75     neighbourhood: 'ALGIROS',
76     avg_host_year: 2019.9149560117303,
77         : 341
78 },
79 {
80     neighbourhood: 'PATRAIX',
81     avg_host_year: 2019.864406779661,
82         : 177
83 }
84 ]
85 }

```

5.2.4. Consulta: Cales son os barrios con hospedaxes máis grandes (máis habitacións)?

Xustificación: esta información é decisiva nunha análise de desigualdade entre territorios, ou mesmo pode ser de interese gobernamental, para o desenvolvemento de leis.

```

1 db.listings.aggregate([
2   {
3     $match: {
4       bedrooms: { $exists: true, $ne: null },
5       neighbourhood_group_cleansed: { $exists: true, $ne: null }
6     }
7   },
8   {
9     $group: {
10      _id: {
11        city: "$city",
12        neighbourhood: "$neighbourhood_group_cleansed"
13      },
14      avg_bedrooms: { $avg: "$bedrooms" },
15      max_bedrooms: { $max: "$bedrooms" },
16      total_properties: { $sum: 1 },
17      large_properties: {
18        $sum: { $cond: [{ $gte: ["$bedrooms", 3] }, 1, 0] }
19      }
20    }
21  },
22  {
23    $project: {
24      city: "$_id.city",
25      neighbourhood: "$_id.neighbourhood",

```

```

26     avg_bedrooms: { $round: ["$avg_bedrooms", 2] },
27     max_bedrooms: 1,
28     total_properties: 1,
29     large_properties_percentage: {
30         $round: [
31             { $multiply: [{ $divide: ["$large_properties", "
32                 $total_properties"] }, 100] },
33             2
34         ]
35     },
36 },
37 { $sort: { "avg_bedrooms": -1, "large_properties_percentage": -1 }
38     },
39 { $limit: 10 }
40 ])
```

Resultados: Móstrase abaixo os 3 mellores hospedadores deste mes (hospedadores con mellor *performance score*, composto dunha ponderación do número de reviews do último mes, as súas reviews por mes e o seu rating).

```

1  {
2      _id: { city: 'porto', neighbourhood: 'SAO JOAO DA MADEIRA' },
3      max_bedrooms: 20,
4      total_properties: 49,
5      city: 'porto',
6      neighbourhood: 'SAO JOAO DA MADEIRA',
7      avg_bedrooms: 7.76,
8      large_properties_percentage: 40.82
9  },
10 {
11     _id: { city: 'mallorca', neighbourhood: 'Lisboa' },
12     max_bedrooms: 20,
13     total_properties: 15034,
14     city: 'mallorca',
15     neighbourhood: 'Lisboa',
16     avg_bedrooms: 2.95,
17     large_properties_percentage: 62.63
18 },
19 {
20     _id: { city: 'lisboa', neighbourhood: 'Azambuja' },
21     max_bedrooms: 5,
22     total_properties: 18,
23     city: 'lisboa',
24     neighbourhood: 'Azambuja',
25     avg_bedrooms: 2.83,
26     large_properties_percentage: 50
27 },
28 {
29     _id: { city: 'menorca', neighbourhood: 'Lisboa' },
30     max_bedrooms: 12,
31     total_properties: 3679,
32     city: 'menorca',
33     neighbourhood: 'Lisboa',

```

```

34     avg_bedrooms: 2.66,
35     large_properties_percentage: 52.6
36 },
37
38     ...

```

5.2.5. Consulta: Cales son os hospedaxes con hospedadores fóra desa cidade?

Xustificación: Ter un hospedador que vive lonxe (noutra cidade) pode ser un inconveniente tanto para os inquilinos como para o propio AirBnB se é que estes están descontentos. Caracterizalos é importante.

```

1  db.listings.aggregate([
2    {
3      $project: {
4        _id: 1,
5        city: 1,
6        neighbourhood_group_cleansed: 1,
7        host_location: "$host.location",
8        host_city: {
9          $let: {
10             vars: {
11               loc: { $toLower: "$host.location" }
12             },
13             in: {
14               $arrayElemAt: [
15                 { $split: ["$$loc", ","] },
16                 0
17               ]
18             }
19           }
20         }
21       }
22     },
23     {
24       $match: {
25         $expr: {
26           $ne: [
27             { $trim: { input: { $toLower: "$city" } } },
28             { $trim: { input: "$host_city" } }
29           ]
30         }
31       }
32     },
33     {
34       $project: {
35         _id: 1,
36         property_city: "$city",
37         property_neighbourhood: "$neighbourhood_group_cleansed",
38         host_location: 1,
39         host_city: 1,
40         is_different_city: true
41       }

```

```

42 },
43 { $limit: 20 }
44 ])

```

Resultados: Abaixo podemos ver tres exemplos deste tipo de hospedadores. Curiosamente as tres descrições están en inglés, o cal denota impersonalidade.

```

1   _id: ObjectId('693479ddab134920609d88b9'),
2   host_location: 'Catalonia, Spain',
3   host_city: 'catalonia',
4   property_city: 'barcelona',
5   property_neighbourhood: 'Sant Marti'
6 },
7 {
8   _id: ObjectId('693479ddab134920609d88c5'),
9   host_location: 'Vilassar de Mar, Spain',
10  host_city: 'vilassar de mar',
11  property_city: 'barcelona',
12  property_neighbourhood: 'Sant Marti'
13 },
14 {
15   _id: ObjectId('693479ddab134920609d88c7'),
16   host_location: 'Colon, Panama',
17   host_city: 'colon',
18   property_city: 'barcelona',
19   property_neighbourhood: 'Eixample'
20 },
21
22 ...

```

5.2.6. Consulta: Cales son os hospedaxes que están a facer un bo último mes?

Xustificación: esta consulta é de carácter moi xeral e o interese pode vir de moitos lados; os hospedadores poden querer estudar que fan eses hospedaxes tan bos; tamén AirBnB pódese ver beneficiado se é capaz de caracterizar tendencias, ou premiar aos mellores hospedaxes.

```

1 db.listings.aggregate([
2   {
3     $match: {
4       number_of_reviews_130d: { $gt: 0 },
5       reviews_per_month: { $gt: 0 }
6     }
7   },
8   {
9     $project: {
10       _id: 1,
11       city: 1,
12       neighbourhood_group_cleansed: 1,
13       price: 1,
14       "score.rating": 1,
15       number_of_reviews_130d: 1,
16       reviews_per_month: 1,
17       performance_score: {
18         $add: [

```

```

19         { $multiply: ["$number_of_reviews_130d", 2] },
20         { $multiply: ["$reviews_per_month", 1.5] },
21         { $multiply: ["$score.rating", 10] }
22     ]
23 },
24 recent_popularity: {
25     $multiply: ["$number_of_reviews_130d", 10]
26 }
27 }
28 },
29 {
30     $match: {
31         performance_score: { $gt: 40 }
32     }
33 },
34 {
35     $sort: {
36         performance_score: -1,
37         recent_popularity: -1
38     }
39 },
40 {
41     $project: {
42         _id: 1,
43         city: 1,
44         neighbourhood: "$neighbourhood_group_cleansed",
45         price: 1,
46         rating: "$score.rating",
47         reviews_last_30d: "$number_of_reviews_130d",
48         reviews_per_month: 1,
49         performance_score: { $round: ["$performance_score", 2] },
50         status: {
51             $switch: {
52                 branches: [
53                     { case: { $gte: ["$performance_score", 70] }, then: "Excellent" },
54                     { case: { $gte: ["$performance_score", 50] }, then: "Good" },
55                     { case: { $gte: ["$performance_score", 40] }, then: "Average" }
56                 ],
57                 default: "Below Average"
58             }
59         }
60     }
61 },
62 { $limit: 15 }
63 ])

```

Resultados:

```

1  {
2    _id: ObjectId('693348dc7269f26612df5898'),
3    price: 33,

```

```

4     reviews_per_month: 94.77,
5     city: 'barcelona',
6     neighbourhood: 'San Marti',
7     performance_score: 428.45,
8     status: 'Excellent'
9 },
10 {
11     _id: ObjectId('693348dc7269f26612e06f70'),
12     price: 128,
13     reviews_per_month: 82.94,
14     city: 'madrid',
15     neighbourhood: 'San Blas - Canillejas',
16     rating: 4.82,
17     reviews_last_30d: 116,
18     performance_score: 404.61,
19     status: 'Excellent'
20 },
21 {
22     _id: ObjectId('693348dc7269f26612df3f4f'),
23     price: 324,
24     reviews_per_month: 61.23,
25     city: 'barcelona',
26     neighbourhood: 'Eixample',
27     rating: 4.72,
28     reviews_last_30d: 100,
29     performance_score: 339.05,
30     status: 'Excellent'
31 },
32
33 ...

```

6. Recheo de nulos usando Aprendizaxe Automática

Como a columna `price` nos `.csv` orixinais tiña un 13% de nulos (ver Figura 2), decidimos adestrar un modelo de Aprendizaxe Automática para *predicir* os valores do prezo. Ademais, esta tarefa parecíanos interesante de por si. Para facela consideramos interesante a columna de centralidade obtida na Consulta 1. Se ben é certo que sae máis a conta calcular eses valores de centralidade directamente en Python, queremos cargar eses valores de MongoDB para simular unha ocasión na que sexa máis doado facer unha consulta. Para isto usamos o arquivo adxunto `mongo2csv.py` que devolve a devandita columna ordenada polo número de fila para garantir a coherencia e a engade pola dereita ao `csv` orixinal. Sobre estes datos hai que realizar algunhas modificacións: as columnas de texto libre (como a descrición ou os barrios) elimínanse, as categóricas (como o tempo de resposta ou o tipo de propiedade) codifícanse *one hot* e as numéricas que estaban en porcentaxe formatéanse. Deste xeito temos uns datos listos para adestrar un modelo con eles. O modelo elixido é un XGBoost que se basea en árbores con Boosting e ten licenza Apache 2, polo que podería ter efectivamente un uso comercial por parte de AirBnB ou algunha empresa de hospedaxes xa que a licenza o permite. As tarefas de limpeza e adestramento fanas `train.py`, quen tamén devolve táboas $\text{\LaTeX}$ como saída.

Táboa 2: Métricas do modelo

Métrica	Valor
MAE	128.02
RMSE	933.03
R ²	0.58
MAPE (\ %)	57.31
Prezo medio	327.23
MAE / Prezo medio (\ %)	39.12

Táboa 3: Predicións de exemplo

Prezo real	Prezo predicido	Diferenza	Erro (\ %)
148.000000	250.000000	-102.000000	68.920000
32.000000	82.559998	-50.560000	158.000000
144.000000	234.710007	-90.710000	62.990000
9143.000000	6978.950195	2164.050000	23.670000
192.000000	169.710007	22.290000	11.610000
51.000000	111.699997	-60.700000	119.020000
126.000000	123.199997	2.800000	2.220000
40.000000	42.880001	-2.880000	7.210000
192.000000	200.089996	-8.090000	4.220000
25.000000	113.599998	-88.600000	354.400000

Táboa 4: Importancia das variables

Variable	Importancia
property_type_Room in aparthotel	0.086350
host_total_listings_count	0.053015
city_lyon	0.048556
host_response_rate	0.044750
host_location_Barcelona, Spain	0.038908
host_location_London, United Kingdom	0.031774
city_mallorca	0.030695
host_experience_days	0.030252
host_location_Munich, Germany	0.028399
host_location_Petra, Spain	0.027636
property_type_Room in boutique hotel	0.025786
property_type_Room in serviced apartment	0.025423
city_lisboa	0.024066
property_type_Room in hotel	0.021175
host_location_Zürich, Switzerland	0.019949

7. Conclusións

Deseñada a base de datos e realizadas as consultas de exemplo, estimamos este enfoque do traballo como potencialmente útil para a análise de mercado neste sector dos alugueres/turis-

mo. Enfocar a BD cara aos listings permitiunos aplicar características clave e moi útiles da plataforma MongoDB (como os xa mencionados arrays embebidos e documentos anidados) as cales houberan sido máis difíciles de aplicar e mostrar a súa utilidade se o enfoque principal da base seguise sendo as reviews en si [1].

Deste modo tamén foi trivial a tarefa de pensar nunha aplicación dun modelo de Aprendizaxe Automática, pois pode resolver un problema real, o de suxerir un prezo para o usuario que quere publicar un novo listing, ademais do seu posible uso para rechear nulos.

Para pechar esta conclusión gustaríanos sinalar como posible traballo futuro a construción da base de datos tendo as reviews como elemento principal. Isto permitiría a obtención dun dataset útil para algúns modelos de Linguaxe (estilo BERT). O seu uso principal sería adestralos sobre todo co texto das reviews e que esencialmente realice unha tarefa de análise de sentimentos sobre eles, sendo capaz incluso de asociarlles un rating máis preciso e realista que o do propio usuario xa que xeralmente os ratings dados polos usuarios non seguen a distribución normal, senón que teñen picos nos extremos, moitas reviews teñen 0 e 5 estrelas. Este fenómeno recibe o nome de patrón de distribución en J e está ben documentado [[8]] e comprobado que adestrar modelos sobre datos que seguen tales patróns é máis dificultoso e producen peores resultados [[9]] (outro motivo polo que optouse polo cambio do enfoque do dataset nesta práctica).

Referencias

- [1] “pandas bsd 3-clause license,” <https://github.com/pandas-dev/pandas?tab=BSD-3-Clause-1-ov-file>, accessed: 2025-12-05.
- [2] Python Software Foundation, “Cpython license (psf license version 2),” <https://github.com/python/cpython?tab=License-1-ov-file>, accessed: 2025-12-05.
- [3] “Gnu general public license, version 3,” <https://www.gnu.org/licenses/gpl-3.0.html>, accessed: 2025-12-05.
- [4] “Mongodb server side public license (sspl),” <https://github.com/mongodb/mongo?tab=License-1-ov-file>, accessed: 2025-12-05.
- [5] “Syntactic sugar,” https://en.wikipedia.org/wiki/Syntactic_sugar, accessed: 2025-12-06.
- [6] “R license,” <https://www.r-project.org/COPYING>, accessed: 2025-12-05.
- [7] “Julia mit license,” <https://github.com/JuliaLang/julia?tab=MIT-1-ov-file>, accessed: 2025-12-05.
- [8] N. Hu, P. A. Pavlou, and J. Zhang, “Overcoming the j-shaped distribution of product reviews,” *Communications of the ACM*, vol. 52, no. 10, pp. 144–147, 2009.
- [9] J. M. Johnson and T. M. Khoshgoftaar, “Survey on deep learning with class imbalance,” *Journal of Big Data*, vol. 6, no. 1, pp. 1–54, 2019.