

ENTREGA 3: ADE & MONGODB

Marcelo Ferreiro Sánchez, Pablo Chantada Saborido
Gillermo García Engelmo & Pepe Romero Conde

5 de diciembre de 2025

Índice

1. Introducción	2
2. Modelo de Datos	2
3. Preprocesado de datos	3
3.1. Análisis exploratorio del dataset	4
3.2. Tratamiento de nulos	4
3.3. Otras operaciones de procesado	5
4. Definición e implementación de la Base de Datos	5
5. Explotación de la Base de Datos	5
Consulta 1	5
Consulta 2	6
Consulta 3	6
Consulta 4	7
Consulta 5	8
Consulta 6	8
Consulta 7	8
6. Recheo de nulos usando Aprendizaxe Automático	10

1. Introducción

Como nas prácticas anteriores, traballamos sobre o conxunto de datos de AirB&B. Neste caso truncamos o punto de vista ou a aplicación. Se ben anteriormente o foco era na explotación analítica de o feito **valoración** agora centrámosnos nos **hospedaxes**. O diseño da Base de datos terá lugar na sección 4, e será realizado sobre os datos expostos en 2.

2. Modelo de Datos

Nesta ocasión non nos limitamos a usar os `.csvs` de unha cidade, con motivo de enriquezer as estadísticas. Dende un principio observamos que o porcentaxe de nulos non era ó meso ó longo das cidades, por eso con varias cidades esperamos unha representación máis fiel da realidade. As primeiras manipulacións que tivemos que facerlle ós datos foi a de eliminar as columnas que non nos interesasen, engadir a columna de “cidade” e apilar todo nun `csv`. Fixemos ese traballo ca librería Pandas [?] de Python [?] (ver `scripts/clean_csvs.py`).

As columnas elixidas **[FALAR DAS COLUMNAS ELIXIDAS, A ELECCION]**

As cidades elixidas foron: Barcelona, Euskadi, Girona, Lisboa, Madrid, Malaga, Mallorca, Menorca, Porto, Sevilla e Valencia. O Modelo de Datos co porcentaxe de nulos reportado para estas cidades pode verse na Figura 1.



Figura 1: Diagrama do Modelo de Datos

3. Preprocesado de datos

- Análisis exploratorio inicial. Mostrar forma y tamaño del dataset, identificar tipos de datos, identificar valores nulos y detectar posibles outliers.
- Tratamiento de valores faltantes. Aplicar al menos dos estrategias diferentes, justificadas según el tipo de variable: eliminar registros con demasiados nulos, rellenar variables numéricas (media, mediana, etc.), rellenar categóricos (utilizando la moda o una categoría especial), sustituir mediante reglas específicas del dominio.
- Transformaciones adicionales. Según proceda en el dominio, deben aplicarse al menos dos transformaciones tales como:

Normalización o estandarización de variables numéricas.

Codificación simple de valores categóricos.

Limpieza de texto simple (trim, lowercase, ...).

Agrupaciones o reducción de categorías (por ejemplo, High, Medium, Low).

- Balanceo de datos. Si el dominio lo requiere deben aplicarse técnicas de undersampling, oversampling, filtrado de ruido, etc. (Opcional, solo si es pertinente en caso de hacer tarea 4)

3.1. Análisis exploratorio del dataset

3.2. Tratamiento de nulos

En canto o tratamento de nulos, dicir que todos son de tipo numérico. Isto condiciona as opcións de imputación. Ademáis pódense que os nulos divídense en tres grupos: os relacionados co inmobiliario (baños, habitacións e camas), os valores de *Score* e o número de hospedaxes. Unha primeira idea de encher os nulos dun grupo con valores do mesmo (e.g. imputar o *score* de comunicación co resto de *scores*) desmantelouse á vista da Figura 2



Figura 2: Correlación entre os nulos. Pódese apreciar claramente que os *scores* son nulos á vez, igual que cos membros do inmobiliario.

```
(.venv) 🌱🌱🌱🌱 entrega_03 (main) » python scripts/knn_vs_median.py
bathrooms: Median MSE=1.3115, KNN MSE=0.6238
beds: Median MSE=5.4196, KNN MSE=2.3719
host_total_listings_count: Median MSE=283499.0809, KNN MSE=191732.6506
bedrooms: Median MSE=1.9067, KNN MSE=0.9160
```

Figura 3: Comparación dos métodos de imputación KNN ($k=3$) e mediana sobre a métrica $\mathcal{L}_2$. Os resultados repórtanse con KFold de $k=2$.

3.3. Otras operaciones de procesado

4. Definición e implementación de la Base de Datos

- Deberá crearse una base de datos específica para el dominio en una instalación propia de MongoDB, en la que se importarán los datos usando una de las tres formas:
 - Pymongo para importación directa desde Python.
 - Exportación en formato JSON y carga mediante MongoDB Compass.
 - Exportación en formato JSON e importación mediante mongoimport desde terminal.
- Explicar detalladamente la estructura de los documentos (anidar objetos, arrays, decisiones de normalización o desnormalización). Xustificar el modelo elegido y posibles alternativas.

Unha vez que temos o `csv` con as columnas que queremos (e solo esas) e os valores limpos, é un bo momento de cargar os datos en MongoDB (licencia en [?])

5. Explotación de la Base de Datos

Cada grupo deberá implementar 4 consultas que respondan a preguntas analíticas relevantes dentro de su dominio. Se valorará positivamente el uso del pipeline de agregación. Algunos ejemplos de categorías válidas serían: cálculo de estadísticas numéricas, agrupaciones por barrio/tipo de habitación/host/país, ranking (top de precios/valoraciones), detección de anomalías o valores extremos, evolución temporal. Cada consulta debe incluir:

- Enunciado claro de la pregunta analítica que quiere responder.
- Consulta completa o pipeline en sintaxis MongoDB.
- Resultados resumidos o capturas de la salida, acompañados de una breve explicación de la salida.

Agora que hemos definido e implementado a nosa Base de Datos,

Consulta 1: Obter un índice de centralidade (dentro da cidade) para cada hospedaxe

Xustificación: como verase na sección 6, imos usar este valor para facer prediccións sobre o precio de cada hospedaxe. Ademáis parecíanos un bo uso das funcións nativas de MongoDB.

Para levar acabo esta consulta precisamos calcular os centroides de cada cidade e logo, para cada hospedaxe calcularemos a distancia ó centroide. O seguinte código crea ditos centroides, agragando os hospedaxes por cidade e facendo a media das súas coordenadas.

```

1 const centroides = db.listings.aggregate([
2   {
3     $group: {
4       _id: "$city",
5       avg_lat: { $avg: "$latitude" },
6       avg_lon: { $avg: "$longitude" }
7     }
8   }
9 ]).toArray();

```

Agora que temos eso só nos queda facer un `updateMany` no que por cada centroide, collemos os hospedaxes desa cidade e calculamos a distancia euclídea do centroide ó hospedaxe. Malia seren moitas liñas, as liñas 8-13 correspóndense co cálculo.

```

1 centroides.forEach(c => {
2   db.listings.updateMany(
3     { city: c._id },      // filtro
4     [
5       {
6         $set: {
7           centrality: {
8             $sqrt: {
9               $add: [
10                { $pow: [{ $subtract: ["$latitude", c.avg_lat] }, 2]
11                },
12                { $pow: [{ $subtract: ["$longitude", c.avg_lon] }, 2]
13                }
14              ]
15            }
16          }
17        }
18      ]
19    );
20  });

```

Resultados: Tal cual o fixemos cambia a base de datos, non devolve. Para ver o efecto podemos facer unha mini-consulta de comprobación como `db.listings.findOne()` e ver que xa figura o novo atributo.

Consulta 2: Cales son os barrios con hospedadores máis novos? Para cada cidade

Xustificación:

Resultados:

```

1 SELECT

```

Consulta 3: Influe foto de perfil no prezo medio?

Xustificación: de ser certo, AirBnB debería existir ós seus hospedadores que se poñan foto, ou mesmo saldría deles. Tamén é interesante dende o punto de vista sociolóxico.

Esta consulta é sinxela, só hai que agrupar por valor de `host.has_profile_pic`, agregando o precio

```
1 db.listings.aggregate([
2   {
3     $group: {
4       _id: "$host.has_profile_pic",
5       avg_price: { $avg: "$price" },
6       min_price: { $min: "$price" },
7       max_price: { $max: "$price" },
8       std_dev_price: { $stdDevSamp: "$price" },
9       count: { $sum: 1 }
10    }
11  },
12  {
13    $project: {
14      has_profile_pic: "$_id",
15      avg_price: { $round: ["$avg_price", 2] },
16      min_price: 1,
17      max_price: 1,
18      std_dev_price: 1,
19      count: 1,
20      _id: 0
21    }
22  },
23  { $sort: { has_profile_pic: 1 } }
24 ])
```

Resultados: como pode verse os resultados obtidos (ver abaixo) son algo significativos, posto que aínda que as medias son distintas as desviacións estandar solápanse. En calquera caso, análise de distribucións é algo que debería facerse en R [?], Julia [?] ou Python pero non en MongoDB.

```
1 {
2   min_price: 8,
3   max_price: 18000,
4   std_dev_price: 407.5147249606762,
5   count: 4682,
6   has_profile_pic: false,
7   avg_price: 161.12
8 },
9 {
10  min_price: 8,
11  max_price: 92150,
12  std_dev_price: 1500.7666758984817,
13  count: 154072,
14  has_profile_pic: true,
15  avg_price: 366.86
16 }
```

Consulta 4: Cales son os barrios con hospedaxes máis grandes (máis habitacións)?

Xustificación:

Resultados:

```
1 SELECT
```

Consulta 5: Que score é o que máis fluctua?

Xustificación:

Resultados:

```
1 SELECT
```

Consulta 6: Cales son os hospedaxes con hospedadores fóra desa cidade?

Xustificación:

Resultados:

```
1 SELECT
```

Consulta 7: Cales son os hospedaxes que estan a facer un bo último mes?

Xustificación: esta consula é de carácter moi xeral e o interese pode vir de moitos lados, os hospedadores poden querer estudar que fan eses hospedaxes tan bos; tamén AirBnB pódese ver beneficiado se é capaz de caracterizar tendencias, ou premiar ós mellores hospedaxes.

```
1 db.listings.aggregate([
2   {
3     $match: {
4       number_of_reviews_l30d: { $gt: 0 },
5       reviews_per_month: { $gt: 0 }
6     }
7   },
8   {
9     $project: {
10       _id: 1,
11       description: 1,
12       city: 1,
13       neighbourhood_group_cleansed: 1,
14       price: 1,
15       "score.rating": 1,
16       number_of_reviews_l30d: 1,
17       reviews_per_month: 1,
18       performance_score: {
19         $add: [
20           { $multiply: ["$number_of_reviews_l30d", 2] },
21           { $multiply: ["$reviews_per_month", 1.5] },
22           { $multiply: ["$score.rating", 10] }
23         ]
24       },
25       recent_popularity: {
26         $multiply: ["$number_of_reviews_l30d", 10]
```



```

27     }
28   }
29 },
30 {
31   $match: {
32     performance_score: { $gt: 40 }
33   }
34 },
35 {
36   $sort: {
37     performance_score: -1,
38     recent_popularity: -1
39   }
40 },
41 {
42   $project: {
43     _id: 1,
44     description: 1,
45     city: 1,
46     neighbourhood: "$neighbourhood_group_cleansed",
47     price: 1,
48     rating: "$score.rating",
49     reviews_last_30d: "$number_of_reviews_l30d",
50     reviews_per_month: 1,
51     performance_score: { $round: ["$performance_score", 2] },
52     status: {
53       $switch: {
54         branches: [
55           { case: { $gte: ["$performance_score", 70] }, then: "
56             Excellent" },
57           { case: { $gte: ["$performance_score", 50] }, then: "Good"
58             },
59           { case: { $gte: ["$performance_score", 40] }, then: "
60             Average" }
61         ],
62         default: "Below Average"
63       }
64     }
65   }
66 },
67 { $limit: 15 }
68 ]))

```

Resultados:

```

1  {
2    _id: ObjectId('693348dc7269f26612df5898'),
3    description: 'Ideal room to share stories and experiences with
    capacity for up to 8 people. It has 4 bunk beds. Includes a
    private bathroom, two sinks, air conditioning, free wifi, bed
    linen and an individual space to store your luggage. All beds
    have USB connection to charge your devices. Unite has rooms
    with bathroom adapted for the disabled according to
    availability.<br/>The establishment is cashless.<br/>Unite is

```

```

    'cashless',
4   price: 33,
5   reviews_per_month: 94.77,
6   city: 'barcelona',
7   neighbourhood: 'Sant Mart ',
8   rating: 4.43,
9   reviews_last_30d: 121,
10  performance_score: 428.45,
11  status: 'Excellent'
12 },
13 {
14   _id: ObjectId('693348dc7269f26612e06f70'),
15   description: 'This bright and cosy double room comes with a double
    bed, air-conditioning, wall-mounted TV and free Wi-Fi. All
    rooms in easyHotel Madrid Alcalá offer comfort and cleanliness
    at a budget price to allow you to spend time exploring our
    great city outside of your hotel room. Room size 12 sqm.',
16   price: 128,
17   reviews_per_month: 82.94,
18   city: 'madrid',
19   neighbourhood: 'San Blas - Canillejas',
20   rating: 4.82,
21   reviews_last_30d: 116,
22   performance_score: 404.61,
23   status: 'Excellent'
24 },
25 {
26   _id: ObjectId('693348dc7269f26612df3f4f'),
27   description: 'Flawless time with the whole family in this stylish
    accommodation!<br/><br/>The apartments have three bedrooms,
    a bathroom, and a toilet. The master bedroom has a double bed,
    the second bedroom has two single beds and the third bedroom
    has a single bed.<br/><br/>Enjoy the freedom and privacy of
    having your own apartment in the city center.',
28   price: 324,
29   reviews_per_month: 61.23,
30   city: 'barcelona',
31   neighbourhood: 'Eixample',
32   rating: 4.72,
33   reviews_last_30d: 100,
34   performance_score: 339.05,
35   status: 'Excellent'
36 },
37
38 ...

```

6. Recheo de nulos usando Aprendizaxe Automático

De forma opcional y rápida, entrenar un modelo de aprendizaje automático utilizando los datos almacenados en MongoDB (por ejemplo, regresión, clasificación, ...). Debe explicarse brevemente el objetivo del modelo, las variables utilizadas y los resultados principales.

Como a columna `price` nos .csvs orixinais tiña un 10% de nulos, decidimos entrenar un

modelo de Aprendizaxe Automático para *regresar* los valores de precio. Además, esta tarea parecíanos interesante de por sí.

Referencias

- [1] “pandas bsd 3-clause license,” <https://github.com/pandas-dev/pandas?tab=BSD-3-Clause-1-ov-file>, accessed: 2025-12-05.
- [2] Python Software Foundation, “Cpython license (psf license version 2),” <https://github.com/python/cpython?tab=License-1-ov-file>, accessed: 2025-12-05.
- [3] “Mongodb server side public license (sspl),” <https://github.com/mongodb/mongo?tab=License-1-ov-file>, accessed: 2025-12-05.
- [4] “R license,” <https://www.r-project.org/COPYING>, accessed: 2025-12-05.
- [5] “Julia mit license,” <https://github.com/JuliaLang/julia?tab=MIT-1-ov-file>, accessed: 2025-12-05.