

ENTREGA 3: ADE & MONGODB

Marcelo Ferreiro Sánchez, Pablo Chantada Saborido
Gillermo García Engelman & Pepe Romero Conde

6 de diciembre de 2025

Índice

1. Introducción	2
2. Modelo de Datos	2
3. Preprocesado de datos	3
3.1. Análisis exploratorio del dataset	4
3.2. Tratamiento de nulos	4
3.2.1. Nulos numéricos	4
3.2.2. Otros nulos	5
3.3. Otras operaciones de procesado	6
4. Definición e implementación da Base de Datos	6
5. Explotación da Base de Datos	8
Consulta 1	9
Consulta 2	10
Consulta 3	12
Consulta 4	13
Consulta 5	15
Consulta 6	17
Consulta 7	19
6. Relleno de nulos usando Aprendizaxe Automático	21

1. Introducción

Como nas prácticas anteriores, traballamos sobre o conxunto de datos de AirBnB. Neste caso truncamos o punto de vista ou a aplicación. Se ben anteriormente o foco era na explotación analítica do feito **valoración** agora centrámonos nos **hospedaxes**. O diseño da Base de datos terá lugar na sección 4, e será realizado sobre os datos expostos en 2.

2. Modelo de Datos

Nesta ocasión non nos limitamos a usar os `.csvs` de unha cidade, con motivo de facer máis diversas as estadísticas e os resultados en xeral. Dende un principio observamos que o porcentaxe de nulos para a mesma columna non era ó meso ó longo das cidades, por eso con varias cidades esperamos unha representación máis fiel da realidade (e.g a cidade de Girona ten 100% de nulos para a columna `neighbourhood_group_cleansed` mentras que Lisboa ten un 0%). As primeiras manipulacións que tivemos que facerlle ós datos foi a de eliminar as columnas que non nos interesasen, engadir a columna de “cidade” e apilar todo nun `csv`. Fixemos ese traballo ca librería Pandas [1] de Python [2], xa que os campos de texto libre, como `description`, contiñan caracteres de salto de carro `^M` que dificultaban a tarefa a *oneliners* en AWK [3] (ver o programa adxunto `src/merge_csvs.py` e a Figura 1).

As columnas elixidas pódense ver na Figura 2. A elección foi un compromiso entre expresividade e tamaño, pensamos que cas columnas elixidas podemos facer bos análisis e consultas sen ten que cargar con todo o peso dos `.csvs` orixinais. Ademáis, o teren tipos de datos distintos e mesmo unha estrutura xerárquica implícita, supoñen unha interesante materia prima. A estrutura implícita a modelamos como: unha única colección de hospedaxes na que cada documento ten embebidos outros dous (o hospedador e máis o *Score*) e un arranxo, as prestacións.




Figura 1: A primeira transformación e xuntar os datos de distintas cidades e quitar as columnas que non nos interesen. Aproveitamos a ocasión para facer unha imputación sinxela, *vaninilla* dos datos



Figura 2: Diagrama do Modelo de Datos

3. Preprocesado de datos

- Análisis exploratorio inicial. Mostrar forma y tamaño del dataset, identificar tipos de datos, identificar valores nulos y detectar posibles outliers.
- Tratamiento de valores faltantes. Aplicar al menos dos estrategias diferentes, justificadas según el tipo de variable: eliminar registros con demasiados nulos, rellenar variables numéricas (media, mediana, etc.), rellenar categóricos (utilizando la moda o una categoría especial), sustituir mediante reglas específicas del dominio.
- Transformaciones adicionales. Según proceda en el dominio, deben aplicarse al menos dos transformaciones tales como:

Normalización o estandarización de variables numéricas.

Codificación simple de valores categóricos.

Limpieza de texto simple (trim, lowercase, ...).

Agrupaciones o reducción de categorías (por ejemplo, High, Medium, Low).

- Balanceo de datos. Si el dominio lo requiere deben aplicarse técnicas de undersampling, oversampling, filtrado de ruido, etc. (Opcional, solo si es pertinente en caso de hacer tarea 4)

3.1. Análisis exploratorio del dataset




Figura 3

Densidade de Hospedaxes por Cidade




Figura 4




Figura 5

3.2. Tratamiento de nulos

Como logo temos que volcar os datos a MongoDB (licencia en [4]), o noso programa xa limpia os datos cunha imputación sinxela pero apropiada para o tipo de datos (o exisido pola práctica), non obstante podemos desactivala e observar os nulos do arquivo mergeado, o porcentaxe está dispoñíbel na Figura 2. Ademáis do porcentaxe é interesante o tipo de dato e o rol que desempeña esa columna.

3.2.1. Nulos numéricos

Dende logo o tipo de dato condiciona as opcións de imputación. Ademáis pódese dicir que estos nulos divídense en tres grupos: os relacionados co inmobiliario (baños, habitacións e camas), os valores das reseñas e tres atributos do hospedador. Unha primeira idea de encher os nulos dun grupo con valores do mesmo (e.g. imputar o *score* de comunicación co resto de *scores*) desmantelouse á vista da Figura 3, e dicir, non se poden encher os nulos dun grupo con valores dese grupo porque cando un é nulo os outros tamén (alta correlación). Ademáis por curiosidade, fixemos un experimento (ver `src/knn_vs_median.py` ou Figura 4) para ver a diferenza de error se usamos imputación simple (mediana) ou máis sofisticada (adestramento dun KNN non paramétrico) e obervamos que o erro malia ser a metade co método sofisticado, segue estando no mesmo orde de magnitude e ademáis encarece moito computacionalmente. Por todo o dito, e o alcance da práctica, limitámonos a unha imputación sinxela por mediana.

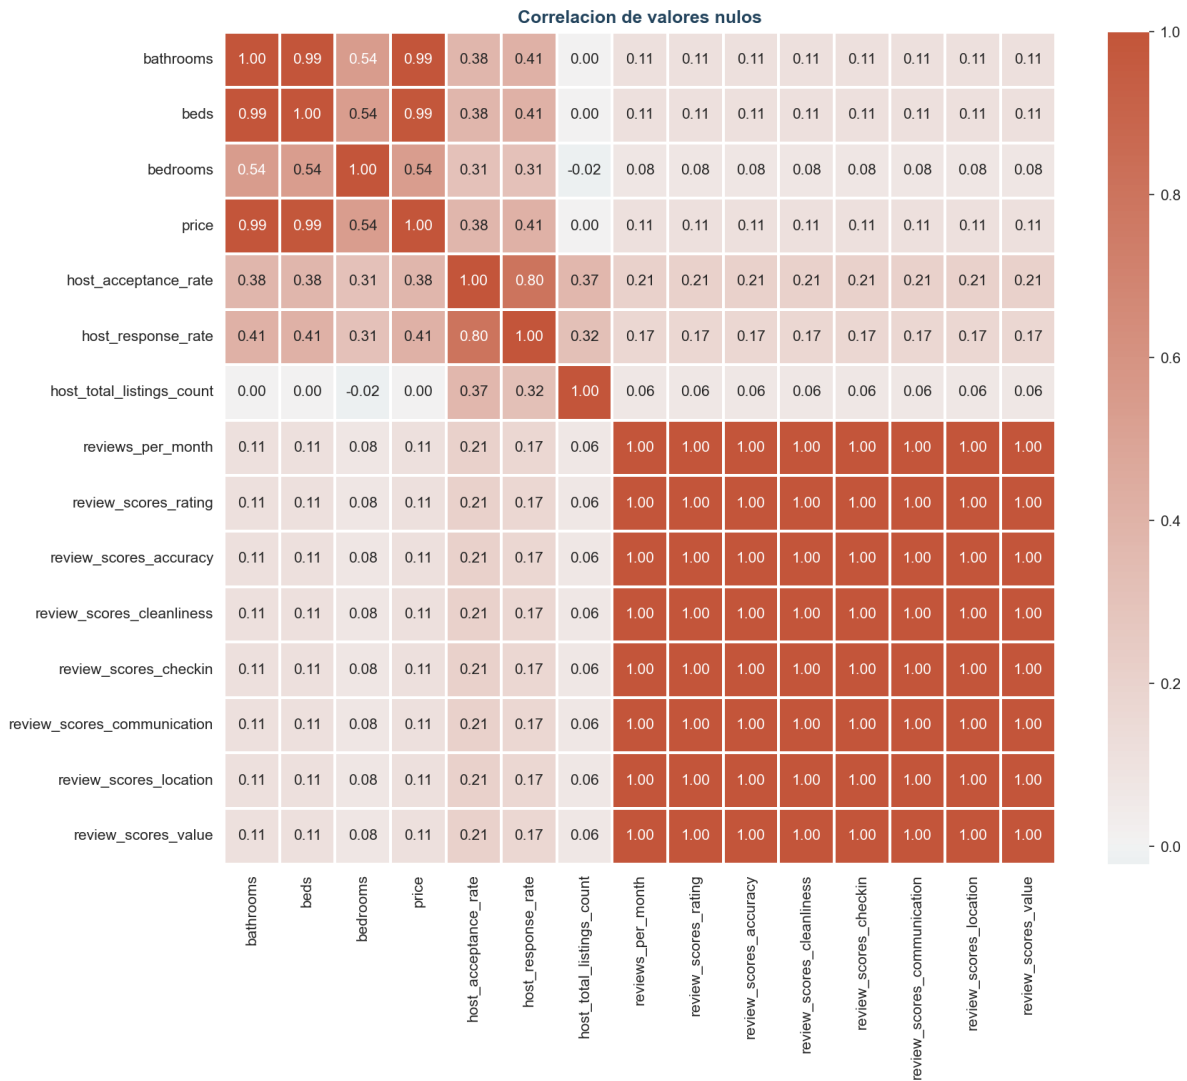


Figura 6: Correlación entre os nulos. Pódese apreciar claramente que os *scores* son nulos á vez, igual que cos membros do inmobiliario.

```

1 (.venv) > python src/knn_vs_median.py
2
3 bathrooms: Median MSE=1.3115, KNN MSE=0.6238
4 beds: Median MSE=5.4196, KNN MSE=2.3719
5 host_total_listings_count: Median MSE=283499.0809, KNN MSE=191732.6506
6 bedrooms: Median MSE=1.9067, KNN MSE=0.9160

```

Figura 7: Comparación dos métodos de imputación KNN ($k=3$) e mediana sobre a métrica $\mathcal{L}_2$. Os resultados repórtanse con KFold de $k=2$.

3.2.2. Outros nulos

Como pode verse na función `fillna` do arquivo `src/merge_csvs.py`, tanto os Booleanos como os Strings impútanse mediante a moda. Se ben poderíanse levar acabo operacións máis sofisticadas, polo alcance da práctica limitámonos a esta opción.

3.3. Outras operacións de procesado

Se ben o discutido até agora foi máis ben dos valores en sí, cabe destacar que para volcar os datos a MongoDB foi necesario un especial arranxo dos datos, en particular para o formato dos dous documentos embebidos e do arranxo de prestacións, estas operacións, en cambio as situamos na fase de carga (*Load*) e por tanto lévanse acabo no arquivo adxunto `csv2mongo.py`.

4. Definición e implementación da Base de Datos

- Deberá crearse una base de datos específica para el dominio en una instalación propia de MongoDB, en la que se importarán los datos usando una das tres formas:
 - Pymongo para importación directa desde Python.
 - Exportación en formato JSON y carga mediante MongoDB Compass.
 - Exportación en formato JSON e importación mediante mongoimport desde terminal.
- Explicar detalladamente la estructura de los documentos (anidar objetos, arrays, decisiones de normalización o desnormalización). Xustificar el modelo elegido y posibles alternativas.




Figura 8: Una vez que temos todos os datos nun `.csv` sobre o cal podemos facer Análisis Exploratorio, estamos listos para pasalos datos a MongoDB, segundo a definición do esquema dada na sección 2

O modelo de Datos da Figura 2 é o “esquema” que usaremos en MongoDB. Dado o noso planteamento de centrarnos nos *hospedaxes* (os protagonistas dos *csvs* máis grandes e argumentablemente da aplicación enteira de AirBnB) non houbo moitas decisións de deseño difíciles. O arranxo prestacións tiña que ser un arranxo en MongoDB e os *scores* son un documento embebido principalmente por suxe sintáctica [5]; en cambio os *hospedadores* ben podían ter sido unha colección por si mesma. Tal cousa tería sentido se fixeramos consultas *hospedador-centricas*, é dicir, se pensásemos os *hospedadores* como entidades por si mesmas, non foi o noso caso pois pensamos que o *hospedador* ven surrogado ó *hospedaxe* e as consultas que iamos facer non precisaban a complexidade de varias coleccións.

Dito o anterior, a Base de Datos móntase co *script* adxunto `csv2mongo.py`. Este establece conexión cun cliente de Mongo local e carga os datos no formato especificado, de xeito que podemos facer:

```
1 (.venv) entrega_03 (main) > python src/mongo/csv2mongo.py
2 Inserted 158754 listings into airbnb.listings
```



```

3 (.venv) entrega_03 (main) > mongosh
4 Current Mongosh Log ID: 69347505a2994911f4cd9cc3
5 Connecting to:          mongodb://127.0.0.1:27017/?directConnection=
      true&serverSelectionTimeoutMS=2000&appName=mongosh+2.5.10
6 Using MongoDB:          8.2.2
7 Using Mongosh:          2.5.10
8
9 For mongosh info see: https://www.mongodb.com/docs/mongodb-shell/
10
11 -----
12 The server generated these startup warnings when booting
13 2025-12-06T16:07:08.499+01:00: Access control          enabled for
      the database. Read      write access to data      configuration
      unrestricted
14 -----
15
16 test> use airbnb
17 switched to db airbnb
18 airbnb> db.listings.findOne()
19 {
20   _id: ObjectId('693474fcce4ae65c237470e5'),
21   description: '110m2 apartment to rent in Barcelona. Located in the
      Eixample district, near the Sagrada Familia. It has a small
      balcony where you can see the temple of Gaudi. Capacity for 8
      people. <br /><br />Licence number: HUTB-002062',
22   neighbourhood_group_cleansed: 'Eixample',
23   latitude: 41.40556,
24   longitude: 2.17262,
25   property_type: 'Entire rental unit',
26   accommodates: 8,
27   bathrooms: 2,
28   bedrooms: 3,
29   beds: 6,
30   price: 210,
31   number_of_reviews: 51,
32   number_of_reviews_l30d: 0,
33   availability_eoy: 74,
34   instant_bookable: true,
35   reviews_per_month: 0.34,
36   city: 'barcelona',
37   host: {
38     since: '2010-01-19',
39     location: 'Barcelona, Spain',
40     response_time: 'within an hour',
41     response_rate: '96%',
42     acceptance_rate: '91%',
43     is_superhost: false,
44     total_listings_count: 46,
45     has_profile_pic: true,
46     identity_verified: true
47   },
48   score: {
49     rating: 4.34,

```

```

50     accuracy: 4.4,
51     cleanliness: 4.56,
52     checkin: 4.64,
53     communication: 4.62,
54     location: 4.82,
55     value: 4.32
56 },
57 amenities: [
58     '["Pets allowed',
59     '30 inch TV',
60     'Coffee maker',
61     'Elevator',
62     'Host greets you',
63     'Pack \u2019n play/Travel crib',
64     'Heating',
65     'Hangers',
66     'AC - split type ductless system',
67     'Iron',
68     'Crib',
69     'Dishes and silverware',
70     'Private patio or balcony',
71     'Kitchen',
72     'Essentials',
73     'Free washer \u2013 In unit',
74     'Wifi',
75     'Hot water',
76     'City skyline view',
77     'Shampoo',
78     'Hair dryer',
79     'Refrigerator"]',
80 ],
81 row_id: 0
82 }

```

Pódese ver que a operación é exitosa e a consulta da liña 18 e só un exemplo para demostrar o funcionamento. Ademais pódese ver que ó final do documento hai un atributo de fila, este vai ser útil na sección 6 pois imos ter que exportar o resultado da primeira consulta de MongoDB a csv de volta, e ter o identificador de fila vai valer para emparexar facilmente. Sen identificador de fila teríamos que exportar a base de datos enteira, pero con el, podemos devolver as columnas que creemos en MongoDB ordeadas por `row_id` e teremos a certeza de que vai cuadrar ben.

5. Explotación da Base de Datos

Cada grupo deberá implementar 4 consultas que respondan a preguntas analíticas relevantes dentro de su dominio. Se valorará positivamente el uso del pipeline de agregación. Algunos ejemplos de categorías válidas serían: cálculo de estadísticas numéricas, agrupaciones por barrio/tipo de habitación/host/país, ranking (top de precios/valoraciones), detección de anomalías o valores extremos, evolución temporal. Cada consulta debe incluir:

- Enunciado claro da pregunta analítica que quiere responder.
- Consulta completa o pipeline en sintaxis MongoDB.

- Resultados resumidos o capturas da saída, acompañados de una breve explicación da saída.

Agora que hemos definido e implementado a nosa Base de Datos,

Consulta 1: Obter un índice de centralidade (dentro da cidade) para cada hospedaxe

Xustificación: como verase na sección 6, imos usar este valor para facer prediccións sobre o precio de cada hospedaxe. Ademáis parecíanos un bo uso das funcións nativas de MongoDB.

Para levar acabo esta consulta precisamos calcular os centroides de cada cidade e logo, para cada hospedaxe calcularemos a distancia ó centroide. O seguinte código crea ditos centroides, agragando os hospedaxes por cidade e facendo a media das súas coordenadas.

```
1 const centroides = db.listings.aggregate([
2   {
3     $group: {
4       _id: "$city",
5       avg_lat: { $avg: "$latitude" },
6       avg_lon: { $avg: "$longitude" }
7     }
8   }
9 ]).toArray();
```

Agora que temos eso só nos queda facer un `updateMany` no que por cada centroide, collemos os hospedaxes desa cidade e calculamos a distancia euclidea do centroide ó hospedaxe. Malia seren moitas liñas, as liñas 8-13 correspóndense co cálculo.

```
1 centroides.forEach(c => {
2   db.listings.updateMany(
3     { city: c._id },      // filtro
4     [
5       {
6         $set: {
7           centrality: {
8             $sqrt: {
9               $add: [
10                { $pow: [{ $subtract: ["$latitude", c.avg_lat] }, 2]
11                },
12                { $pow: [{ $subtract: ["$longitude", c.avg_lon] }, 2]
13                }
14              ]
15            }
16          }
17        }
18      ]
19    );
20 });
```

Resultados: Tal cual o fixemos cambia a base de datos, non devolve. Para ver o efecto podemos facer unha mini-consulta de comprobación como `db.listings.findOne()` e ver que xa figura o novo atributo.

Consulta 2: Cales son os barrios con hospedadores máis novos? Para cada cidade

Xustificación: esta consulta é básica para o análise de tendencias e evolución do mercado inmobiliario.

```
1 db.listings.aggregate([
2   {
3     $project: {
4       city: 1,
5       neighbourhood_group_cleansed: 1,
6       host_since: "$host.since",
7       year: { $year: { $toDate: "$host.since" } }
8     }
9   },
10  {
11    $group: {
12      _id: {
13        city: "$city",
14        neighbourhood: "$neighbourhood_group_cleansed"
15      },
16      avg_host_year: { $avg: "$year" },
17      count: { $sum: 1 }
18    }
19  },
20  {
21    $sort: { "_id.city": 1, "avg_host_year": -1 }
22  },
23  {
24    $group: {
25      _id: "$_id.city",
26      neighbourhoods: {
27        $push: {
28          neighbourhood: "$_id.neighbourhood",
29          avg_host_year: "$avg_host_year",
30          count: "$count"
31        }
32      }
33    }
34  },
35  {
36    $project: {
37      city: "$_id",
38      neighbourhoods: {
39        $slice: [
40          {
41            $sortBy: {
42              input: "$neighbourhoods",
43              sortBy: { avg_host_year: -1 }
44            }
45          },
46          5
47        ]
48      }
49    }
50  }
51 ]
```

```

49     }
50 }
51 ])

```

Resultados: se ben non procede mostrar os resultados completos, abaixo pódese ver as cidades con barrios máis novos. O certo é que a forma de mostrar esta consulta non so compara os barrios dentro dunha cidade pero ademáis as cidades entre sí.

```

1   ...
2
3   {
4     _id: 'euskadi',
5     city: 'euskadi',
6     neighbourhoods: [
7       {
8         neighbourhood: 'Vizcaya',
9         avg_host_year: 2019.032435404068,
10        : 3638
11      },
12      {
13        neighbourhood: 'Alava',
14        avg_host_year: 2017.819964349376,
15        : 561
16      },
17      {
18        neighbourhood: 'Guipuzcoa',
19        avg_host_year: 2017.6565040650407,
20        : 2952
21      }
22    ]
23  },
24  {
25    _id: 'madrid',
26    city: 'madrid',
27    neighbourhoods: [
28      {
29        neighbourhood: 'Vic lvaro',
30        avg_host_year: 2020.0117647058823,
31        : 85
32      },
33      {
34        neighbourhood: 'Tetu n',
35        avg_host_year: 2019.724836212031,
36        : 1679
37      },
38      {
39        neighbourhood: 'Villaverde',
40        avg_host_year: 2019.5731707317073,
41        : 246
42      },
43      {
44        neighbourhood: 'Villa de Vallecas',
45        avg_host_year: 2019.4336283185842,
46        : 113

```

```

47     },
48     {
49         neighbourhood: 'Barajas',
50         avg_host_year: 2019.3680981595091,
51         : 163
52     }
53 ]
54 },
55 {
56     _id: 'valencia',
57     city: 'valencia',
58     neighbourhoods: [
59         {
60             neighbourhood: 'BENICALAP',
61             avg_host_year: 2020.3698630136987,
62             : 146
63         },
64         {
65             neighbourhood: 'JESUS',
66             avg_host_year: 2020.0177304964539,
67             : 282
68         },
69         {
70             neighbourhood: 'RASCANYA',
71             avg_host_year: 2019.9685534591194,
72             : 159
73         },
74         {
75             neighbourhood: 'ALGIROS',
76             avg_host_year: 2019.9149560117303,
77             : 341
78         },
79         {
80             neighbourhood: 'PATRAIX',
81             avg_host_year: 2019.864406779661,
82             : 177
83         }
84     ]
85 }

```

Consulta 3: Influe foto de perfil no prezo medio?

Xustificación: de ser certo, AirBnB debería existir ós seus hospedadores que se poñan foto, ou mesmo saldría deles. Tamén é interesante dende o punto de vista sociolóxico.

Esta consulta é sinxela, só hai que agrupar por valor de `host.has_profile_pic`, agregando o prezo

```

1 db.listings.aggregate([
2     {
3         $group: {
4             _id: "$host.has_profile_pic",
5             avg_price: { $avg: "$price" },
6             min_price: { $min: "$price" },

```

```

7     max_price: { $max: "$price" },
8     std_dev_price: { $stdDevSamp: "$price" },
9     count: { $sum: 1 }
10  }
11 },
12 {
13     $project: {
14         has_profile_pic: "$_id",
15         avg_price: { $round: ["$avg_price", 2] },
16         min_price: 1,
17         max_price: 1,
18         std_dev_price: 1,
19         count: 1,
20         _id: 0
21     }
22 },
23 { $sort: { has_profile_pic: 1 } }
24 ]))

```

Resultados: como pode verse os resultados obtidos (ver abaixo) son algo significativos, posto que aínda que as medias son distintas as desviacións estándar solápanse. En calquera caso, análise de distribucións é algo que debería facerse en R [6], Julia [7] ou Python pero non en MongoDB.

```

1 {
2     min_price: 8,
3     max_price: 18000,
4     std_dev_price: 407.5147249606762,
5     : 4682,
6     has_profile_pic: false,
7     avg_price: 161.12
8 },
9 {
10     min_price: 8,
11     max_price: 92150,
12     std_dev_price: 1500.7666758984817,
13     : 154072,
14     has_profile_pic: true,
15     avg_price: 366.86
16 }

```

Consulta 4: Cales son os barrios con hospedaxes máis grandes (máis habitacións)?

Xustificación: esta información é decisiva nun análise de desigualdade entre territorios, ou mesmo pode ser de interese gobernamental, para o desenvolvemento de leis.

```

1 db.listings.aggregate([
2     {
3         $match: {
4             bedrooms: { $exists: true, $ne: null },
5             neighbourhood_group_cleansed: { $exists: true, $ne: null }
6         }
7     }
8 ])

```

```

7   },
8   {
9     $group: {
10      _id: {
11        city: "$city",
12        neighbourhood: "$neighbourhood_group_cleansed"
13      },
14      avg_bedrooms: { $avg: "$bedrooms" },
15      max_bedrooms: { $max: "$bedrooms" },
16      total_properties: { $sum: 1 },
17      large_properties: {
18        $sum: { $cond: [{ $gte: ["$bedrooms", 3] }, 1, 0] }
19      }
20    }
21  },
22  {
23    $project: {
24      city: "$_id.city",
25      neighbourhood: "$_id.neighbourhood",
26      avg_bedrooms: { $round: ["$avg_bedrooms", 2] },
27      max_bedrooms: 1,
28      total_properties: 1,
29      large_properties_percentage: {
30        $round: [
31          { $multiply: [{ $divide: ["$large_properties", "$total_properties"] }, 100] },
32          2
33        ]
34      }
35    }
36  },
37  { $sort: { "avg_bedrooms": -1, "large_properties_percentage": -1 } },
38  { $limit: 10 }
39 ]})

```

Resultados:

```

1   {
2     _id: { city: 'porto', neighbourhood: 'SAO JOAO DA MADEIRA' },
3     max_bedrooms: 20,
4     total_properties: 49,
5     city: 'porto',
6     neighbourhood: 'SAO JOAO DA MADEIRA',
7     avg_bedrooms: 7.76,
8     large_properties_percentage: 40.82
9   },
10  {
11    _id: { city: 'mallorca', neighbourhood: 'Lisboa' },
12    max_bedrooms: 20,
13    total_properties: 15034,
14    city: 'mallorca',
15    neighbourhood: 'Lisboa',
16    avg_bedrooms: 2.95,

```



```

17     large_properties_percentage: 62.63
18 },
19 {
20     _id: { city: 'lisboa', neighbourhood: 'Azambuja' },
21     max_bedrooms: 5,
22     total_properties: 18,
23     city: 'lisboa',
24     neighbourhood: 'Azambuja',
25     avg_bedrooms: 2.83,
26     large_properties_percentage: 50
27 },
28 {
29     _id: { city: 'menorca', neighbourhood: 'Lisboa' },
30     max_bedrooms: 12,
31     total_properties: 3679,
32     city: 'menorca',
33     neighbourhood: 'Lisboa',
34     avg_bedrooms: 2.66,
35     large_properties_percentage: 52.6
36 },
37
38 ...

```

Consulta 5: Que *score* é o que máis fluctua?

Xustificación:

```

1 db.listings.aggregate([
2   {
3     $match: {
4       "score.rating": { $exists: true, $ne: null }
5     }
6   },
7   {
8     $group: {
9       _id: null,
10      avg_accuracy: { $avg: "$score.accuracy" },
11      std_accuracy: { $stdDevSamp: "$score.accuracy" },
12      avg_cleanliness: { $avg: "$score.cleanliness" },
13      std_cleanliness: { $stdDevSamp: "$score.cleanliness" },
14      avg_checkin: { $avg: "$score.checkin" },
15      std_checkin: { $stdDevSamp: "$score.checkin" },
16      avg_communication: { $avg: "$score.communication" },
17      std_communication: { $stdDevSamp: "$score.communication" },
18      avg_location: { $avg: "$score.location" },
19      std_location: { $stdDevSamp: "$score.location" },
20      avg_value: { $avg: "$score.value" },
21      std_value: { $stdDevSamp: "$score.value" }
22    }
23  },
24  {
25    $project: {
26      _id: 0,

```

```

27     scores: [
28         {
29             name: "accuracy",
30             average: { $round: ["$avg_accuracy", 2] },
31             std_dev: { $round: ["$std_accuracy", 2] }
32         },
33         {
34             name: "cleanliness",
35             average: { $round: ["$avg_cleanliness", 2] },
36             std_dev: { $round: ["$std_cleanliness", 2] }
37         },
38         {
39             name: "checkin",
40             average: { $round: ["$avg_checkin", 2] },
41             std_dev: { $round: ["$std_checkin", 2] }
42         },
43         {
44             name: "communication",
45             average: { $round: ["$avg_communication", 2] },
46             std_dev: { $round: ["$std_communication", 2] }
47         },
48         {
49             name: "location",
50             average: { $round: ["$avg_location", 2] },
51             std_dev: { $round: ["$std_location", 2] }
52         },
53         {
54             name: "value",
55             average: { $round: ["$avg_value", 2] },
56             std_dev: { $round: ["$std_value", 2] }
57         }
58     ]
59 },
60 {
61     $unwind: "$scores"
62 },
63 {
64     $sort: { "scores.std_dev": -1 }
65 },
66 {
67     $group: {
68         _id: null,
69         most_fluctuating: { $first: "$scores" },
70         all_scores: { $push: "$scores" }
71     }
72 },
73 {
74     $project: {
75         _id: 0,
76         "O_score_queue_m is_fluct a": {
77             name: "$most_fluctuating.name",
78             desviaci n_t pica: "$most_fluctuating.std_dev",
79

```

```

80     media: "$most_fluctuating.average"
81   },
82   "Todos os scores por orde de fluctuación": "$all_scores"
83 }
84 }
85 ])
```

Resultados: os resultados son sociolóxicamente moi interesantes porque as propiedades máis obxetivas e concretas do hospedaxe: a ubicación e a hora de checkin teñen menos fluctuación que as máis subxetivas e xerais como o valor xeral ou a limpeza (que é algo moi persoal).

```

1  [
2  {
3    'O score que m ís fluctúa': { name: 'value', 'desviación típica'
4      : 0.45, media: 4.56 },
5    'Todos os scores por orde de fluctuación': [
6      { name: 'value', average: 4.56, std_dev: 0.45 },
7      { name: 'cleanliness', average: 4.68, std_dev: 0.42 },
8      { name: 'accuracy', average: 4.72, std_dev: 0.4 },
9      { name: 'communication', average: 4.78, std_dev: 0.39 },
10     { name: 'checkin', average: 4.78, std_dev: 0.37 },
11     { name: 'location', average: 4.74, std_dev: 0.34 }
12   ]
13 }
```

Consulta 6: Cales son os hospedaxes con hospedadores fóra desa cidade?

Xustificación:

```

1  db.listings.aggregate([
2    {
3      $project: {
4        _id: 1,
5        description: 1,
6        city: 1,
7        neighbourhood_group_cleaned: 1,
8        host_location: "$host.location",
9        host_city: {
10          $let: {
11            vars: {
12              loc: { $toLower: "$host.location" }
13            },
14            in: {
15              $arrayElemAt: [
16                { $split: ["$$loc", ","] },
17                0
18              ]
19            }
20          }
21        }
22      }
23    },
```

```

24 {
25   $match: {
26     $expr: {
27       $ne: [
28         { $trim: { input: { $toLower: "$city" } } },
29         { $trim: { input: "$host_city" } }
30       ]
31     }
32   }
33 },
34 {
35   $project: {
36     _id: 1,
37     description: 1,
38     property_city: "$city",
39     property_neighbourhood: "$neighbourhood_group_cleansed",
40     host_location: 1,
41     host_city: 1,
42     is_different_city: true
43   }
44 },
45 { $limit: 20 }
46 ]))

```

Resultados:

```

1  _id: ObjectId('693479ddab134920609d88b9'),
2  description: 'Beautiful and Spacious Apartment with Large Terrace
      Just 5 Minutes from CCIB, 10 Minutes to the Beach and
      Marina (Port F rum).<br /><br />Enjoy the perfect balance of
      business and leisure in this modern, family-friendly apartment.
      <br /><br />Relax on the terrace with dinner, wine, or a cold
      beer just a short walk from the sea and Marina, but away from
      the crowds of central Barcelona.<br /><br />Smart TV, high-
      speed Wi-Fi, elevator, private parking (on request), and great
      public transport links.',
3  host_location: 'Catalonia, Spain',
4  host_city: 'catalonia',
5  property_city: 'barcelona',
6  property_neighbourhood: 'Sant Marti'
7 },
8 {
9  _id: ObjectId('693479ddab134920609d88c5'),
10 description: 'Tourist Licence No:
      ESFCTU0000080730009178160000000000000000HUTB-0000835. <br /><br />
      Maximum 3 persons.<br />Colourful apartment with a private
      patio in a lovely local neighbourhood. It has three bedrooms,
      two with double beds, one with a single bed and a sofa in the
      living room. Well served by public transport.<br /><br />
      Barcelona City tax not included in reservation amount.',
11 host_location: 'Vilassar de Mar, Spain',
12 host_city: 'vilassar de mar',
13 property_city: 'barcelona',
14 property_neighbourhood: 'Sant Marti'

```

```

15 },
16 {
17   _id: ObjectId('693479ddab134920609d88c7'),
18   description: 'Bedroom with a private bathroom exclusive use for
    this guests room. <br />Wi-Fi <br />Central apartment. <br />
    Conected to the airport with a cheap bus. <br />Most of the
    touristic areas can be visited by walk. <br />Safe area. <br
    />24h groseery shops around <br />Many international and local
    restaurants in the area. <br />Metro and buses on the corner of
    home. <br />Small room but all is very clean and at night is
    super calm to have a good rest. <br />You will love to enjoy
    your stay with our small family but We respect your time and
    space.',
19   host_location: 'Colon, Panama',
20   host_city: 'colon',
21   property_city: 'barcelona',
22   property_neighbourhood: 'Eixample'
23 },
24
25 ...

```

Consulta 7: Cales son os hospedaxes que estan a facer un bo último mes?

Xustificación: esta consula é de carácter moi xeral e o interese pode vir de moitos lados, os hospedadores poden querer estudar que fan eses hospedaxes tan bos; tamén AirBnB pódese ver beneficiado se é capaz de caracterizar tendencias, ou premiar ós mellores hospedaxes.

```

1 db.listings.aggregate([
2   {
3     $match: {
4       number_of_reviews_l30d: { $gt: 0 },
5       reviews_per_month: { $gt: 0 }
6     }
7   },
8   {
9     $project: {
10       _id: 1,
11       description: 1,
12       city: 1,
13       neighbourhood_group_cleansed: 1,
14       price: 1,
15       "score.rating": 1,
16       number_of_reviews_l30d: 1,
17       reviews_per_month: 1,
18       performance_score: {
19         $add: [
20           { $multiply: ["$number_of_reviews_l30d", 2] },
21           { $multiply: ["$reviews_per_month", 1.5] },
22           { $multiply: ["$score.rating", 10] }
23         ]
24       },
25       recent_popularity: {

```

```

26     $multiply: ["$number_of_reviews_l30d", 10]
27   }
28 }
29 },
30 {
31   $match: {
32     performance_score: { $gt: 40 }
33   }
34 },
35 {
36   $sort: {
37     performance_score: -1,
38     recent_popularity: -1
39   }
40 },
41 {
42   $project: {
43     _id: 1,
44     description: 1,
45     city: 1,
46     neighbourhood: "$neighbourhood_group_cleansed",
47     price: 1,
48     rating: "$score.rating",
49     reviews_last_30d: "$number_of_reviews_l30d",
50     reviews_per_month: 1,
51     performance_score: { $round: ["$performance_score", 2] },
52     status: {
53       $switch: {
54         branches: [
55           { case: { $gte: ["$performance_score", 70] }, then: "
56             Excellent" },
57           { case: { $gte: ["$performance_score", 50] }, then: "Good"
58             },
59           { case: { $gte: ["$performance_score", 40] }, then: "
60             Average" }
61         ],
62         default: "Below Average"
63       }
64     }
65   },
66   { $limit: 15 }
67 ]})

```

Resultados:

```

1  {
2    _id: ObjectId('693348dc7269f26612df5898'),
3    description: 'Ideal room to share stories and experiences with
      capacity for up to 8 people. It has 4 bunk beds. Includes a
      private bathroom, two sinks, air conditioning, free wifi, bed
      linen and an individual space to store your luggage. All beds
      have USB connection to charge your devices. Unite has rooms
      with bathroom adapted for the disabled according to

```

```

    availability.<br />The establishment is cashless.<br />Unite is
    cashless',
4   price: 33,
5   reviews_per_month: 94.77,
6   city: 'barcelona',
7   neighbourhood: 'San Marti',
8   performance_score: 428.45,
9   status: 'Excellent'
10 },
11 {
12   _id: ObjectId('693348dc7269f26612e06f70'),
13   description: 'This bright and cosy double room comes with a double
    bed, air-conditioning, wall-mounted TV and free Wi-Fi. All
    rooms in easyHotel Madrid Alcala offer comfort and cleanliness
    at a budget price to allow you to spend time exploring our
    great city outside of your hotel room. Room size 12 sqm.',
14   price: 128,
15   reviews_per_month: 82.94,
16   city: 'madrid',
17   neighbourhood: 'San Blas - Canillejas',
18   rating: 4.82,
19   reviews_last_30d: 116,
20   performance_score: 404.61,
21   status: 'Excellent'
22 },
23 {
24   _id: ObjectId('693348dc7269f26612df3f4f'),
25   description: 'Flawless time with the whole family in this stylish
    accommodation! <br /><br />The apartments have three bedrooms,
    a bathroom, and a toilet. The master bedroom has a double bed,
    the second bedroom has two single beds and the third bedroom
    has a single bed. <br /><br />Enjoy the freedom and privacy of
    having your own apartment in the city center.',
26   price: 324,
27   reviews_per_month: 61.23,
28   city: 'barcelona',
29   neighbourhood: 'Eixample',
30   rating: 4.72,
31   reviews_last_30d: 100,
32   performance_score: 339.05,
33   status: 'Excellent'
34 },
35
36 ...

```

6. Recheo de nulos usando Aprendizaxe Automático

De forma opcional y rápida, entrenar un modelo de aprendizaje automático utilizando los datos almacenados en MongoDB (por ejemplo, regresión, clasificación, ...). Debe explicarse brevemente el objetivo del modelo, las variables utilizadas y los resultados principales.

Como a columna `price` nos `.csvs` orixinais tiña un 13% de nulos (ver Figura 2), decidimos adestrar un modelo de Aprendizaxe Automático para *regresar* os valores do prezo. Ademáis,

esta tarefa parecíanos interesante de por sí. Para facela cosideramos interesante a columna de centralidade obtida na Consulta 1. Se ben e certo que sae máis a conta calcular esos valores de centralidade directamente en Python, queremos cargar esos valores de MongoDB para simular unha ocasión na que sexa máis doado facer unha consulta. Para isto usamos o arquivo adxunto `mongo2csv.py` que devolve a devandita columna ordeada polo numero de fila para garantir a coherencia e a engade pola dereita ó csv orixinal. Sobre estes datos hai que realizar algunhas modificacións: as columnas de texto libre (como a descripcón ou os barrios) eliminanse, as categoricas (como o tempo de resposta ou o tipo de propiedade) codifícanse *one hot* e as numericas que estaban en porcentaxe formatéanse. Deste xeito temos uns datos listos para adestrar un modelo con eles. O modelo elixido é un XGBoost que baséase en árbores con Boosting e ten licencia Apache 2 . As tarefas de limpeza e adestramento fannas `train.py`, quen tamén reporta os resultados de xeito que:

```

1  (.venv) entrega_03 (main) > python src/train.py
2
3  ...
4
5  =====
6  MODEL EVALUATION
7  =====
8  Mean Absolute Error (MAE): $147.40
9  Root Mean Squared Error (RMSE): $670.78
10 R    Score: 0.7923
11 Mean Absolute Percentage Error (MAPE): 69.3%
12
13 Average Price: $360.79
14 MAE      % of average price: 40.9%
15
16 =====
17 SAMPLE PREDICTIONS (First 10)
18 =====
19 Actual_Price  Predicted_Price  Difference  Error_Percent
20          45.0      138.289993      -93.29      207.31
21          68.0      438.220001     -370.22      544.44
22         128.0      127.089996         0.91         0.71
23         275.0      205.940002        69.06        25.11
24         143.0      143.179993        -0.18         0.13
25          77.0      159.039993     -82.04      106.54
26         132.0      116.050003        15.95        12.09
27         180.0      175.669998         4.33         2.41
28         160.0      124.470001        35.53        22.20
29         174.0      444.450012     -270.45      155.43
30
31 =====
32 TOP 15 FEATURE IMPORTANCES
33 =====
34             Feature  Importance
35             city_lisboa      0.271252
36             host_response_rate      0.053550
37             host_total_listings_count      0.052922
38             host_location_Barcelona, Spain      0.052279
39             host_experience_days      0.052269
40             city_mallorca      0.034516

```


41	host_location_M l a g a , Spain	0.029934
42	beds	0.024191
43	host_location_Palma , Spain	0.022844
44	host_location_Renswoude , Netherlands	0.020828
45	host_response_time_within a day	0.020798
46	host_response_time_within an hour	0.017689
47	host_identity_verified	0.017307
48	property_type_Room aparthotel	0.017164
49	host_location_Munich , Germany	0.017116
50		
51		
52	. . .	

Referencias

- [1] “pandas bsd 3-clause license,” <https://github.com/pandas-dev/pandas?tab=BSD-3-Clause-1-ov-file>, accessed: 2025-12-05.
- [2] Python Software Foundation, “Cpython license (psf license version 2),” <https://github.com/python/cpython?tab=License-1-ov-file>, accessed: 2025-12-05.
- [3] “Gnu general public license, version 3,” <https://www.gnu.org/licenses/gpl-3.0.html>, accessed: 2025-12-05.
- [4] “Mongodb server side public license (sspl),” <https://github.com/mongodb/mongo?tab=License-1-ov-file>, accessed: 2025-12-05.
- [5] “Syntactic sugar,” https://en.wikipedia.org/wiki/Syntactic_sugar, accessed: 2025-12-06.
- [6] “R license,” <https://www.r-project.org/COPYING>, accessed: 2025-12-05.
- [7] “Julia mit license,” <https://github.com/JuliaLang/julia?tab=MIT-1-ov-file>, accessed: 2025-12-05.