

ENTREGA 3: MONGODB

Marcelo Ferreiro Sánchez, Pablo Chantada Saborido
Guillermo García Engelman & Pepe Romero Conde

10 de diciembre de 2025

Índice

1. Introducción	2
2. Modelo de Datos	2
3. Preprocesado de datos	2
3.1. Análisis exploratorio del dataset	2
3.2. Tratamiento de nulos	6
3.2.1. Nulos numéricos	6
3.2.2. Otros nulos	7
3.3. Otras operaciones de procesado	7
4. Definición e implementación da Base de Datos	7
5. Explotación da Base de Datos	9
Consulta 1	9
Consulta 2	10
Consulta 3	11
Consulta 4	13
Consulta 2	14
Consulta 3	16
Consulta 4	18
Consulta 5	20
6. Relleno de nulos usando Aprendizaxe Automático	22
7. Conclusiones	23

1. Introducción

Na práctica actual, mantemos o conxunto de datos de AirBnB, pero cambiamos o foco da explotación analítica. Se ben nas sesións anteriores nos centramos en feitos sinxelos como a táboa de **valoracións**, nesta práctica a nosa atención céntrase nos **hospedaxes**. Este cambio débese á nosa elección de empregar **MongoDB**, unha base de datos NoSQL orientada a documentos, o que nos permite un deseño de datos máis flexible e complexo. O obxectivo é aproveitar as súas características para demostrar a capacidade dos **documentos anidados** e **arrays** embebidos, como os detalles do **host** dentro do documento do **hospedaxe**. Deste xeito, eliminamos a necesidade de realizar custosas **unións** (*joins*) en tempo de consulta, mellorando o desempeño da recuperación e permitindo unha modelaxe máis natural dos datos (sempre cando nosas consultas non teñan como obxectivo devolver hospedadores, nese caso serían algo máis caras).

O deseño da Base de datos terá lugar na sección 4, e será realizado sobre os datos expostos na sección 2.

2. Modelo de Datos

Nesta ocasión non nos limitamos a usar os **.csvs** de unha cidade, con motivo de facer máis diversas as estadísticas e os resultados en xeral. Dende un principio observamos que o porcentaxe de nulos para a mesma columna non era ó meso ó longo das cidades, por eso con varias cidades esperamos unha representación máis fiel da realidade (e.g a cidade de Girona ten 100 % de nulos para a columna **neighbourhood.group.cleansed** mentras que Lisboa ten un 0 %). As primeiras manipulacións que tivemos que facerlle ós datos foi a de eliminar as columnas que non nos interesasen, engadir a columna de “cidade” e apilar todo nun **csv**. Fixemos ese traballo ca librería Pandas [?] de Python [?], xa que os campos de texto libre, como **description**, contiñan caracteres de salto de carro **^M** que dificultaban a tarefa a *oneliners* en AWK [?] (ver o programa adxunto **src/merge_csvs.py** e a Figura 1).

As columnas elixidas pódense ver na Figura 2. A elección foi un compromiso entre expresividade e tamaño, pensamos que cas columnas elixidas podemos facer bos análisis e consultas sen ten que cargar con todo o peso dos **.csvs** orixinais. Ademáis, o teren tipos de datos distintos e mesmo unha estrutura xerárquica implícita, supoñen unha interesante materia prima. A estrutura implícita a modelamos como: unha única colección de hospedaxes na que cada documento ten embebidos outros dous (o hospedador e máis o *Score*) e un arranxo, as prestacións.

3. Preprocesado de datos

3.1. Análisis exploratorio del dataset

Comenzamos a análise co obxecto de estudo da Consulta 1 e da sección 6, o prezo das vivendas. Vemos que en xeral a distribución $p(\$ = X)$ ten as colas moi longas (aunque por exemplo $p(\$ = X | \text{cidade} = \text{Madrid})$ non tanto). Vemos que as dous cidades con maiores abanicos son as ínsuas, que efectivamente hai unha correlación entre o que custa un hospedaxe e a xente que cabe nel (ver Consulta 4) e que o logaritmo é unha mellor forma de representar o prezo.






Figura 1: A primeira transformación e xuntar os datos de distintas cidades e quitar as columnas que non nos interesen. Aproveitamos a ocasión para facer unha imputación sinxela, *vainilla* dos datos




No gráfico de abaixo podemos ver o esparsidos que están os hospedaxes nas cidades, o cal repercutirá no índice de centralidade, ver Consulta 1. Parécenos curioso que Mallorca está tan plagada de turismo que pódese reconecer a forma insuar dende este gráfico.



Figura 2: Diagrama do Modelo de Datos



Por último queríamos mostrar as distribucións mas dispersas, tanto que parece que estan cheas de atípicos. Per nos pensamos que non é o caso, que simplemente a realidade é dispersa, como veremos en 5.



3.2. Tratamiento de nulos

Como logo temos que volcar os datos a MongoDB (licencia en [?]), o noso programa xa limpia os datos cunha imputación sinxela pero apropiada para o tipo de datos (o exisido pola práctica), non obstante podemos desactivala e observar os nulos do arquivo mergeado, o porcentaxe está dispoñíbel na Figura 2. Ademáis do porcentaxe é interesante o tipo de dato e o rol que desempeña esa columna.

3.2.1. Nulos núéricos

Dende logo o tipo de dato condiciona as opcións de imputación. Ademáis pódese dicir que estos nulos divídense en tres grupos: os relacionados co inmobiliario (baños, habitacións e camas), os valores das reseñas e tres atributos do hospedador. Unha primeira idea de encher os nulos dun grupo con valores do mesmo (e.g. imputar o *score* de comunicación co resto de *scores*) desmantelouse á vista da Figura 3, e dicir, non se poden encher os nulos dun grupo con valores dese grupo porque cando un é nulo os outros tamén (alta correlación). Ademáis por curiosidade, fixemos un experimento (ver `src/knn_vs_median.py` ou Cadro ??) para ver a diferenza de error se usamos imputación simple (mediana) ou máis sofisticada (adestramento dun KNN non paramétrico) e obervamos que o erro malia ser a metade co método sofisticado, segue estando no mesmo orde de magnitude e ademáis encarece moito computacionalmente. Por todo o dito, e o alcance da práctica, limitámonos a unha imputación sinxela por mediana.




Figura 3: Correlación entre os nulos. Pódese apreciar claramente que os *scores* son nulos á vez, igual que cos membros do inmobiliario.

Cuadro 1: Comparación de MSE: Imputación por Mediana vs KNN

Variable	MSE Mediana	MSE KNN
bathrooms	0.5484	0.3359
beds	3.1542	2.2738
host_total_listings_count	30972.2424	27884.0846
bedrooms	1.0932	0.8283

3.2.2. Outros nulos

Como pode verse na función `fillna` do arquivo `src/merge_csvs.py`, tanto os Booleanos como os Strings impútanse mediante a moda. Se ben poderíanse levar acabo operacións máis sofisticadas, polo alcance da práctica limitámonos a esta opción.

3.3. Outras operaciones de procesado

Se ben o discutido ate agora foi máis ben dos valores en sí, cabe destacar que para volcar os datos a MongoDB foi necesario un especial arranxo dos datos, en particular para o formato dos dous documentos embebidos e do arranxo de prestacións, estas operacións, en cambio as situamos na fase de carga (*Load*) e por tanto lévanse acabo no arquivo adxunto `csv2mongo.py`.

4. Definición e implementación da Base de Datos




Figura 4: Una vez que temos todos os datos nun `.csv` sobre o cal podemos facer Análisis Exploratorio, estamos listos para pasalos datos a MongoDB, segundo a definición do esquema dada na sección 2

O modelo de Datos da Figura 2 é o “esquema” que usaremos en MongoDB. Dado o noso planteamento de centrarnos nos hospedaxes (os protagonistas dos `csvs` máis grandes e argumentablemente da aplicación enteira de AirBnB) non houbo moitas decisións de diseño difíciles. O arranxo prestacións tiña que ser un arranxo en MongoDB e os *scores* son un documento embebido principalmente por sucre sintáctica [?]; en cambio os hospedadores ben podían ter sido unha colección por si mesma. Tal cousa tería sentido se fixeramos consultas hospedador-centricas, é dicir, se pensásemos os hospedadores como entidades por si mesmas, non foi o noso caso pois pensamos que o hospedador ven surrogado ó hospedaxe e as consultas que iamos facer non precisaban a complexidade de varias coleccións.

Dito o anterior, a Base de Datos móntase co *script* adxunto `csv2mongo.py`. Este establece conexión cun cliente de Mongo local e carga os datos no formato especificado, de xeito que podemos facer:

```

1  (.venv) entrega_03 (main) > python src/mongo/csv2mongo.py
2  Inserted 158754 listings into airbnb.listings
3  (.venv) entrega_03 (main) > mongosh
4  Current Mongosh Log ID: 69347505a2994911f4cd9cc3
5  Connecting to:          mongodb://127.0.0.1:27017/?directConnection=
    true&serverSelectionTimeoutMS=2000&appName=mongosh+2.5.10
6  Using MongoDB:         8.2.2
7  Using Mongosh:         2.5.10
8
9  For mongosh info see: https://www.mongodb.com/docs/mongodb-shell/
10
11  -----
12  The server generated these startup warnings when booting
13  2025-12-06T16:07:08.499+01:00: Access control          enabled for
    the database. Read      write access to data      configuration
    unrestricted
14  -----
15
16  test> use airbnb
17  switched to db airbnb
18  airbnb> db.listings.findOne()
19  {
20    _id: ObjectId('693474fcce4ae65c237470e5'),
21    neighbourhood_group_cleansed: 'Eixample',
22    latitude: 41.40556,
23    longitude: 2.17262,
24    property_type: 'Entire rental unit',
25    accommodates: 8,
26    bathrooms: 2,
27    bedrooms: 3,
28    beds: 6,
29    price: 210,
30    number_of_reviews: 51,
31    number_of_reviews_l30d: 0,
32    availability_eoy: 74,
33    instant_bookable: true,
34    reviews_per_month: 0.34,
35    city: 'barcelona',
36    host: {
37      since: '2010-01-19',
38      location: 'Barcelona, Spain',
39      response_time: 'within an hour',
40      response_rate: '96%',
41      acceptance_rate: '91%',
42      is_superhost: false,
43      total_listings_count: 46,
44      has_profile_pic: true,
45      identity_verified: true
46    },
47    score: {
48      rating: 4.34,
49      accuracy: 4.4,
50      cleanliness: 4.56,

```

```

51     checkin: 4.64,
52     communication: 4.62,
53     location: 4.82,
54     value: 4.32
55 },
56 amenities: [
57     '["Pets allowed',
58     '30 inch TV',
59     'Coffee maker',
60     'Elevator',
61     'Host greets you',
62     'Pack \\u2019n play/Travel crib',
63     'Heating',
64     'Hangers',
65     'AC - split type ductless system',
66     'Iron',
67     'Crib',
68     'Dishes and silverware',
69     'Private patio or balcony',
70     'Kitchen',
71     'Essentials',
72     'Free washer \\u2013 In unit',
73     'Wifi',
74     'Hot water',
75     'City skyline view',
76     'Shampoo',
77     'Hair dryer',
78     'Refrigerator"]'
79 ],
80 row_id: 0
81 }

```

Pódese ver que a operación é exitosa e a consulta da liña 18 e só un exemplo para demostrar o funcionamento. Ademáis pódese ver que ó final do documento hai un atributo de fila, este vai ser útil na sección 6 pois imos ter que exportar o resultado da primeira consulta de MongoDB a csv de volta, e ter o identificador de fila vains valer para emparexar fácilmente. Sen identificador de fila teríamos que exportar a base de datos enteira, pero con el, podemos devolver as columnas que creemos en MongoDB ordeadas por `row_id` e teremos a certeza de que vai cuadrar ben.

5. Explotación da Base de Datos

Agora que hemos definido e implementado a nosa Base de Datos,

Consulta 1: Obter un índice de centralidade (dentro da cidade) para cada hospedaxe

Xustificación: como verase na sección 6, imos usar este valor para facer prediccións sobre o precio de cada hospedaxe. Ademáis parecíanos un bo uso das funcións nativas de MongoDB.

Para levar acabo esta consulta precisamos calcular os centroides de cada cidade e logo, para cada hospedaxe calcularemos a distancia ó centroide. O seguinte código crea ditos centroides, agregando os hospedaxes por cidade e facendo a media das súas coordenadas.

```

1 const centroides = db.listings.aggregate([
2   {
3     $group: {
4       _id: "$city",
5       avg_lat: { $avg: "$latitude" },
6       avg_lon: { $avg: "$longitude" }
7     }
8   }
9 ]).toArray();

```

Agora que temos eso só nos queda facer un `updateMany` no que por cada centroide, collemos os hospedaxes desa cidade e calculamos a distancia euclídea do centroide ó hospedaxe. Malia seren moitas liñas, as liñas 8-13 correspóndense co cálculo.

```

1 centroides.forEach(c => {
2   db.listings.updateMany(
3     { city: c._id },      // filtro
4     [
5       {
6         $set: {
7           centrality: {
8             $sqrt: {
9               $add: [
10                { $pow: [{ $subtract: ["$latitude", c.avg_lat] }, 2]
11                },
12                { $pow: [{ $subtract: ["$longitude", c.avg_lon] }, 2]
13                }
14              ]
15            }
16          }
17        }
18      ]
19    );
20 });

```

Resultados: Tal cual o fixemos cambia a base de datos, non devolve. Para ver o efecto podemos facer unha mini-consulta de comprobación como `db.listings.findOne()` e ver que xa figura o novo atributo.

Consulta 2: Influe foto de perfil no prezo medio?

Xustificación: de ser certo, AirBnB debería exisir ós seus hospedadores que se poñan foto, ou mesmo saldría deles. Tamén é interesante dende o punto de vista sociolóxico.

Esta consulta é sinxela, só hai que agrupar por valor de `host.has_profile_pic`, agregando o prezo

```

1 db.listings.aggregate([
2   {
3     $group: {
4       _id: "$host.has_profile_pic",
5       avg_price: { $avg: "$price" },
6       min_price: { $min: "$price" },
7       max_price: { $max: "$price" },

```

```

8     std_dev_price: { $stdDevSamp: "$price" },
9     count: { $sum: 1 }
10  }
11 },
12 {
13     $project: {
14         has_profile_pic: "$_id",
15         avg_price: { $round: ["$avg_price", 2] },
16         min_price: 1,
17         max_price: 1,
18         std_dev_price: 1,
19         count: 1,
20         _id: 0
21     }
22 },
23 { $sort: { has_profile_pic: 1 } }
24 ])
```

Resultados: como pode verse os resultados obtidos (ver abaixo) son algo significativos, posto que aínda que as medias son distintas as desviacións estándar solápanse. En calquera caso, análise de distribucións é algo que debería facerse en R [?], Julia [?] ou Python pero non en MongoDB.

```

1  {
2    min_price: 8,
3    max_price: 18000,
4    std_dev_price: 407.5147249606762,
5      : 4682,
6    has_profile_pic: false,
7    avg_price: 161.12
8  },
9  {
10   min_price: 8,
11   max_price: 92150,
12   std_dev_price: 1500.7666758984817,
13     : 154072,
14   has_profile_pic: true,
15   avg_price: 366.86
16 }
```

Consulta 3: Cal é o hospedaxe que ten 40 habitacións?

Xustificación: É un anómalo realmente?

```

1  airbnb> db.listings.find({bedrooms : {$gt : 40}}, {bedrooms : 1}).
    sort({ bedrooms: -1 })
```

```

1  [
2    { _id: ObjectId('693479deab134920609e549c'), bedrooms: 43 },
3    { _id: ObjectId('693846ba023c5ca99b6f26e6'), bedrooms: 43 },
4    { _id: ObjectId('693848aca2b4d841d69f4700'), bedrooms: 43 }
5  ]
```

```
1  airbnb> db.listings.find({_id : 693479deab134920609e549c})
```

Resultados: Vemos que é un hotel, polo que non poderíamos dicir que é un dato erróneo, e esperaríamos máis hoteles polo que quedarnos con él parece lóxico.

```
1  [
2    {
3      _id: ObjectId('693479deab134920609e549c'),
4      description: 'Cascais at your door',
5      neighbourhood_group_cleansed: 'Cascais',
6      latitude: 38.69952,
7      longitude: -9.42015,
8      property_type: 'Room in hotel',
9      accommodates: 3,
10     bathrooms: 1,
11     bedrooms: 43,
12     beds: 2,
13     price: 128,
14     number_of_reviews: 9,
15     number_of_reviews_l30d: 0,
16     availability_eoy: 80,
17     instant_bookable: true,
18     reviews_per_month: 0.14,
19     city: 'lisboa',
20     host: {
21       since: '2020-07-16',
22       location: 'Madrid, Spain',
23       response_time: 'within an hour',
24       response_rate: '100%',
25       acceptance_rate: '100%',
26       is_superhost: true,
27       total_listings_count: 7,
28       has_profile_pic: true,
29       identity_verified: true
30     },
31     score: {
32       rating: 4.67,
33       accuracy: 5,
34       cleanliness: 4.89,
35       checkin: 4.78,
36       communication: 4.78,
37       location: 5,
38       value: 4.44
39     },
40     amenities: [
41       'Heating',
42       'Smoke alarm',
43       'Essentials',
44       'Private entrance',
45       'Carbon monoxide alarm',
46       'Breakfast',
47       'Self check-in',
48       'Air conditioning',
49       'HDTV',
```

```

50     'Shampoo',
51     'Exterior security cameras on property',
52     'Fire extinguisher',
53     'Iron',
54     'Building staff',
55     'Hangers',
56     'Hair dryer',
57     'Wifi"]'
58 ],
59 row_id: 52196,
60 centrality: 0.22156954910595233
61 }
62 ]

```

Consulta 4: cuales son os barrios con hospedadores máis novos? Para cada cidade

Xustificación: A plataforma de AirBnB podría sinalar que un hospedaxe ten tantas camas como habitacións o cal estaría ben, por exemplo, para viaxes de parella ou grupos. Pero primeiro, hai tales hospedaxes?

```

1  airbnb> db.listings.find(
2  |    { beds: { $gt: 5 }, $expr: { $eq: ["$beds", "$bedrooms"] } },
3  |    { price: 1, beds: 1 }
4  | ).sort({ beds: -1 })

```

Resultados: Vemos que sí, Hoteis.

```

1  [
2    { _id: ObjectId('693479deab134920609efe31'), beds: 25, price: 72 },
3    { _id: ObjectId('693848aca2b4d841d6a020f4'), beds: 25, price: 72 },
4    { _id: ObjectId('693846ba023c5ca99b7000da'), beds: 25, price: 72 },
5    { _id: ObjectId('693848ada2b4d841d6a0f3f7'), beds: 20, price: 29 },
6    { _id: ObjectId('693848ada2b4d841d6a0f3f4'), beds: 20, price: 41 },
7    { _id: ObjectId('693479deab134920609fdf9c'), beds: 20, price: 41 },
8    { _id: ObjectId('693479deab134920609fdf9b'), beds: 20, price: 36 },
9    { _id: ObjectId('693479deab134920609fdf98'), beds: 20, price: 36 },
10   { _id: ObjectId('693479deab134920609fdf97'), beds: 20, price: 31 },
11   { _id: ObjectId('693846ba023c5ca99b70d3d9'), beds: 20, price: 36 },
12   { _id: ObjectId('693479deab134920609fdf96'), beds: 20, price: 28 },
13   { _id: ObjectId('693479deab134920609fdf95'), beds: 20, price: 36 },
14   { _id: ObjectId('693479deab134920609fdf94'), beds: 20, price: 37 },
15   { _id: ObjectId('693846ba023c5ca99b70d3e6'), beds: 20, price: 41 },
16   { _id: ObjectId('693846ba023c5ca99b70d3e5'), beds: 20, price: 36 },
17   { _id: ObjectId('693848ada2b4d841d6a0f400'), beds: 20, price: 41 },
18   { _id: ObjectId('693848ada2b4d841d6a0f3ff'), beds: 20, price: 36 },
19   { _id: ObjectId('693846ba023c5ca99b70d3e2'), beds: 20, price: 36 },
20   { _id: ObjectId('693846ba023c5ca99b70d3e1'), beds: 20, price: 31 },
21   { _id: ObjectId('693479deab134920609fdf93'), beds: 20, price: 29 }
22 ]

```

Consulta 4: Cales son os barrios con hospedadores máis novos? Para cada cidade

Xustificación: esta consulta é básica para o análise de tendencias e evolución do mercado inmobiliario.

```
1 db.listings.aggregate([
2   {
3     $project: {
4       city: 1,
5       neighbourhood_group_cleansed: 1,
6       host_since: "$host.since",
7       year: { $year: { $toDate: "$host.since" } }
8     }
9   },
10  {
11    $group: {
12      _id: {
13        city: "$city",
14        neighbourhood: "$neighbourhood_group_cleansed"
15      },
16      avg_host_year: { $avg: "$year" },
17      count: { $sum: 1 }
18    }
19  },
20  {
21    $sort: { "_id.city": 1, "avg_host_year": -1 }
22  },
23  {
24    $group: {
25      _id: "$_id.city",
26      neighbourhoods: {
27        $push: {
28          neighbourhood: "$_id.neighbourhood",
29          avg_host_year: "$avg_host_year",
30          count: "$count"
31        }
32      }
33    }
34  },
35  {
36    $project: {
37      city: "$_id",
38      neighbourhoods: {
39        $slice: [
40          {
41            $sortBy: {
42              input: "$neighbourhoods",
43              sortBy: { avg_host_year: -1 }
44            }
45          },
46          5
47        ]
48      }
49    }
50  }
51 ]
```

```

49     }
50 }
51 ])

```

Resultados: se ben non procede mostrar os resultados completos, abaixo pódese ver as cidades con barrios máis novos. O certo é que a forma de mostrar esta consulta non so compara os barrios dentro dunha cidade pero ademáis as cidades entre sí.

```

1  ...
2
3  {
4    _id: 'euskadi',
5    city: 'euskadi',
6    neighbourhoods: [
7      {
8        neighbourhood: 'Vizcaya',
9        avg_host_year: 2019.032435404068,
10       : 3638
11      },
12      {
13        neighbourhood: 'Alava',
14        avg_host_year: 2017.819964349376,
15       : 561
16      },
17      {
18        neighbourhood: 'Guipuzcoa',
19        avg_host_year: 2017.6565040650407,
20       : 2952
21      }
22    ]
23  },
24  {
25    _id: 'madrid',
26    city: 'madrid',
27    neighbourhoods: [
28      {
29        neighbourhood: 'Vic lvaro',
30        avg_host_year: 2020.0117647058823,
31       : 85
32      },
33      {
34        neighbourhood: 'Tetu n',
35        avg_host_year: 2019.724836212031,
36       : 1679
37      },
38      {
39        neighbourhood: 'Villaverde',
40        avg_host_year: 2019.5731707317073,
41       : 246
42      },
43      {
44        neighbourhood: 'Villa de Vallecas',
45        avg_host_year: 2019.4336283185842,
46       : 113

```

```

47     },
48     {
49         neighbourhood: 'Barajas',
50         avg_host_year: 2019.3680981595091,
51         : 163
52     }
53 ]
54 },
55 {
56     _id: 'valencia',
57     city: 'valencia',
58     neighbourhoods: [
59         {
60             neighbourhood: 'BENICALAP',
61             avg_host_year: 2020.3698630136987,
62             : 146
63         },
64         {
65             neighbourhood: 'JESUS',
66             avg_host_year: 2020.0177304964539,
67             : 282
68         },
69         {
70             neighbourhood: 'RASCANYA',
71             avg_host_year: 2019.9685534591194,
72             : 159
73         },
74         {
75             neighbourhood: 'ALGIROS',
76             avg_host_year: 2019.9149560117303,
77             : 341
78         },
79         {
80             neighbourhood: 'PATRAIX',
81             avg_host_year: 2019.864406779661,
82             : 177
83         }
84     ]
85 }

```

Consulta 5: Cales son os barrios con hospedaxes máis grandes (máis habitacións)?

Xustificación: esta información é decisiva nun análise de desigualdade entre territorios, ou mesmo pode ser de interese gobernamental, para o desenvolvemento de leis.

```

1 db.listings.aggregate([
2   {
3     $match: {
4       bedrooms: { $exists: true, $ne: null },
5       neighbourhood_group_cleansed: { $exists: true, $ne: null }
6     }
7   },

```

```

8 {
9   $group: {
10     _id: {
11       city: "$city",
12       neighbourhood: "$neighbourhood_group_cleansed"
13     },
14     avg_bedrooms: { $avg: "$bedrooms" },
15     max_bedrooms: { $max: "$bedrooms" },
16     total_properties: { $sum: 1 },
17     large_properties: {
18       $sum: { $cond: [{ $gte: ["$bedrooms", 3] }, 1, 0] }
19     }
20   }
21 },
22 {
23   $project: {
24     city: "$_id.city",
25     neighbourhood: "$_id.neighbourhood",
26     avg_bedrooms: { $round: ["$avg_bedrooms", 2] },
27     max_bedrooms: 1,
28     total_properties: 1,
29     large_properties_percentage: {
30       $round: [
31         { $multiply: [{ $divide: ["$large_properties", "$total_properties"] }, 100] },
32         2
33       ]
34     }
35   }
36 },
37 { $sort: { "avg_bedrooms": -1, "large_properties_percentage": -1 } },
38 { $limit: 10 }
39 ]))

```

Resultados: Móstrase abaixo os 3 mellores hospedadores deste mes (hospedadores con mellor performance score, composto dunha ponderación do número de reviews do último mes, súas reviews por mes e o seu rating).

```

1 {
2   _id: { city: 'porto', neighbourhood: 'SAO JOAO DA MADEIRA' },
3   max_bedrooms: 20,
4   total_properties: 49,
5   city: 'porto',
6   neighbourhood: 'SAO JOAO DA MADEIRA',
7   avg_bedrooms: 7.76,
8   large_properties_percentage: 40.82
9 },
10 {
11   _id: { city: 'mallorca', neighbourhood: 'Lisboa' },
12   max_bedrooms: 20,
13   total_properties: 15034,
14   city: 'mallorca',
15   neighbourhood: 'Lisboa',

```

```

16     avg_bedrooms: 2.95,
17     large_properties_percentage: 62.63
18 },
19 {
20     _id: { city: 'lisboa', neighbourhood: 'Azambuja' },
21     max_bedrooms: 5,
22     total_properties: 18,
23     city: 'lisboa',
24     neighbourhood: 'Azambuja',
25     avg_bedrooms: 2.83,
26     large_properties_percentage: 50
27 },
28 {
29     _id: { city: 'menorca', neighbourhood: 'Lisboa' },
30     max_bedrooms: 12,
31     total_properties: 3679,
32     city: 'menorca',
33     neighbourhood: 'Lisboa',
34     avg_bedrooms: 2.66,
35     large_properties_percentage: 52.6
36 },
37
38 ...

```

Consulta 6: Cales son os hospedaxes con hospedadores fóra desa cidade?

Xustificación: Ter un hospedador que vive lonxe (noutra cidade) pode ser un inconveniente tanto para os inquilinos como para o propio AirBnB se é que estes están discontentos. Caracterizalos é importante.

```

1 db.listings.aggregate([
2   {
3     $project: {
4       _id: 1,
5       city: 1,
6       neighbourhood_group_cleansed: 1,
7       host_location: "$host.location",
8       host_city: {
9         $let: {
10           vars: {
11             loc: { $toLower: "$host.location" }
12           },
13           in: {
14             $arrayElemAt: [
15               { $split: ["$$loc", ","] },
16               0
17             ]
18           }
19         }
20       }
21     }
22   },

```

```

23 {
24   $match: {
25     $expr: {
26       $ne: [
27         { $trim: { input: { $toLower: "$city" } } },
28         { $trim: { input: "$host_city" } }
29       ]
30     }
31   }
32 },
33 {
34   $project: {
35     _id: 1,
36     property_city: "$city",
37     property_neighbourhood: "$neighbourhood_group_cleansed",
38     host_location: 1,
39     host_city: 1,
40     is_different_city: true
41   }
42 },
43 { $limit: 20 }
44 ])
```

Resultados: Abaixo podemos ver tres exemplos deste tipo de hospedadores. Curiosamente as tres descripcións están inglés, o cal denota impersonalidade.

```

1   _id: ObjectId('693479ddab134920609d88b9'),
2   host_location: 'Catalonia, Spain',
3   host_city: 'catalonia',
4   property_city: 'barcelona',
5   property_neighbourhood: 'Sant Marti'
6 },
7 {
8   _id: ObjectId('693479ddab134920609d88c5'),
9   host_location: 'Vilassar de Mar, Spain',
10  host_city: 'vilassar de mar',
11  property_city: 'barcelona',
12  property_neighbourhood: 'Sant Marti'
13 },
14 {
15   _id: ObjectId('693479ddab134920609d88c7'),
16   host_location: 'Colon, Panama',
17   host_city: 'colon',
18   property_city: 'barcelona',
19   property_neighbourhood: 'Eixample'
20 },
21
22 ...
```

Consulta 7: Cales son os hospedaxes que estan a facer un bo último mes?

Xustificación: esta consula é de carácter moi xeral e o interese pode vir de moitos lados, os hospedadores poden querer estudar que fan eses hospedaxes tan bos; tamén AirBnB pódese ver beneficiado se é capaz de caracterizar tendencias, ou premiar ós mellores hospedaxes.

```
1 db.listings.aggregate([
2   {
3     $match: {
4       number_of_reviews_130d: { $gt: 0 },
5       reviews_per_month: { $gt: 0 }
6     }
7   },
8   {
9     $project: {
10       _id: 1,
11       city: 1,
12       neighbourhood_group_cleansed: 1,
13       price: 1,
14       "score.rating": 1,
15       number_of_reviews_130d: 1,
16       reviews_per_month: 1,
17       performance_score: {
18         $add: [
19           { $multiply: ["$number_of_reviews_130d", 2] },
20           { $multiply: ["$reviews_per_month", 1.5] },
21           { $multiply: ["$score.rating", 10] }
22         ]
23       },
24       recent_popularity: {
25         $multiply: ["$number_of_reviews_130d", 10]
26       }
27     },
28   },
29   {
30     $match: {
31       performance_score: { $gt: 40 }
32     }
33   },
34   {
35     $sort: {
36       performance_score: -1,
37       recent_popularity: -1
38     }
39   },
40   {
41     $project: {
42       _id: 1,
43       city: 1,
44       neighbourhood: "$neighbourhood_group_cleansed",
45       price: 1,
46       rating: "$score.rating",
47       reviews_last_30d: "$number_of_reviews_130d",
```

```

48     reviews_per_month: 1,
49     performance_score: { $round: ["$performance_score", 2] },
50     status: {
51         $switch: {
52             branches: [
53                 { case: { $gte: ["$performance_score", 70] }, then: "
54                     Excellent" },
55                 { case: { $gte: ["$performance_score", 50] }, then: "Good"
56                     },
57                 { case: { $gte: ["$performance_score", 40] }, then: "
58                     Average" }
59             ],
60             default: "Below Average"
61         }
62     },
63     { $limit: 15 }
64 ]})

```

Resultados:

```

1  {
2    _id: ObjectId('693348dc7269f26612df5898'),
3    price: 33,
4    reviews_per_month: 94.77,
5    city: 'barcelona',
6    neighbourhood: 'San Marti',
7    performance_score: 428.45,
8    status: 'Excellent'
9  },
10 {
11   _id: ObjectId('693348dc7269f26612e06f70'),
12   price: 128,
13   reviews_per_month: 82.94,
14   city: 'madrid',
15   neighbourhood: 'San Blas - Canillejas',
16   rating: 4.82,
17   reviews_last_30d: 116,
18   performance_score: 404.61,
19   status: 'Excellent'
20 },
21 {
22   _id: ObjectId('693348dc7269f26612df3f4f'),
23   price: 324,
24   reviews_per_month: 61.23,
25   city: 'barcelona',
26   neighbourhood: 'Eixample',
27   rating: 4.72,
28   reviews_last_30d: 100,
29   performance_score: 339.05,
30   status: 'Excellent'
31 },
32

```

6. Recheo de nulos usando Aprendizaxe Automático

Como a columna `price` nos `.csvs` orixinais tiña un 13 % de nulos (ver Figura 2), decidimos adestrar un modelo de Aprendizaxe Automático para *regresar* os valores do prezo. Ademáis, esta tarefa parecíanos interesante de por sí. Para facela cosideramos interesante a columna de centralidade obtida na Consulta 1. Se ben e certo que sae máis a conta calcular esos valores de centralidade directamente en Python, queremos cargar esos valores de MongoDB para simular unha ocasión na que sexa máis doado facer unha consulta. Para isto usamos o arquivo adxunto `mongo2csv.py` que devolve a devandita columna ordeada polo numero de fila para garantir a coherencia e a engade pola dereita ó csv orixinal. Sobre estes datos hai que realizar algunhas modificacións: as columnas de texto libre (como a descrición ou os barrios) eliminanse, as categoricas (como o tempo de resposta ou o tipo de propiedade) codifícanse *one hot* e as numericas que estaban en porcentaxe formatéanse. Deste xeito temos uns datos listos para adestrar un modelo con eles. O modelo elixido é un XGBoost que baséase en árbores con Boosting e ten licencia Apache 2, polo que podería ter efectivamente un uso comercial por parte airbnb ou algunha empresa de hospedaxes xa que a licencia o permite. As tarefas de limpeza e adestramento fannas `train.py`, quen tamén devolve tablas $\text{\LaTeX}$ como saída.

Cuadro 2: Métricas do modelo

Métrica	Valor
MAE	128.02
RMSE	933.03
R^2	0.58
MAPE (\ %)	57.31
Prezo medio	327.23
MAE / Prezo medio (\ %)	39.12

Cuadro 3: Predicións de exemplo

Prezo real	Prezo predicido	Diferenza	Erro (\ %)
148.000000	250.000000	-102.000000	68.920000
32.000000	82.559998	-50.560000	158.000000
144.000000	234.710007	-90.710000	62.990000
9143.000000	6978.950195	2164.050000	23.670000
192.000000	169.710007	22.290000	11.610000
51.000000	111.699997	-60.700000	119.020000
126.000000	123.199997	2.800000	2.220000
40.000000	42.880001	-2.880000	7.210000
192.000000	200.089996	-8.090000	4.220000
25.000000	113.599998	-88.600000	354.400000

Cuadro 4: Importancia das variables

Variable	Importancia
property_type_Room in aparthotel	0.086350
host_total_listings_count	0.053015
city_lyon	0.048556
host_response_rate	0.044750
host_location_Barcelona, Spain	0.038908
host_location_London, United Kingdom	0.031774
city_mallorca	0.030695
host_experience_days	0.030252
host_location_Munich, Germany	0.028399
host_location_Petra, Spain	0.027636
property_type_Room in boutique hotel	0.025786
property_type_Room in serviced apartment	0.025423
city_lisboa	0.024066
property_type_Room in hotel	0.021175
host_location_Zürich, Switzerland	0.019949

7. Conclusións

Deseñada a base de datos e realizadas as consultas de exemplo, estimamos este enfoque do traballo como potencialmente útil para o análise de mercado neste sector dos alugueres/turismo. Enforcar a BD hacia os listings permitiunos aplicar características clave e moi útiles da plataforma MongoDB (como os xa mencionados arrays embebidos e documentos anidados) as cales houberan sido mais difíciles de aplicar e mostrar súa utilidade se o enfoque principal da base seguera sendo as reviews en sí.

Deste modo tamén foi trivial a tarefa de pensar nunha aplicación dun modelo de Aprendizaxe Automática, pois pode resolver un problema real, o de suxerir un prezo para o usuario que quere publicar un novo listing, ademáis do seu posible uso para rechear nulos.

Para cerrar esta conclusión gustaríanos sinalar como posible traballo futuro a construción da base de datos tendo as reviews como elemento principal. Isto permitiría a construción dun dataset útil para algúns modelos de Linguaxe (estilo BERT). Seu uso principal sería entrenalos sobre todo o texto das reviews e que esencialmente realice unha tarefa de análise de sentimentos sobre eles, sendo capaz incluso de asociarlles un rating mais preciso e realista que o do propio usuario (xeralmente os ratings dados polos usuarios non seguen a distribución normal, senón que teñen picos nos extremos, moitas reviews teñen 0 e 5 estrelas).